

Toma de Decisiones Secuencial y Aprendizaje por Refuerzo

Clase 1

- Introducción al Aprendizaje por Refuerzo
- Procesos Markovianos
 - Definición
 - Propiedades
 - Ejemplos

Aprendizaje Automático (Machine Learning)

Aprendizaje No Supervisado

Datos




Modelo




Resultado

Aprendizaje Automático (Machine Learning)

Aprendizaje No Supervisado




Aprendizaje Supervisado



Aprendizaje Automático (Machine Learning)


Aprendizaje No Supervisado



- Agrupamiento (clustering)
- Reducción de dimensionalidad
- Extracción de características


Aprendizaje Automático (Machine Learning)

Aprendizaje No Supervisado



- Agrupamiento (clustering)
- Reducción de dimensionalidad
- Extracción de características


Aprendizaje Supervisado



- Clasificación
- Regresión


Aprendizaje Automático

Aprendizaje Por Refuerzo (Reinforcement Learning)




Aprendizaje Automático

Aprendizaje Por Refuerzo (Reinforcement Learning)



Aprendizaje Automático

Aprendizaje Por Refuerzo (Reinforcement Learning)



Aprendizaje Por Refuerzo (Reinforcement Learning)

- Aprendizaje de estrategias óptimas para situaciones que se extienden en el tiempo

Aprendizaje Por Refuerzo (Reinforcement Learning)

- Aprendizaje de estrategias óptimas para situaciones que se extienden en el tiempo
- La función de “refuerzo” puede ser diseñada para expresar diferentes objetivos
- Modelo de toma de decisiones **secuenciales**:
 - Ambiente tiene un **estado** que cambia al largo del tiempo
 - Evolución del estado afectada por decisiones
 - Función de “refuerzo” afectada por estado y decisiones

Aprendizaje Por Refuerzo (Reinforcement Learning)

- Dificultades extras vs otros tipos de aprendizaje:
 - las consecuencias de una acción actual pueden impactar en el futuro
 - no hay una señal directa midiendo ese impacto, solo la recompensa inmediata

Aprendizaje Por Refuerzo (Reinforcement Learning)



- Dificultades extras vs otros tipos de aprendizaje:
 - las consecuencias de una acción actual pueden impactar en el futuro
 - no hay una señal directa midiendo ese impacto, solo la recompensa inmediata
 - el ambiente puede ser desconocido
 - necesidad de aprender un modelo del ambiente y la acción

Aprendizaje Por Refuerzo (Reinforcement Learning)

- Dificultades extras vs otros tipos de aprendizaje:
 - las consecuencias de una acción actual pueden impactar en el futuro
 - no hay una señal directa midiendo ese impacto, solo la recompensa inmediata
 - el ambiente puede ser desconocido
 - Necesidad de aprender un modelo del ambiente y la acción
 - potencialmente muchas acciones posibles
 - Hay que encontrar una forma eficiente de explorar las acciones

Aprendizaje Por Refuerzo - Juegos



TD-Gammon (1992)



Aprendizaje Por Refuerzo - Juegos

TD-Gammon (1992)

AlphaGo (2015-2017)



Aprendizaje Por Refuerzo - Robótica



Aprendizaje Por Refuerzo - Medicina

Reinforcement Learning in Healthcare: A Survey

Chao Yu, Jiming Liu, *Fellow, IEEE*, and Shamim Nemati


Abstract—As a subfield of machine learning, *reinforcement learning* (RL) aims at empowering one's capabilities in behavioural decision making by using interaction experience with the world and an evaluative feedback. Unlike traditional supervised learning methods that usually rely on one-shot, exhaustive and supervised reward signals, RL tackles with sequential decision making problems with sampled, evaluative and delayed feedback simultaneously. Such distinctive features make RL technique a suitable candidate for developing powerful solutions in a variety of healthcare domains, where diagnosing decisions or treatment regimes are usually characterized by a prolonged and sequential procedure. This survey discusses the broad applications of RL techniques in healthcare domains, in order to provide the research community with systematic understanding of theoretical foundations, enabling methods and techniques, existing challenges, and new insights of this emerging paradigm. By first briefly examining theoretical foundations and key techniques in RL research from efficient and representational directions, we then provide an overview of RL applications in healthcare domains ranging from dynamic treatment regimes in chronic diseases and critical care, automated medical diagnosis from both unstructured and structured clinical data, as well as many other control or scheduling domains that have infiltrated many aspects of a healthcare system. Finally, we summarize the challenges and open issues in current research, and point out some potential solutions and directions for future research.

Index Terms—Reinforcement Learning, Healthcare, Dynamic Treatment Regimes, Critical Care, Chronic Disease, Automated Diagnosis.

feedback and the new state from the environment. The goal of the agent is to learn an optimal policy (i.e., a mapping from the states to the actions) that maximizes the accumulated reward it receives over time. Therefore, agents in RL do not receive direct instructions regarding which action they should take, instead they must learn which actions are the best through trial-and-error interactions with the environment. This adaptive closed-loop feature renders RL distinct from traditional supervised learning methods for regression or classification, in which a list of correct labels must be provided, or from unsupervised learning approaches to dimensionality reduction or density estimation, which aim at finding hidden structures in a collection of example data [11]. Moreover, in comparison with other traditional control-based methods, RL does not require a well-represented mathematical model of the environment, but develops a control policy directly from experience to predict states and rewards during a learning procedure. Since the design of RL is letting an agent controller interact with the system, unknown and time-varying dynamics as well as changing performance requirements can be naturally accounted for by the controller [15]. Lastly, RL is uniquely suited to systems with inherent time delays, in which decisions are performed without immediate knowledge of effectiveness, but evaluated by a long-term future reward.


The above features naturally make RL an attractive solution

Aprendizaje Por Refuerzo - Medicina



Aprendizaje Por Refuerzo

Procesamiento de Lenguaje Natural



Aprendizaje Por Refuerzo

Procesamiento de Lenguaje Natural



Aprendizaje Por Refuerzo


Procesamiento de Lenguaje Natural



Aprendizaje Por Refuerzo Vehículos Autónomos




Aprendizaje Por Refuerzo - Sistemas de Energía



Aprendizaje Por Refuerzo


- Marketing (campañas A/B, subastas)
- Gerenciamiento de recursos
- Finanzas
- Gestión de cadenas de suministro (supply chain management)
- Precios dinámicos
- ...

Toma de Decisiones Secuenciales



- Cómo describir el problema matemáticamente?

Toma de Decisiones Secuenciales




- Cómo describir el problema matemáticamente?
- Aprendizaje por refuerzo basado en **Procesos de Decisión Markovianos** (Markov Decision Processes - MDPs)

Procesos Markovianos

- Ejemplo: cómo representar condiciones de mercado?

Procesos Markovianos

- Ejemplo: cómo representar condiciones de mercado?
 - En cada semana, uno de tres posibles estados




Alcista

Bajista

Estable


Procesos Markovianos

- Ejemplo: cómo representar condiciones de mercado?
 - En cada semana, uno de tres posibles estados
 - Cómo evolucionan en el tiempo?




Procesos Markovianos

- Ejemplo: cómo representar condiciones de mercado?
 - En cada semana, uno de tres posibles estados
 - Cómo evolucionan en el tiempo? Descripción en términos de probabilidad




Procesos Markovianos

- Ejemplo: cómo representar condiciones de mercado?
 - En cada semana, uno de tres posibles estados
 - Cómo evolucionan en el tiempo? Descripción en términos de probabilidad




Procesos Markovianos

- Ejemplo: cómo representar condiciones de mercado?
 - En cada semana, uno de tres posibles estados
 - Cómo evolucionan en el tiempo? Descripción en términos de probabilidad
 - En este curso, nos enfocaremos en procesos a tiempo discreto




Procesos Markovianos

- Cómo definir matemáticamente el proceso de regímenes de mercado?



Procesos Markovianos


- Cómo definir matemáticamente el proceso de regímenes de mercado?
- Espacio de estados S
 - $S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$
 - Estados pueden ser discretos o continuos



Procesos Markovianos

- Cómo definir matemáticamente el proceso de regímenes de mercado?
- Espacio de estados S
 - $S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$
 - Estados pueden ser discretos o continuos
- Evolución en el tiempo:


from\to	Alcista	Bajista	Estable
Alcista			
Bajista			
Estable			



Procesos Markovianos

- Cómo definir matemáticamente el proceso de regímenes de mercado?
- Espacio de estados S
 - $S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$
 - Estados pueden ser discretos o continuos
- Evolución en el tiempo:


from\to	Alcista	Bajista	Estable
Alcista	0.9		
Bajista			
Estable			



Procesos Markovianos

- Cómo definir matemáticamente el proceso de regímenes de mercado?
- Espacio de estados S
 - $S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$
 - Estados pueden ser discretos o continuos
- Evolución en el tiempo:


from\to	Alcista	Bajista	Estable
Alcista	0.9	0.075	
Bajista			
Estable			



Procesos Markovianos

- Cómo definir matemáticamente el proceso de regímenes de mercado?
- Espacio de estados S
 - $S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$
 - Estados pueden ser discretos o continuos
- Evolución en el tiempo:


from\to	Alcista	Bajista	Estable
Alcista	0.9	0.075	0.025
Bajista			
Estable			



Procesos Markovianos

- Cómo definir matemáticamente el proceso de regímenes de mercado?
- Espacio de estados S
 - $S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$
 - Estados pueden ser discretos o continuos
- Evolución en el tiempo:


from\to	Alcista	Bajista	Estable
Alcista	0.9	0.075	0.025
Bajista	0.15	0.8	0.05
Estable	0.25	0.25	0.5



Procesos Markovianos

- Cómo definir matemáticamente el proceso de regímenes de mercado?
- Espacio de estados S
 - $S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$
 - Estados pueden ser discretos o continuos
- Evolución en el tiempo:
 - Matriz de transición


from\to	Alcista	Bajista	Estable
Alcista	0.9	0.075	0.025
Bajista	0.15	0.8	0.05
Estable	0.25	0.25	0.5



Procesos Markovianos

- Cómo definir matemáticamente el proceso de regímenes de mercado?
- Espacio de estados $\mathbf{S}$
 - $\mathbf{S} = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$
 - Estados pueden ser discretos o continuos
- Evolución en el tiempo:
 - Matriz de transición $\mathbf{P}$

$$P = \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}$$




Procesos Markovianos

- Cómo definir matemáticamente el proceso de regímenes de mercado?
- Espacio de estados $\mathbf{S}$
 - $\mathbf{S} = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$
 - Estados pueden ser discretos o continuos
- Evolución en el tiempo:
 - Matriz de transición $\mathbf{P}$

$$\mathbf{P} = \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}$$

- Tupla $(\mathbf{S}, \mathbf{P})$ define el proceso markoviano




Procesos Markovianos

- Cómo definir matemáticamente el proceso de regímenes de mercado?
- Espacio de estados S
 - $S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$
 - Estados pueden ser discretos o continuos
- Evolución en el tiempo:
 - Matriz de transición P

$$P = \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}$$

- Tupla (S, P) define el proceso markoviano
 - Si el número de estados es finito, también decimos **cadena markoviana**.



Propiedad de Markov

“El futuro del proceso markoviano depende solamente del estado presente.”

Propiedad de Markov

“El futuro del proceso markoviano depende solamente del estado presente.”

- Proceso de Markov: tupla (S,P)

Propiedad de Markov

“El futuro del proceso markoviano depende solamente del estado presente.”

- Proceso de Markov: tupla (S, P)
- Estados $s_0, s_1, s_2, \dots$ ($s_t \in S$ for $t = 0, 1, 2, \dots$)

Propiedad de Markov

“El futuro del proceso markoviano depende solamente del estado presente.”

- Proceso de Markov: tupla $(\mathbf{S}, \mathbf{P})$
- Estados $\mathbf{s}_0, \mathbf{s}_1, \mathbf{s}_2, \dots$ ($\mathbf{s}_t \in \mathbf{S}$ for $t = 0, 1, 2, \dots$)
- $\text{Prob}(\mathbf{s}_{t+1} | \mathbf{s}_0, \mathbf{s}_1, \dots, \mathbf{s}_t) = \text{Prob}(\mathbf{s}_{t+1} | \mathbf{s}_t)$
 - El estado $\mathbf{s}_t$ contiene toda la información relevante para el futuro del proceso
 - Si conocemos $\mathbf{s}_t$, podemos olvidar $\mathbf{s}_{t-1}, \mathbf{s}_{t-2}, \dots, \mathbf{s}_0$.

Propiedad de Markov

“El futuro del proceso markoviano depende solamente del estado presente.”

- Proceso de Markov: tupla $(\mathbf{S}, \mathbf{P})$
- Estados $\mathbf{s}_0, \mathbf{s}_1, \mathbf{s}_2, \dots$ ($\mathbf{s}_t \in \mathbf{S}$ for $t = 0, 1, 2, \dots$)
- $\text{Prob}(\mathbf{s}_{t+1} | \mathbf{s}_0, \mathbf{s}_1, \dots, \mathbf{s}_t) = \text{Prob}(\mathbf{s}_{t+1} | \mathbf{s}_t)$
 - El estado $\mathbf{s}_t$ contiene toda la información relevante para el futuro del proceso
 - Si conocemos $\mathbf{s}_t$, podemos olvidar $\mathbf{s}_{t-1}, \mathbf{s}_{t-2}, \dots, \mathbf{s}_0$.
 - $\text{Prob}(\mathbf{s}_{t+1} = s | \mathbf{s}_t = s') = \mathbf{P}(s, s')$

Propiedad de Markov

“El futuro del proceso markoviano depende solamente del estado presente.”

- Proceso de Markov: tupla $(\mathbf{S}, \mathbf{P})$
- Estados $\mathbf{s}_0, \mathbf{s}_1, \mathbf{s}_2, \dots$ ($\mathbf{s}_t \in \mathbf{S}$ for $t = 0, 1, 2, \dots$)
- $\text{Prob}(\mathbf{s}_{t+1} | \mathbf{s}_0, \mathbf{s}_1, \dots, \mathbf{s}_t) = \text{Prob}(\mathbf{s}_{t+1} | \mathbf{s}_t)$
 - El estado $\mathbf{s}_t$ contiene toda la información relevante para el futuro del proceso
 - Si conocemos $\mathbf{s}_t$, podemos olvidar $\mathbf{s}_{t-1}, \mathbf{s}_{t-2}, \dots, \mathbf{s}_0$.
 - $\text{Prob}(\mathbf{s}_{t+1} = s | \mathbf{s}_t = s') = \mathbf{P}(s, s')$
 - E.g. $\text{Prob}(\mathbf{s}_{t+1} = \text{Bajista} | \mathbf{s}_t = \text{Alcista}) = P(\text{Alcista}, \text{Bajista}) = 0.075$


Propiedad de Markov

Cuál es la probabilidad de tener un mercado bajista en la próxima semana después de haber tenido un mercado alcista en las últimas 5 semanas?

Cuál es la probabilidad de tener un mercado bajista en la próxima semana después de haber tenido un mercado alcista en la última semana, y bajista en las 4 anteriores?

$S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$

$$P = \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}$$




Propiedad de Markov

Cuál es la probabilidad de tener un mercado bajista en la próxima semana **después de haber tenido un mercado alcista en las últimas 5 semanas?**

Cuál es la probabilidad de tener un mercado bajista en la próxima semana **después de haber tenido un mercado alcista en la última semana, y bajista en las 4 anteriores?**

$S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$

$$P = \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}$$




Propiedad de Markov

Cuál es la probabilidad de tener un mercado bajista en la próxima semana **después de haber tenido un mercado alcista en las últimas 5 semanas?**

Cuál es la probabilidad de tener un mercado bajista en la próxima semana **después de haber tenido un mercado alcista en la última semana, y bajista en las 4 anteriores?**

$S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$

$$P = \begin{bmatrix} 0.9 & \boxed{0.075} & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}$$




Distribución Probabilística de Estados

Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? En 10 semanas?

$S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$

$$P = \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}$$



Distribución Probabilística de Estados

Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? En 10 semanas?

Vamos a representar una distribución probabilística de estados con la variable π_t :

$$\pi_t(s) = \text{Prob}(\mathbf{s}_t = s)$$

Distribución Probabilística de Estados

Si **esta semana el mercado es bajista**, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? En 10 semanas?

Vamos a representar una distribución probabilística de estados con la variable π_t :

$$\pi_t(s) = \text{Prob}(\mathbf{s}_t = s)$$

En nuestro ejemplo, si consideramos que esta semana corresponde a $t = 0$:

$$\text{Prob}(\mathbf{s}_0 = \text{Altista}) = 0, \text{Prob}(\mathbf{s}_0 = \text{Bajista}) = 1, \text{Prob}(\mathbf{s}_0 = \text{Estable}) = 0$$

Distribución Probabilística de Estados


Si **esta semana el mercado es bajista**, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? En 10 semanas?

Vamos a representar una distribución probabilística de estados con la variable π_t :

$$\pi_t(s) = \text{Prob}(\mathbf{s}_t = s)$$

En nuestro ejemplo, si consideramos que esta semana corresponde a $t = 0$:

$$\text{Prob}(\mathbf{s}_0 = \text{Altista}) = 0, \text{Prob}(\mathbf{s}_0 = \text{Bajista}) = 1, \text{Prob}(\mathbf{s}_0 = \text{Estable}) = 0$$

$$\pi_0 = [0 \quad 1 \quad 0]$$


Distribución Probabilística de Estados


Si **esta semana el mercado es bajista**, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? En 10 semanas?

Vamos a representar una distribución probabilística de estados con la variable π_t :

$$\pi_t(s) = \text{Prob}(\mathbf{s}_t = s)$$

En nuestro ejemplo, si consideramos que esta semana corresponde a $t = 0$:

$$\text{Prob}(\mathbf{s}_0 = \text{Altista}) = 0, \text{Prob}(\mathbf{s}_0 = \text{Bajista}) = 1, \text{Prob}(\mathbf{s}_0 = \text{Estable}) = 0$$

$$\pi_0 = [0 \quad 1 \quad 0]$$



π_0 es la distribución inicial de estados en el proceso markoviano.

Distribución Probabilística de Estados

Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? En 10 semanas?

$S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$

$$P = \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}$$




Distribución Probabilística de Estados

Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? En 10 semanas?

La probabilidad de que sea bajista en la próxima semana es 0.8

$S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$

$$P = \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & \boxed{0.8} & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}$$




Distribución Probabilística de Estados

Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? **En 2 semanas?** En 10 semanas?

$S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$

$$P = \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}$$



Distribución Probabilística de Estados


Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? **En 2 semanas?** En 10 semanas?

Podemos enumerar las posibilidades y sumarlas...

$$\text{Prob}(\text{Alcista}, \text{Bajista}) + \text{Prob}(\text{Bajista}, \text{Bajista}) + \text{Prob}(\text{Estable}, \text{Bajista})$$

$S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$

$$P = \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}$$



Distribución Probabilística de Estados


Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? **En 2 semanas?** En 10 semanas?

Podemos enumerar las posibilidades y sumarlas...

$$\begin{aligned} & \text{Prob(Alcista, Bajista)} + \text{Prob(Bajista, Bajista)} + \text{Prob(Estable, Bajista)} \\ &= 0.15 * 0.075 + 0.8 * 0.8 + 0.05 * 0.25 \\ &= \mathbf{0.66375} \end{aligned}$$

$S = \{\text{Alcista, Bajista, Estable}\}$

$$P = \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}$$



Distribución Probabilística de Estados

Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? En 10 semanas?

Se puede responder a esas preguntas más fácilmente con álgebra lineal!

Distribución Probabilística de Estados

Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? En 10 semanas?

Se puede responder a esas preguntas más fácilmente con álgebra linear!

Recordemos que $\pi_t(s) = \text{Prob}(\mathbf{s}_t = s)$. Resulta que $\pi_{t+1} = \pi_t \times P$ y $\pi_t = \pi_0 \times P^t$

Distribución Probabilística de Estados

Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? En 10 semanas?

Se puede responder a esas preguntas más fácilmente con álgebra lineal!

Recordemos que $\pi_t(s) = \text{Prob}(\mathbf{s}_t = s)$. Resulta que $\pi_{t+1} = \pi_t \times \mathbf{P}$ y $\pi_t = \pi_0 \times \mathbf{P}^t$

Entonces:

$$\pi_1 = [0 \quad 1 \quad 0] \times \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}^1 = [0.15 \quad 0.8 \quad 0.05]$$

$$\text{Prob}(\mathbf{s}_1 = \text{Bajista} \mid \mathbf{s}_0 = \text{Bajista}) = 0.8$$

Distribución Probabilística de Estados

Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? **En 2 semanas?** En 10 semanas?

Se puede responder más fácilmente con álgebra linear!

Recordemos que $\pi_t(s) = \text{Prob}(\mathbf{s}_t = s)$. Resulta que $\pi_{t+1} = \pi_t \times P$ y $\pi_t = \pi_0 \times P^t$

Entonces (Python):

$$\pi_2 = [0 \quad 1 \quad 0] \times \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}^2 = [0.2675 \quad 0.66375 \quad 0.06875]$$

$$\text{Prob}(\mathbf{s}_2 = \text{Bajista} \mid \mathbf{s}_0 = \text{Bajista}) = 0.66375$$

Distribución Probabilística de Estados

Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? **En 10 semanas?**

Se puede responder más fácilmente con álgebra lineal!

Recordemos que $\pi_t(s) = \text{Prob}(\mathbf{s}_t = s)$. Resulta que $\pi_{t+1} = \pi_t \times \mathbf{P}$ y $\pi_t = \pi_0 \times \mathbf{P}^t$

Entonces (Python):

$$\pi_{10} = [0 \quad 1 \quad 0] \times \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}^{10} = [0.59159 \quad 0.34310 \quad 0.06532]$$

$$\text{Prob}(\mathbf{s}_{10} = \text{Bajista} \mid \mathbf{s}_0 = \text{Bajista}) = 0.34310$$

Distribución Estacionaria de Estados

Cuál es la frecuencia de semanas alcistas, bajistas y estables en ese mercado?

Distribución estacionaria: $\pi_{t+1} = \pi_t \times P$, pero estacionariedad implica $\pi_{t+1} = \pi_t = \pi$.

Distribución Estacionaria de Estados

Cuál es la frecuencia de semanas alcistas, bajistas y estables en ese mercado?

Distribución estacionaria: $\pi = \pi \times P$

Distribución Estacionaria de Estados

Cuál es la frecuencia de semanas alcistas, bajistas y estables en ese mercado?

Distribución estacionaria: $\pi = \pi \times P$

Si el número de estados es finito, siempre existe una solución, pero no es necesariamente única.

Distribución Estacionaria de Estados

Cuál es la frecuencia de semanas alcistas, bajistas y estables en ese mercado?

Distribución estacionaria: $\pi = \pi \times P$

Si el número de estados es finito, siempre existe una solución, pero no es necesariamente única.

Resolvemos este ejemplo con Python...

Distribución Estacionaria de Estados

Cuál es la frecuencia de semanas alcistas, bajistas y estables en ese mercado?

Distribución estacionaria: $\pi = \pi \times P$

Si el número de estados es finito, siempre existe una solución, pero no es necesariamente única.

$$\pi = [0 \quad 1 \quad 0] \times \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}^{\infty} = [0.625 \quad 0.3125 \quad 0.0625]$$

Distribución Estacionaria de Estados

Cuál es la frecuencia de semanas alcistas, bajistas y estables en ese mercado?

Distribución estacionaria: $\pi = \pi \times P$

Si el número de estados es finito, siempre existe una solución, pero no es necesariamente única.

$$\pi = [0 \quad 1 \quad 0] \times \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}^{\infty} = [0.625 \quad 0.3125 \quad 0.0625]$$

En ese mercado, 62.5% de las semanas son alcistas, 31.25% son bajistas, y 6.25% son estables.

Ejemplo: Google PageRank


Cuando hacemos una búsqueda en Google, las páginas que satisfacen a nuestras condiciones son presentadas en orden de importancia.

Cómo determinar importancia/ranking?

Ejemplo: Google PageRank

Cuando hacemos una búsqueda en Google, las páginas que satisfacen a nuestras condiciones son presentadas en orden de importancia.



Cómo determinar importancia/ranking?



Ejemplo: Google PageRank

Cuando hacemos una búsqueda en Google, las páginas que satisfacen a nuestras condiciones son presentadas en orden de importancia.



Cómo determinar importancia/ranking?



Ejemplo: Google PageRank

Cuando hacemos una búsqueda en Google, las páginas que satisfacen a nuestras condiciones son presentadas en orden de importancia.

Cómo determinar importancia/ranking? Ranking = distribución estacionaria!




Ejemplo: Participación en El Mercado

- Cadenas markovianas son frecuentemente utilizadas para modelar el comportamiento de consumidores de marcas adversarias y predecir la participación en el mercado de esas marcas al largo del tiempo.


Ejemplo: Participación en El Mercado

- Cadenas markovianas son frecuentemente utilizadas para modelar el comportamiento de consumidores de marcas adversarias y predecir la participación en el mercado de esas marcas al largo del tiempo.




Ejemplo: Participación en El Mercado

- Cadenas markovianas son frecuentemente utilizadas para modelar el comportamiento de consumidores de marcas adversarias y predecir la participación en el mercado de esas marcas a largo del tiempo.
- p_{ij} = probabilidad que consumidor de marca i se pase a marca j



Ejemplo: Participación en El Mercado

- Cadenas markovianas son frecuentemente utilizadas para modelar el comportamiento de usuarios de proveedores adversarios y predecir la participación en el mercado de esas marcas al largo del tiempo.
- p_{ij} = probabilidad que usuario de proveedor i se pase a proveedor j



Ejemplo: Participación en El Mercado

Table 4: Respondents Brand Switching Behaviour

Gains and Losses	Mobile Telecom Operators						Total
	<i>M</i>	<i>V</i>	<i>T</i>	<i>E</i>	<i>A</i>	<i>G</i>	
<i>M</i>	290	38	24	2	36	15	405
<i>V</i>	80	91	22	4	32	6	235
<i>T</i>	83	17	101	4	21	11	237
<i>E</i>	9	6	11	4	0	0	30
<i>A</i>	72	22	21	2	87	5	209
<i>G</i>	38	9	13	1	21	32	114

Source: Author's Computation (2013)

“Prediction of Subscribers’ Brand Switching Behaviour and Ergodic Market Share of Network Service Providers in Ghana Using Markov Chain Model”, Ezekiel Nortey

Ejemplo: Participación en El Mercado

Table 4: Respondents Brand Switching Behaviour

Gains and Losses	Mobile Telecom Operators						Total
	<i>M</i>	<i>V</i>	<i>T</i>	<i>E</i>	<i>A</i>	<i>G</i>	
<i>M</i>	290	38	24	2	36	15	405
<i>V</i>	80	91	22	4	32	6	235
<i>T</i>	83	17	101	4	21	11	237
<i>E</i>	9	6	11	4	0	0	30
<i>A</i>	72	22	21	2	87	5	209
<i>G</i>	38	9	13	1	21	32	114

Source: Author's Computation (2013)

Current market share derived from totals = $[405 \ 235 \ 237 \ 30 \ 209 \ 114]/1230$
= $[0.33, 0.19, 0.19, 0.02, 0.17, 0.09]$

Ejemplo: Participación en El Mercado

Table 4: Respondents Brand Switching Behaviour

Gains and Losses	Mobile Telecom Operators						Total
	<i>M</i>	<i>V</i>	<i>T</i>	<i>E</i>	<i>A</i>	<i>G</i>	
<i>M</i>	290	38	24	2	36	15	405
<i>V</i>	80	91	22	4	32	6	235
<i>T</i>	83	17	101	4	21	11	237
<i>E</i>	9	6	11	4	0	0	30
<i>A</i>	72	22	21	2	87	5	209
<i>G</i>	38	9	13	1	21	32	114

Source: Author's Computation (2013)

Transition probability P derived similarly, e.g. $P(M,V) = 38/405 = 0.094$

Ejemplo: Participación en El Mercado

$$\pi_0 = [0.33, 0.19, 0.19, 0.02, 0.17, 0.09]$$

Ejemplo: Participación en El Mercado

$$\pi_0 = [0.33, 0.19, 0.19, 0.02, 0.17, 0.09]$$

$$P = \begin{bmatrix} 0.716 & 0.094 & 0.059 & 0.005 & 0.089 & 0.037 \\ 0.34 & 0.387 & 0.094 & 0.017 & 0.136 & 0.026 \\ 0.35 & 0.072 & 0.426 & 0.017 & 0.089 & 0.046 \\ 0.3 & 0.2 & 0.367 & 0.133 & 0.0 & 0.0 \\ 0.344 & 0.105 & 0.1 & 0.01 & 0.416 & 0.024 \\ 0.333 & 0.079 & 0.114 & 0.009 & 0.184 & 0.281 \end{bmatrix}$$

Ejemplo: Participación en El Mercado

$$\pi_0 = [0.33, 0.19, 0.19, 0.02, 0.17, 0.09]$$

$$P = \begin{bmatrix} 0.716 & 0.094 & 0.059 & 0.005 & 0.089 & 0.037 \\ 0.34 & 0.387 & 0.094 & 0.017 & 0.136 & 0.026 \\ 0.35 & 0.072 & 0.426 & 0.017 & 0.089 & 0.046 \\ 0.3 & 0.2 & 0.367 & 0.133 & 0.0 & 0.0 \\ 0.344 & 0.105 & 0.1 & 0.01 & 0.416 & 0.024 \\ 0.333 & 0.079 & 0.114 & 0.009 & 0.184 & 0.281 \end{bmatrix}$$

Recordando que $\pi_t = \pi_0 \times P^t$, perform Markov chain analysis on Python.

Ejemplo: Participación en El Mercado

