

Procesos de Decisión Markovianos

Clase 2

- Procesos markovianos con recompensa
 - Resolución por recursión
 - La función valor
- Procesos de decisión markovianos
 - Espacio de acciones
 - Políticas de decisión
 - Algoritmo de programación dinámica
- Aplicación: Precificación dinámica

Proceso Markoviano con Recompensa


- Proceso markoviano: tupla $(\mathcal{S}, \mathcal{P})$

Proceso Markoviano con Recompensa

- Proceso markoviano: tupla $(\mathbf{S}, \mathbf{P})$
- Con recompensa: tupla $(\mathbf{S}, \mathbf{P}, r)$
 - $r(\mathbf{x})$ = recompensa (o costo) de estar en el estado $\mathbf{x}$

Proceso Markoviano con Recompensa


- Proceso markoviano: tupla (S, P)
- Con recompensa: tupla (S, P, r)
 - $r(x)$ = recompensa (o costo) de estar en el estado x
- Ejemplo: regímenes de mercado
 - Ganancia (o pérdida) dependiendo del estado



Proceso Markoviano con Recompensa

- Proceso markoviano: tupla (S, P)
- Con recompensa: tupla (S, P, r)
 - $r(x)$ = recompensa (o costo) de estar en el estado x


- Ejemplo: regímenes de mercado
 - Ganancia (o pérdida) dependiendo del estado
 - Interpretación: Inversión de \$1 resulta en $\$(1+r(x))$



Proceso Markoviano con Recompensa

- Proceso markoviano: tupla (S, P)
- Con recompensa: tupla (S, P, r)
 - $r(x)$ = recompensa (o costo) de estar en el estado x


- Ejemplo: regímenes de mercado
 - Ganancia (o pérdida) dependiendo del estado
 - Interpretación: Inversión de \$1 resulta en $\$(1+r(x))$
 - $r(\text{alcista}) = 0.005$, $r(\text{bajista}) = -0.005$, $r(\text{estable}) = 0$



Proceso Markoviano con Recompensa


- Proceso markoviano: tupla (S, P)
- Con recompensa: tupla (S, P, r)
 - $r(x)$ = recompensa (o costo) de estar en el estado x

- Ejemplo: regímenes de mercado
 - Ganancia (o pérdida) dependiendo del estado
 - Interpretación: Inversión de \$1 resulta en $\$(1+r(x))$
 - $r(\text{alcista}) = 0.005$, $r(\text{bajista}) = -0.005$, $r(\text{estable}) = 0$
 - **Invirtiendo \$1 hoy, cuánta plata habrá después de 3 semanas?**



Proceso Markoviano con Recompensa

- Invirtiendo \$1 hoy, cuánta plata habrá después de 3 semanas?



Proceso Markoviano con Recompensa

- **Invirtiendo \$1 hoy, cuánto plata habrá después de 3 semanas?**
- Consideramos una secuencia de estados x_0, x_1, x_2
 - E.g. x_0 ,= alcista, x_1 ,= alcista, x_2 ,=bajista

Proceso Markoviano con Recompensa

- **Invirtiendo \$1 hoy, cuánto plata habrá después de 3 semanas?**
- Consideramos una secuencia de estados x_0, x_1, x_2, x_3
 - E.g. $x_0 = \text{alcista}$, $x_1 = \text{alcista}$, $x_2 = \text{bajista}$
 - Después de 3 semanas, tenemos

$$(1+r(\text{alcista}))(1+r(\text{alcista}))(1+r(\text{bajista}))$$

Proceso Markoviano con Recompensa

- **Invirtiendo \$1 hoy, cuánta plata habrá después de 3 semanas?**
- Consideramos una secuencia de estados x_0, x_1, x_2
 - Generalizando:

$$(1+r(x_0))(1+r(x_1))(1+r(x_2))$$

Proceso Markoviano con Recompensa

- **Invirtiendo \$1 hoy, cuánto plata habrá después de 3 semanas?**
- Consideramos una secuencia de estados x_0, x_1, x_2
 - Generalizando:
 - En $t = 0$, no sabemos cuáles serán los próximos estados x_1, x_2 .
Utilizamos el valor esperado:

$$E[(1+r(x_0))(1+r(x_1))(1+r(x_2)) \mid x_0]$$

Proceso Markoviano con Recompensa

- **Invirtiendo \$1 hoy, cuánto plata habrá después de 3 semanas?**
- Consideramos una secuencia de estados x_0, x_1, x_2, x_3
 - Generalizando:
 - En $t = 0$, no sabemos cuáles serán los próximos estados x_1, x_2 .
Utilizamos el valor esperado:

$$V_0(x_0) = E[(1+r(x_0))(1+r(x_1))(1+r(x_2)) \mid x_0]$$

Proceso Markoviano con Recompensa

- **Invirtiendo \$1 hoy, cuánto plata habrá después de 3 semanas?**
- Consideramos una secuencia de estados x_0, x_1, x_2, x_3
 - Generalizando:
 - En $t = 0$, no sabemos cuáles serán los próximos estados x_1, x_2 . Utilizamos el valor esperado:

$$V_0(x_0) = E[(1+r(x_0))(1+r(x_1))(1+r(x_2)) \mid x_0]$$

- $V_0(x_0)$ representa el valor de estar en el estado x_0 en $t = 0$

Proceso Markoviano con Recompensa

- **Invirtiendo \$1 hoy, cuánto plata habrá después de 3 semanas?**
- Consideramos una secuencia de estados x_0, x_1, x_2, x_3
 - Generalizando:
 - En $t = 0$, no sabemos cuáles serán los próximos estados x_1, x_2 . Utilizamos el valor esperado:

$$V_0(x) = E[(1+r(x_0))(1+r(x_1))(1+r(x_2)) \mid x_0 = x]$$

- $V_0(x)$ denote el valor de estar en el estado x en $t = 0$
- Cómo calcular $V_0(x)$?

Calculando $V_0(x)$

$$V_0(x) = E[(1+r(x_0))(1+r(x_1))(1+r(x_2)) \mid x_0 = x]$$

Calculando $V_0(x)$

$$V_0(x) = E[(1+r(x_0))(1+r(x_1))(1+r(x_2)) \mid x_0 = x]$$

$$= 1 + E[r(x_0) + r(x_1) + r(x_2) + r(x_0)r(x_1) + r(x_0)r(x_2) + r(x_1)r(x_2) + r(x_0)r(x_1)r(x_2))]$$

Calculando $V_0(x)$

$$\begin{aligned} V_0(x) &= E[(1+r(x_0))(1+r(x_1))(1+r(x_2)) \mid x_0 = x] \\ &= 1 + E[r(x_0) + r(x_1) + r(x_2) + \underbrace{r(x_0)r(x_1) + r(x_0)r(x_2) + r(x_1)r(x_2) + r(x_0)r(x_1)r(x_2))}_{\approx 0}] \end{aligned}$$

Como r es pequeño, los productos $r(x)r(y)$ son mucho menores que $r(x)$, así que vamos a simplificar:

$$V_0(x) \approx 1 + E[r(x_0) + r(x_1) + r(x_2) \mid x_0 = x]$$

Calculando $V_0(x)$

$$\begin{aligned} V_0(x) &= E[(1+r(x_0))(1+r(x_1))(1+r(x_2)) \mid x_0 = x] \\ &= 1 + E[r(x_0) + r(x_1) + r(x_2) + \underbrace{r(x_0)r(x_1) + r(x_0)r(x_2) + r(x_1)r(x_2) + r(x_0)r(x_1)r(x_2))}_{\approx 0}] \end{aligned}$$

Como r es pequeño, los productos $r(x)r(y)$ son mucho menores que $r(x)$, así que vamos a simplificar la expresión:

$$V_0(x) \approx 1 + E[r(x_0) + r(x_1) + r(x_2) \mid x_0 = x]$$

Calculando $V_0(x)$

$$\begin{aligned} V_0(x) &= E[(1+r(x_0))(1+r(x_1))(1+r(x_2)) \mid x_0 = x] \\ &= 1 + E[r(x_0) + r(x_1) + r(x_2) + \underbrace{r(x_0)r(x_1) + r(x_0)r(x_2) + r(x_1)r(x_2) + r(x_0)r(x_1)r(x_2))}_{\approx 0}] \end{aligned}$$


Como r es pequeño, los productos $r(x)r(y)$ son mucho menores que $r(x)$, así que vamos a simplificar la expresión:

$$V_0(x) \approx 1 + E[r(x_0) + r(x_1) + r(x_2) \mid x_0 = x]$$

Vamos a derivar un algoritmo para calcular el valor esperado. También es posible trabajar con la expresión multiplicativa, pero la suma es más comúnmente utilizada.


Calculando $V_0(x)$

- Vamos a representar el proceso con un nuevo grafo, mostrando su evolución semana a semana.





Calculando $V_0(x)$

- Vamos a representar el proceso con un nuevo grafo, desplegando su evolución semana a semana.




Calculando $V_0(x)$

- Vamos a representar el proceso con un nuevo grafo, desplegando su evolución semana a semana.




Calculando $V_0(x)$




Calculando $V_0(x)$

- Idea: resolver una serie de problemas más fáciles, hasta llegar a la respuesta original.




Calculando $V_0(x)$

- Idea: resolver una serie de problemas más fáciles, hasta llegar a la respuesta original.
 - 1) Calculamos $V_2(x)$.




Calculando $V_0(x)$

- Idea: resolver una serie de problemas más fáciles, hasta llegar a la respuesta original.
 - 1) Calculamos $V_2(x)$.




Calculando $V_0(x)$

- Idea: resolver una serie de problemas más fáciles, hasta llegar a la respuesta original.
 - 1) Calculamos $V_2(x)$.
 - 2) Retrocedemos una semana y calculamos $V_1(x)$.




Calculando $V_1(x)$




Calculando $V_1(x)$

$$\begin{aligned} V_1(\text{alcista}) &= r(\text{alcista}) + P(\text{alcista}, \text{alcista})V_2(\text{alcista}) + P(\text{alcista}, \text{bajista})V_2(\text{bajista}) + P(\text{alcista}, \text{estable})V_2(\text{estable}) \\ &= 0.005 + 0.9 \cdot 0.005 + 0.075 \cdot (-0.005) + 0.025 \cdot 0 \\ &= 0.009125 \end{aligned}$$



Calculando $V_1(x)$


$$\begin{aligned} V_1(\text{alcista}) &= r(\text{alcista}) + P(\text{alcista}, \text{alcista})V_2(\text{alcista}) + P(\text{alcista}, \text{bajista})V_2(\text{bajista}) + P(\text{alcista}, \text{estable})V_2(\text{estable}) \\ &= 0.005 + 0.9 \cdot 0.005 + 0.075 \cdot (-0.005) + 0.025 \cdot 0 \\ &= 0.009125 \end{aligned}$$



Calculando $V_1(x)$

Repetimos el mismo proceso con $x = \text{bajista}$ y $x = \text{estable}$:

$$V_1(x) = r(x) + \sum_y P(x,y)V_2(y)$$




Calculando $V_0(x)$

- Idea: resolver una serie de problemas más fáciles, hasta llegar a la respuesta original.

1) Calculamos $V_2(x)$.

2) Retrocedemos una semana y calculamos $V_1(x)$.

3) Retrocedemos otra semana y calculamos $V_0(x) = r(x) + \sum_y P(x,y)V_1(y)$



Calculando $V_0(x)$

- Idea: resolver una serie de problemas más fáciles, hasta llegar a la respuesta original.

1) Calculamos $V_2(x)$.

2) Retrocedemos una semana y calculamos $V_1(x)$.

3) Retrocedemos otra semana y calculamos $V_0(x) = r(x) + \sum_y P(x,y)V_1(y)$

$t = 0$	$V_0(x)$	$t = 1$	$V_1(x)$	$t = 2$	$V_2(x)$
	0.01259375		0.009125		0.005
	-0.01023125		-0.00825		-0.005
	0.00021875		0		0

Calculando $V_0(x)$

Invirtiendo \$1 at $t = 0$, si la semana actual es alcista se espera tener **\$1.01259375** después de 3 semanas.

$t = 0$	$V_0(x)$	$t = 1$	$V_1(x)$	$t = 2$	$V_2(x)$
Alcista 0.005	0.01259375	Alcista 0.005	0.009125	Alcista 0.005	0.005
Bajista -0.005	-0.01023125	Bajista -0.005	-0.00825	Bajista -0.005	-0.005
Estable 0	0.00021875	Estable 0	0	Estable 0	0

Función Valor

- Proceso markoviano definido por la tupla $(\mathbf{S}, \mathbf{P}, r)$
- Distintas maneras de combinar $r(x_t)$ en un único criterio (suma, multiplicación, medidas de riesgo)
- Una de las definiciones más comúnmente utilizadas es la recompensa total:

$$V_t(x) = \mathbb{E} \left[\sum_{\tau=t}^T r(x_\tau) | x_t = x \right]$$

Función Valor con Factor de Descuento

- Se puede expandir la definición introduciendo un factor de descuento $0 \leq \alpha \leq 1$:

$$V_t(x) = \mathbb{E} \left[\sum_{\tau=t}^T \alpha^{\tau-t} r(x_{\tau}) | x_t = x \right]$$

Función Valor con Factor de Descuento

- Se puede expandir la definición introduciendo un factor de descuento $0 \leq \alpha \leq 1$:

$$V_t(x) = \mathbb{E} \left[\sum_{\tau=t}^T \alpha^{\tau-t} r(x_{\tau}) | x_t = x \right]$$

- interpretación económica (\$1 vale más en el presente que en el futuro)
- menos confianza en lo que pasará en el futuro distante que cercano

Función Valor con Factor de Descuento

- Se puede expandir la definición introduciendo un factor de descuento $0 \leq \alpha \leq 1$:

$$V_t(x) = \mathbb{E} \left[\sum_{\tau=t}^T \alpha^{\tau-t} r(x_\tau) | x_t = x \right]$$

- interpretación económica (\$1 vale más en el presente que en el futuro)
- menos confianza en lo que pasará en el futuro distante que cercano
- $\alpha = 0$ implica que el criterio de valoración es miope
- $\alpha = 1$ es el caso sin descuento

Programación Dinámica

- Definimos $V_t(x)$ recursivamente:

$$\begin{aligned} V_t(x) &= r(x) + \alpha \mathbb{E} [V_{t+1}(x_{t+1}) | x_t = x] \\ &= r(x) + \alpha \sum_{y \in S} P(x, y) V_{t+1}(y) \\ V_T(x) &= r(x) \end{aligned}$$

Programación Dinámica

- Definimos $V_t(x)$ recursivamente:

$$\begin{aligned}V_t(x) &= r(x) + \alpha \mathbb{E}[V_{t+1}(x_{t+1}) | x_t = x] \\&= r(x) + \alpha \sum_{y \in S} P(x, y) V_{t+1}(y) \\V_T(x) &= r(x)\end{aligned}$$

- Usando matrices:

$$\begin{aligned}V_t &= r + \alpha P V_{t+1} \\V_T &= r\end{aligned}$$

donde $r \in \mathbb{R}^{|S|}$, $V_t \in \mathbb{R}^{|S|}$, $P \in \mathbb{R}^{|S| \times |S|}$.

- Podemos implementar el algoritmo en Python.

Observaciones

- Asumimos que $\mathbf{r}$ y $\mathbf{P}$ no dependen de t , i.e., el proceso markoviano es homogéneo en el tiempo. Pero se puede extender el resultado al caso en que dependen de t :

$$\begin{aligned}V_t &= r_t + \alpha P_t V_{t+1} \\ V_T &= r_T\end{aligned}$$

Observaciones

- Asumimos que $\mathbf{r}$ y $\mathbf{P}$ no dependen de t , i.e., el proceso markoviano es homogéneo en el tiempo. Pero se puede extender el resultado al caso en que dependen de t :

$$\begin{aligned}V_t &= r_t + \alpha P_t V_{t+1} \\ V_T &= r_T\end{aligned}$$

- También asumimos que la recompensa es determinística, pero podemos incorporar casos en que es aleatoria:

$$\bar{r}(x) = \mathbb{E}_w[r(x, w)]$$

Observaciones

- Asumimos que $\mathbf{r}$ y $\mathbf{P}$ no dependen de t , i.e., el proceso markoviano es homogéneo en el tiempo. Pero se puede extender el resultado al caso en que dependen de t :

$$\begin{aligned}V_t &= r_t + \alpha P_t V_{t+1} \\ V_T &= r_T\end{aligned}$$


- También asumimos que la recompensa es determinística, pero podemos incorporar casos en que es aleatoria:

$$\bar{r}(x) = \mathbb{E}_w[r(x, w)]$$

- Si la recompensa depende del próximo estado además del actual, también se puede incorporar utilizando:


$$\bar{r}(x) = \sum_y P(x, y) r(x, y) = \mathbb{E}[r(x, x_{t+1}) | x_t = x]$$

Procesos de Decisión Markovianos



- Hasta ahora, consideramos procesos markovianos $(\mathbf{S}, \mathbf{P}, r)$
- Ahora agregaremos decisiones:
 - Espacio de Estados $\mathbf{S}$
 - Espacio de Acciones $\mathbf{A}$
 - Recompensa $r_a(x)$
 - Probabilidad de transición $P_a(x, y)$

Procesos de Decisión Markovianos



- Hasta ahora, consideramos procesos markovianos $(\mathbf{S}, \mathbf{P}, r)$
- Ahora agregaremos decisiones:
 - Espacio de Estados $\mathbf{S}$
 - Espacio de Acciones $\mathbf{A}$
 - Recompensa $r_a(x)$
 - Probabilidad de transición $P_a(x, y)$
- Proceso de Decisión Markoviano caracterizado por la tupla $(\mathbf{S}, \mathbf{A}, \mathbf{P}, r)$

Ejemplo: Precios Dinámicos

Un vuelo parte en 150 días y tiene capacidad para 100 pasajeros. Un posible pasajero llega por día y acepta pagar un precio máximo m por el vuelo. Ese precio es distribuido con probabilidades $\text{Prob}(m = 50) = \frac{1}{2}$, $\text{Prob}(m = 70) = \frac{1}{3}$, $\text{Prob}(m = 120) = \frac{1}{6}$.


Qué precio la aerolínea debe ofrecer a cada día para maximizar su ganancia?

Ejemplo: Precios Dinámicos - Modelo MDP - (S, A, P, r)

Un vuelo parte el 150 días y tiene capacidad para 100 pasajeros. Un posible pasajero llega por día y acepta pagar un precio máximo m por el vuelo. Ese precio es distribuido con probabilidades $\text{Prob}(m = 50) = \frac{1}{2}$, $\text{Prob}(m = 70) = \frac{1}{3}$, $\text{Prob}(m = 120) = \frac{1}{6}$.


Ejemplo: Precios Dinámicos - Modelo MDP - (S, A, P, r)

Un vuelo parte el 150 días y tiene capacidad para 100 pasajeros. Un posible pasajero llega por día y acepta pagar un precio máximo m por el vuelo. Ese precio es distribuido con probabilidades $\text{Prob}(m = 50) = \frac{1}{2}$, $\text{Prob}(m = 70) = \frac{1}{3}$, $\text{Prob}(m = 120) = \frac{1}{6}$.



Ejemplo: Precios Dinámicos - Modelo MDP - $(\mathbf{S}, \mathbf{A}, \mathbf{P}, r)$


Un vuelo parte el 150 días y tiene capacidad para 100 pasajeros. Un posible pasajero llega por día y acepta pagar un precio máximo m por el vuelo. Ese precio es distribuido con probabilidades $\text{Prob}(m = 50) = \frac{1}{2}$, $\text{Prob}(m = 70) = \frac{1}{3}$, $\text{Prob}(m = 120) = \frac{1}{6}$.



$$\mathbf{S} = \{0, 1, \dots, 100\}$$

Ejemplo: Precios Dinámicos - Modelo MDP - $(\mathbf{S}, \mathbf{A}, \mathbf{P}, r)$

Un vuelo parte el 150 días y tiene capacidad para 100 pasajeros. Un posible pasajero llega por día y acepta pagar un precio máximo m por el vuelo. Ese precio es distribuido con probabilidades $\text{Prob}(m = 50) = \frac{1}{2}$, $\text{Prob}(m = 70) = \frac{1}{3}$, $\text{Prob}(m = 120) = \frac{1}{6}$.




$$\mathbf{S} = \{0, 1, \dots, 100\}$$

$$\mathbf{A} = \{50, 70, 120\}$$

Ejemplo: Precios Dinámicos - Modelo MDP - $(\mathbf{S}, \mathbf{A}, \mathbf{P}, r)$

Un vuelo parte el 150 días y tiene capacidad para 100 pasajeros. Un posible pasajero llega por día y acepta pagar un precio máximo m por el vuelo. Ese precio es distribuido con probabilidades $\text{Prob}(m = 50) = \frac{1}{2}$, $\text{Prob}(m = 70) = \frac{1}{3}$, $\text{Prob}(m = 120) = \frac{1}{6}$.




$$\mathbf{S} = \{0, 1, \dots, 100\}$$
$$\mathbf{A} = \{50, 70, 120\}$$

- $P_a(100, 100) = 1$ (no hay cancelaciones)

Ejemplo: Precios Dinámicos - Modelo MDP - (S, A, P, r)

Un vuelo parte el 150 días y tiene capacidad para 100 pasajeros. Un posible pasajero llega por día y acepta pagar un precio máximo m por el vuelo. Ese precio es distribuido con probabilidades $\text{Prob}(m = 50) = \frac{1}{2}$, $\text{Prob}(m = 70) = \frac{1}{3}$, $\text{Prob}(m = 120) = \frac{1}{6}$.




$$S = \{0, 1, \dots, 100\}$$
$$A = \{50, 70, 120\}$$

- $P_a(100, 100) = 1$ (no hay cancelaciones)
- Para $x < 100$:
 - $P_a(x, x+1) = \text{Prob}(a \leq m) = p_a$
 - $P_a(x, x) = 1-p_a$
 - $P_a(x, y) = 0$ para $y \notin \{x, x+1\}$

Ejemplo: Precios Dinámicos - Modelo MDP - (S, A, P, r)

Un vuelo parte el 150 días y tiene capacidad para 100 pasajeros. Un posible pasajero llega por día y acepta pagar un precio máximo m por el vuelo. Ese precio es distribuido con probabilidades $\text{Prob}(m = 50) = \frac{1}{2}$, $\text{Prob}(m = 70) = \frac{1}{3}$, $\text{Prob}(m = 120) = \frac{1}{6}$.




$$S = \{0, 1, \dots, 100\}$$
$$A = \{50, 70, 120\}$$

- $P_a(100, 100) = 1$ (no hay cancelaciones)
- Para $x < 100$:
 - $P_a(x, x+1) = \text{Prob}(a \leq m) = p_a$
 - $P_a(x, x) = 1-p_a$
 - $P_a(x, y) = 0$ para $y \notin \{x, x+1\}$
- $r_a(x, x+1) = a$
- $r_a(x, y) = 0$ para $y \neq x$

Ejemplo: Precios Dinámicos - Modelo MDP - (S, A, P, r)

Un vuelo parte el 150 días y tiene capacidad para 100 pasajeros. Un posible pasajero llega por día y acepta pagar un precio máximo m por el vuelo. Ese precio es distribuido con probabilidades $\text{Prob}(m = 50) = \frac{1}{2}$, $\text{Prob}(m = 70) = \frac{1}{3}$, $\text{Prob}(m = 120) = \frac{1}{6}$.



$$S = \{0, 1, \dots, 100\}$$

$$A = \{50, 70, 120\}$$

- $P_a(100, 100) = 1$ (no hay cancelaciones)

- Para $x < 100$:

- $P_a(x, x+1) = \text{Prob}(a \leq m) = p_a$

- $P_a(x, x) = 1-p_a$

- $P_a(x, y) = 0$ para $y \notin \{x, x+1\}$


- $r_a(x, x+1) = a$

- $r_a(x, y) = 0$ para $y \neq x$

$$\Rightarrow r_a(x) = P_a(x, x+1)r_a(x, x+1) = a p_a$$

Ejemplo: Precios Dinámicos - Modelo MDP - (S, A, P, r)

Un vuelo parte el 150 días y tiene capacidad para 100 pasajeros. Un posible pasajero llega por día y acepta pagar un precio máximo m por el vuelo. Ese precio es distribuido con probabilidades $\text{Prob}(m = 50) = \frac{1}{2}$, $\text{Prob}(m = 70) = \frac{1}{3}$, $\text{Prob}(m = 120) = \frac{1}{6}$.



$$S = \{0, 1, \dots, 100\}$$
$$A = \{50, 70, 120\}$$

a	$P_a(x, x+1) = \text{Prob}(a \leq m) = p_a$	$r_a(x) = a p_a$
50	1	50
100	0.5	50
150	0.17	25.5

Políticas de Decisión

Volviendo al caso general de un MDP, queremos encontrar acciones a_t que maximicen un criterio de optimalidad. Consideremos la recompensa total esperada:

$$\max_{a_t} E \left[\sum_{t=0}^T r_{a_t}(x_t) \right]$$

Qué información podemos utilizar para elegir a_t ?

Políticas de Decisión

Volviendo al caso general de un MDP, queremos encontrar acciones a_t que maximicen un criterio de optimalidad. Consideremos la recompensa total esperada:

$$\max_{a_t} E \left[\sum_{t=0}^T r_{a_t}(x_t) \right]$$

Qué información podemos utilizar para elegir a_t ?

- En el periodo t , conocemos toda la historia $x_0, x_1, \dots, x_t$. Entonces podríamos considerar una política que utilice toda la información que tenemos hasta ese momento: $a_t = u_t(x_0, x_1, \dots, x_t)$.

Políticas de Decisión

Volviendo al caso general de un MDP, queremos encontrar acciones a_t que maximicen un criterio de optimalidad. Consideremos la recompensa total esperada:

$$\max_{a_t} E \left[\sum_{t=0}^T r_{a_t}(x_t) \right]$$

Qué información podemos utilizar para elegir a_t ?

- En el periodo t , conocemos toda la historia $x_0, x_1, \dots, x_t$. Entonces podríamos considerar una política que utilice toda la información que tenemos hasta ese momento: $a_t = u_t(x_0, x_1, \dots, x_t)$.
- Otra opción es tomar decisiones que ignoren la historia del proceso: $a_t = u_t$.

Políticas de Decisión

Volviendo al caso general de un MDP, queremos encontrar acciones a_t que maximicen un criterio de optimalidad. Consideremos la recompensa total esperada:

$$\max_{a_t} E \left[\sum_{t=0}^T r_{a_t}(x_t) \right]$$

Qué información podemos utilizar para elegir a_t ?

- En el periodo t , conocemos toda la historia $x_0, x_1, \dots, x_t$. Entonces podríamos considerar una política que utilice toda la información que tenemos hasta ese momento: $a_t = u_t(x_0, x_1, \dots, x_t)$.
- Otra opción es tomar decisiones que ignoren la historia del proceso: $a_t = u_t$.
- Resulta que, para obtener optimalidad, es suficiente que la decisión dependa del estado actual: $a_t = u_t(x_t)$.

Política Óptima

- $u_t : S \mapsto A$ es una regla indicando, para cada periodo t y estado x , una acción a .
- Existe una política óptima u_t^* que maximiza la suma de recompensas esperada.
- Nuestro problema se vuelve

$$\max_u \mathbb{E} \left[\sum_{t=0}^T r_{u_t(x_t)}(x_t) \right]$$

Política Óptima

- $u_t : S \mapsto A$ es una regla indicando, para cada periodo t y estado x , una acción a .
- Existe una política óptima u_t^* que maximiza la suma de recompensas esperada.
- Nuestro problema se vuelve

$$\max_u \mathbb{E} \left[\sum_{t=0}^T r_{u_t(x_t)}(x_t) \right]$$

- El número de políticas u en T periodos es $(|S| \times |A|)^T$

Política Óptima

- $u_t : S \mapsto A$ es una regla indicando, para cada periodo t y estado x , una acción a .
- Existe una política óptima u_t^* que maximiza la suma de recompensas esperada.
- Nuestro problema se vuelve

$$\max_u \mathbb{E} \left[\sum_{t=0}^T r_{u_t(x_t)}(x_t) \right]$$

- El número de políticas u en T periodos es $(|S| \times |A|)^T$
 - Pero podemos resolver el problema con más eficiencia...

Principio de Optimalidad

La solución del problema de decisión está basada el principio de optimalidad. Se puede demostrar que, si tenemos una política óptima $\{u_\tau^*, \tau = t + 1, \dots, T\}$ entonces también hay una política óptima $\{u_\tau^*, \tau = t, \dots, T\}$.

Principio de Optimalidad

La solución del problema de decisión está basada el principio de optimalidad. Se puede demostrar que, si tenemos una política óptima $\{u_{\tau}^*, \tau = t + 1, \dots, T\}$ entonces también hay una política óptima $\{u_{\tau}^*, \tau = t, \dots, T\}$.

- La solución del problema empezando en el periodo $t+1$ es óptima también para el problema empezando en el periodo t , entonces se puede resolver por recursión, empezando por $t = T$ y retrocediendo hasta $t = 0$.

Programación Dinámica - MDPs

- El problema en $t = T$ es más sencillo. Elegimos $\arg \max_{a \in A} r_a(x)$. El valor de estar en un estado x en $t = T$ es $V_T^*(x) = \max_{a \in A} r_a(x)$.

Programación Dinámica - MDPs

- El problema en $t = T$ es más sencillo. Elegimos $\arg \max_{a \in A} r_a(x)$. El valor de estar en un estado x en $t = T$ es $V_T^*(x) = \max_{a \in A} r_a(x)$


-

- Suponiendo que conocemos el valor de estar en cada estado x en el periodo $t+1$:


$$V_{t+1}^*(x) = \max_u \mathbb{E} \left[\sum_{\tau=t+1}^T r_u(x_\tau) | x_{t+1} = x \right]$$

podemos encontrar el valor y la política óptima en el periodo t .

Programación Dinámica - MDPs




Programación Dinámica - MDPs



Para cada acción a , recibimos: $r_a(x) + \sum_y P_a(x, y) V_{t+1}^*(y)$

Programación Dinámica - MDPs



Para cada acción a , recibimos: $r_a(x) + \sum_y P_a(x, y) V_{t+1}^*(y)$

La mejor acción maximiza esa expresión. Tenemos $u_t^*(x) = \arg \max_{a \in A} \left\{ r_a(x) + \sum_y P_a(x, y) V_{t+1}^*(y) \right\}$

$$V_t^*(x) = \max_{a \in A} \left\{ r_a(x) + \sum_y P_a(x, y) V_{t+1}^*(y) \right\}$$

Programación Dinámica - MDPs

1. Hacemos $t = T$. Calculamos $V_T^*(x) = \max_{a \in A} r_a(x)$

Programación Dinámica - MDPs

1. Hacemos $t = T$. Calculamos $V_T^*(x) = \max_{a \in A} r_a(x)$
2. Hacemos $t = t-1$. Calculamos $V_t^*(x) = \max_{a \in A} \left\{ r_a(x) + \sum_y P_a(x, y) V_{t+1}^*(y) \right\}$

Programación Dinámica - MDPs


1. Hacemos $t = T$. Calculamos $V_T^*(x) = \max_{a \in A} r_a(x)$
2. Hacemos $t = t-1$. Calculamos $V_t^*(x) = \max_{a \in A} \left\{ r_a(x) + \sum_y P_a(x, y) V_{t+1}^*(y) \right\}$
3. Si $t = 0$, fin. Si no, volvemos al paso 2.

Derivamos la política óptima a partir de la función valor $V_t^*(x)$:

$$u_t^*(x) = \arg \max_{a \in A} \left\{ r_a(x) + \sum_y P_a(x, y) V_{t+1}^*(y) \right\}$$

Ejemplo: Precios Dinámicos - Modelo MDP - ($\mathbf{S}, \mathbf{A}, \mathbf{P}, \mathbf{r}$)

Un vuelo parte el 150 días y tiene capacidad para 100 pasajeros. Un posible pasajero llega por día y acepta pagar un precio máximo m por el vuelo. Ese precio es distribuido con probabilidades $\text{Prob}(m = 50) = \frac{1}{2}$, $\text{Prob}(m = 70) = \frac{1}{3}$, $\text{Prob}(m = 120) = \frac{1}{6}$.




$$\mathbf{S} = \{0, 1, \dots, 100\}$$
$$\mathbf{A} = \{50, 70, 120\}$$

a	$P_a(x, x+1)$	$r_a(x)$
50	1	50
70	$\frac{1}{2}$	35
120	$\frac{1}{6}$	20


Podemos calcular la política que maximiza la ganancia esperada usando Python.

Ejemplo: Precios Dinámicos - Política Óptima




Cuánto esperamos ganar manteniendo el precio tijo en \$50? En \$70? En \$120?

Ejemplo: Precios Dinámicos - Política Óptima



Cuánto esperamos ganar manteniendo el precio fijo en \$50? En \$70? En \$120?

Ejemplo: Precios Dinámicos - Política Óptima



Ejemplo: Precios Dinámicos - Política Óptima

Discusión: Cómo interpretar resultados? Corresponden a las expectativas? Qué hipótesis podrían ser distintas?

