

Procesos Markovianos de Decisión

Clase 3

- MDPs con horizonte infinito
 - Ecuación de Bellman
 - Iteración de valor
 - Iteración de políticas
 - Función de utilidad
- Aplicaciones
 - Política de pesca
 - Optimización de portafolio con consumo

Ejemplo: Pesca de salmones

Cada año, necesitamos decidir cuánto salmón pescar en una determinada área. Cada salmón genera una ganancia fija. Pero si pescamos demasiados salmones en un año, eso impactará en la cantidad de salmones disponibles en el año siguiente. Debemos decidir cuánto pescar a cada año para maximizar la ganancia.

Cómo modelamos ese problema?

Ejemplo: Pesca de salmones

Cada año, necesitamos decidir cuánto salmón pescar en una determinada área. Cada salmón genera una ganancia fija. Pero si pescamos demasiados salmones en un año, eso impactará en la cantidad de salmones disponibles en el año siguiente. Debemos decidir cuánto pescar a cada año para maximizar la ganancia.

Cómo modelamos ese problema?

Vamos a considerar una versión más simple para visualizar el proceso:

- a cada año, decidimos solo si pescar o no una cierta proporción de salmones

Ejemplo: Pesca de salmones

Cada año, necesitamos decidir cuánto salmón pescar en una determinada área. Cada salmón genera una ganancia fija. Pero si pescamos demasiados salmones en un año, eso impactará en la cantidad de salmones disponibles en el año siguiente. Debemos decidir cuánto pescar a cada año para maximizar la ganancia.

Cómo modelamos ese problema?

Vamos a considerar una versión más simple para visualizar el proceso:

- a cada año, decidimos solo si pescar o no una cierta proporción de salmones
- consideramos 4 estados para la población de salmones: vacío, bajo, mediano, alto.

Ejemplo: Pesca de salmones



Diagram illustrating the categories of salmon catch, represented by four ovals arranged horizontally. The categories are: vacío, bajo, mediano, and alto.


vacío

bajo


mediano

alto


Ejemplo: Pesca de salmones




Ejemplo: Pesca de salmones



Ejemplo: Pesca de salmones



Ejemplo: Pesca de salmones




Qué decisiones tomar? Vamos a resolver el problema con Python. Consideramos una versión más refinada del problema, con tres niveles de pesca (no pescar, pesca moderada, pesca agresiva).

Ejemplo: Pesca de salmones

- Cómo la elección del horizonte T impacta nuestras decisiones?

- Cómo la elección del horizonte T impacta nuestras decisiones?




Ejemplo: Pesca de salmones

- Si en el estado vacío tenemos la opción de no repoblar, cómo eso cambia el análisis? Cuáles son las condiciones para repoblar o no?


Ejemplo: Pesca de salmones

- Si en el estado vacío tenemos la opción de no repoblar, cómo eso cambia el análisis? Cuáles son las condiciones para repoblar o no?



Ejemplo: Pesca de salmones

- Si en el estado vacío tenemos la opción de no repoblar, cómo eso cambia el análisis? Cuáles son las condiciones para repoblar o no?



Ejemplo: Pesca de salmones

- Qué horizonte deberíamos considerar?

Ejemplo: Pesca de salmones

- Qué horizonte deberíamos considerar?
- Si utilizamos horizontes más largos, cómo comparar ganancias en el futuro próximo con ganancias en el futuro distante?

Ejemplo: Pesca de salmones

- Qué horizonte deberíamos considerar?
- Si utilizamos horizontes más largos, cómo comparar ganancias en el futuro próximo con ganancias en el futuro distante?
- Vamos a considerar la ganancia esperada con un factor de descuento:

$$\max_u \mathbb{E} \left[\sum_t \alpha^t r_u(x_t) \right]$$

- Cómo encontrar la política óptima?

MDP con Horizonte Infinito

- Consideremos nuevamente la recursión utilizada con horizonte finito, con descuento.

1. Hacemos $t = 0$. Calculamos $V_0^*(x) = \max_{a \in A} r_a(x)$
2. Hacemos $t = t+1$. Calculamos $V_t^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_{t-1}^*(y) \right\}$
3. Si $t = T$, fin. Si no, volvemos al paso 2.

MDP con Horizonte Infinito

- Consideremos nuevamente la recursión utilizada con horizonte finito, con descuento.
- Qué sucede cuando $T \rightarrow \infty$?

1. Hacemos $t = 0$. Calculamos $V_0^*(x) = \max_{a \in A} r_a(x)$
2. Hacemos $t = t+1$. Calculamos $V_t^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_{t-1}^*(y) \right\}$
3. Si $t = T$, fin. Si no, volvemos al paso 2.

MDP con Horizonte Infinito

- Consideremos nuevamente la recursión utilizada con horizonte finito, con descuento.
- Qué sucede cuando $T \rightarrow \infty$?

$$\lim_{T \rightarrow \infty} V_T^*(x) = V^*(x)$$

1. Hacemos $t = 0$. Calculamos $V_0^*(x) = \max_{a \in A} r_a(x)$
2. Hacemos $t = t+1$. Calculamos $V_t^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_{t-1}^*(y) \right\}$
3. Si $t = T$, fin. Si no, volvemos al paso 2.

MDP con Horizonte Infinito

- Consideremos nuevamente la recursión utilizada con horizonte finito, con descuento.
- Qué sucede cuando $T \rightarrow \infty$?

$$\lim_{T \rightarrow \infty} V_T^*(x) = V^*(x)$$

$$V_t^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_{t-1}^*(y) \right\}$$

MDP con Horizonte Infinito - Ecuación de Bellman

- Consideremos nuevamente la recursión utilizada con horizonte finito, con descuento.
- Qué sucede cuando $T \rightarrow \infty$?

$$\lim_{T \rightarrow \infty} V_T^*(x) = V^*(x)$$

- Ecuación de Bellman:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

MDP con Horizonte Infinito - Ecuación de Bellman

- Consideremos nuevamente la recursión utilizada con horizonte finito, con descuento.
- Qué sucede cuando $T \rightarrow \infty$?

$$\lim_{T \rightarrow \infty} V_T^*(x) = V^*(x)$$

- Ecuación de Bellman:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

- Después de resolver la ecuación de Bellman, podemos derivar nuevamente la política óptima a partir de la función valor:

$$u^*(x) = \arg \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

Ecuación de Bellman - Algoritmos de Resolución

- Hay varios algoritmos para resolver la ecuación de Bellman, nos enfocaremos en dos métodos que forman la base para los algoritmos de aprendizaje por refuerzo.

Ecuación de Bellman - Iteración de Valor

- Hay varios algoritmos para resolver la ecuación de Bellman, nos enfocaremos en dos métodos que forman la base para los algoritmos de aprendizaje por refuerzo.
- Iteración de valor:
 1. Hacemos $t = 0$. Inicializamos $V_0(x)$ con un valor arbitrario, por ejemplo 0.
 2. Hacemos $t = t+1$. Calculamos $V_{t+1}(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_t(y) \right\}$.
 3. Utilizando un criterio de convergencia para $V_t(x)$, decidimos si parar o continuar.

Ecuación de Bellman - Iteración de Valor

- Hay varios algoritmos para resolver la ecuación de Bellman, nos enfocaremos en dos métodos que forman la base para los algoritmos de aprendizaje por refuerzo.
- Iteración de valor:
 1. Hacemos $t = 0$. Inicializamos $V_0(x)$ con un valor arbitrario, por ejemplo 0.
 2. Hacemos $t = t+1$. Calculamos $V_{t+1}(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_t(y) \right\}$.
 3. Utilizando un criterio de convergencia para $V_t(x)$, decidimos si parar o continuar. Por ejemplo, $\max_x (V_{t+1}(x) - V_t(x))^2 \leq \epsilon$ para algún ϵ .

Ecuación de Bellman - Iteración de Política

1. Hacemos $t = 0$. Empezamos con una política arbitraria u_0 .
2. Evaluamos la función valor V_{u_t} . Para eso, debemos resolver:

$$V_{u_t} = r_{u_t} + \alpha P_{u_t} v_{u_t}$$

Ecuación de Bellman - Iteración de Política

1. Hacemos $t = 0$. Empezamos con una política arbitraria u_0 .
2. Evaluamos la función valor V_{u_t} . Para eso, debemos resolver:

$$V_{u_t} = r_{u_t} + \alpha P_{u_t} v_{u_t}$$

3. Calculamos una nueva política

$$u_{t+1}(x) = \arg \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_{u_t}(y) \right\}$$

4. Si $u_{t+1} = u_t$, paramos. Si no, hacemos $t = t+1$ y volvemos al paso 2.

Ecuación de Bellman - Iteración de Política

- Intuición:

$$u_{t+1}(x) = \arg \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_{u_t}(y) \right\}$$
$$\implies r_{u_{t+1}} + \alpha P_{u_{t+1}} V_{u_t} \geq r_{u_t} + \alpha P_{u_t} V_{u_t}$$

Ecuación de Bellman - Iteración de Política

- Intuición:

$$u_{t+1}(x) = \arg \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_{u_t}(y) \right\}$$
$$\implies r_{u_{t+1}} + \alpha P_{u_{t+1}} V_{u_t} \geq r_{u_t} + \alpha P_{u_t} V_{u_t}$$

- La secuencia de políticas $(u_{t+1}, u_t, u_t, u_t, \dots)$ es mejor que $(u_t, u_t, u_t, u_t, \dots)$.

Ecuación de Bellman - Iteración de Política

- Intuición:

$$u_{t+1}(x) = \arg \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_{u_t}(y) \right\}$$
$$\implies r_{u_{t+1}} + \alpha P_{u_{t+1}} V_{u_t} \geq r_{u_t} + \alpha P_{u_t} V_{u_t}$$

- La secuencia de políticas $(u_{t+1}, u_t, u_t, u_t, \dots)$ es mejor que $(u_t, u_t, u_t, u_t, \dots)$.
- Pero entonces $(u_{t+1}, u_{t+1}, u_t, u_t, \dots)$ es mejor que $(u_{t+1}, u_t, u_t, u_t, \dots)$

.

Ecuación de Bellman - Iteración de Política

- Intuición:

$$u_{t+1}(x) = \arg \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_{u_t}(y) \right\}$$
$$\implies r_{u_{t+1}} + \alpha P_{u_{t+1}} V_{u_t} \geq r_{u_t} + \alpha P_{u_t} V_{u_t}$$

- La secuencia de políticas $(u_{t+1}, u_t, u_t, u_t, \dots)$ es mejor que $(u_t, u_t, u_t, u_t, \dots)$.
- Pero entonces $(u_{t+1}, u_{t+1}, u_t, u_t, \dots)$ es mejor que $(u_{t+1}, u_t, u_t, u_t, \dots)$.
- Podemos seguir reemplazando u_t con u_{t+1} sucesivamente, obteniendo una secuencia de políticas que van mejorando.
- Concluimos que u_{t+1} es mejor que u_t .

Iteración de Valor vs. Iteración de Política

- Como hay un número finito de políticas, iteración de política siempre termina.


Iteración de Valor vs. Iteración de Política

- Como hay un número finito de políticas, iteración de política siempre termina.
- Un paso de iteración de política es más costoso que un paso de iteración de valor, porque debemos evaluar la política y seleccionar la nueva acción. Sin embargo, iteración de política suele terminar en menos pasos, e iteración de valor puede ser lenta, especialmente cuando el factor de descuento α es alto.

Iteración de Valor vs. Iteración de Política

- Como hay un número finito de políticas, iteración de política siempre termina.
- Un paso de iteración de política es más costoso que un paso de iteración de valor, porque debemos evaluar la política y seleccionar la nueva acción. Sin embargo, iteración de política suele terminar en menos pasos, e iteración de valor puede ser lenta, especialmente cuando el factor de descuento α es alto.
- Iteración de valor e iteración de política forman la base para algoritmos de aprendizaje por refuerzo.

- Resolución con horizonte infinito, distintos factores de descuento



Ejemplo: Optimización de Portafolio

- Consideramos una situación donde hay dos posibilidades de inversión:
 - un instrumento con precio S_t que evoluciona en el tiempo según

$$S_{t+1} = S_t e^{r + \sigma \epsilon_t}$$

donde $\epsilon_t \sim N(0, 1)$,

- una caja de ahorros con tasa de interés r_f
- Cómo debemos invertir para maximizar el valor del portafolio después de T periodos?

Ejemplo: Optimización de Portafolio

- Estado = valor W_t del portafolio
 - Asumimos que no hay costos asociados a la compra y venta de la acción

Ejemplo: Optimización de Portafolio

- Estado = valor W_t del portafolio
 - Asumimos que no hay costos asociados a la compra y venta de la acción
- Acción $0 \leq \beta_t \leq 1$ - fracción del portafolio invertida en la acción

Ejemplo: Optimización de Portafolio

- Estado = valor W_t del portafolio
 - Asumimos que no hay costos asociados a la compra y venta de la acción
- Acción $0 \leq \beta_t \leq 1$ - fracción del portafolio invertida en la acción
- Transición: $W_{t+1} = W_t [\beta_t e^{r+\sigma\epsilon_t} + (1 - \beta_t)r_f]$

Ejemplo: Optimización de Portafolio

- Estado = valor W_t del portafolio
 - Asumimos que no hay costos asociados a la compra y venta de la acción
- Acción $0 \leq \beta_t \leq 1$ - fracción del portafolio invertida en la acción
- Transición: $W_{t+1} = W_t [\beta_t e^{r+\sigma\epsilon_t} + (1 - \beta_t)r_f]$
- Cuál es la solución si estamos interesados en maximizar $E[W_T]$?

$$E[W_T] = E \left\{ \prod_{t=1}^{T-1} [\beta_t e^{r+\sigma\epsilon_t} + (1 - \beta_t)r_f] \right\}$$

Ejemplo: Optimización de Portafolio

- Cuál es la solución si estamos interesados en maximizar $E[W_T]$?

$$E[W_T] = E \left\{ \prod_{t=1}^{T-1} [\beta_t e^{r+\sigma\epsilon_t} + (1-\beta_t)r_f] \right\}$$

- La solución está basada en dos observaciones:
 - ϵ_t es independiente de lo que pasó antes
 - con ese criterio de optimalidad, somos indiferentes al riesgo. Eso quiere decir que, si el instrumento y la caja de ahorros tienen la misma ganancia en valor esperado, podemos elegir tanto uno como el otro, y el criterio se convierte en:

$$\beta_t = \begin{cases} 1 & \text{if } e^{r+\sigma^2/2} > r_f \\ 0 & \text{otherwise} \end{cases}$$

Ejemplo: Optimización de Portafolio

- Cuál es la solución si estamos interesados en maximizar $E[W_T]$?

$$E[W_T] = E \left\{ \prod_{t=1}^{T-1} [\beta_t e^{r+\sigma\epsilon_t} + (1-\beta_t)r_f] \right\}$$

- La solución está basada en dos observaciones:
 - ϵ_t es independiente de lo que pasó antes
 - con ese criterio de optimalidad, somos indiferentes al riesgo. Eso quiere decir que, si el instrumento y la caja de ahorros tienen la misma ganancia en valor esperado, podemos elegir tanto uno como el otro, y el criterio se convierte en:

$$\beta_t = \begin{cases} 1 & \text{if } e^{r+\sigma^2/2} > r_f \\ 0 & \text{otherwise} \end{cases}$$


Aversión al Riesgo

- Consideremos una situación donde podés elegir recibir un monto fijo o un monto establecido por el resultado de tirar una moneda.
 - Si el monto fijo es \$500 y el monto dado por la moneda es \$0 o \$1000, qué elegís?
 - Si el monto fijo es US\$500,000 y el monto dado por la moneda es US\$0 o US\$1,000,000, qué elegís?

Función de Utilidad

- Podemos capturar nuestras preferencias respecto al riesgo eligiendo la función recompensas con el concepto de función de utilidad.
- La función de utilidad captura el valor de distintas opciones. En el caso del juego con la moneda, por ejemplo, podemos tener

$$u(w) = \log(0.001w + 1)$$




Función de Utilidad

- Podemos capturar nuestras preferencias respecto al riesgo eligiendo la función recompensas con el concepto de función de utilidad.
- La función de utilidad captura el valor de distintas opciones. En el caso del juego con la moneda, por ejemplo, podemos tener

$$u(w) = \log(0.001w + 1)$$

- Por qué cóncava?



Función de Utilidad


- Podemos capturar nuestras preferencias respecto al riesgo eligiendo la función recompensas con el concepto de función de utilidad.
- La función de utilidad captura el valor de distintas opciones. En el caso del juego con la moneda, por ejemplo, podemos tener

$$u(w) = \log(0.001w + 1)$$

- Por qué cóncava?
- Entonces

$$u(0.5) \approx 0.5(u(0) + u(1)) \approx 0.0005$$

$$u(500000) = 6.2166 > 0.5(u(0) + u(1000000)) = 3.4544$$



Ejemplo: Optimización de Portafolio


- Estado = valor W_t del portafolio
 - Asumimos que no hay costos asociados a la compra y venta de la acción
- Acción $0 \leq \beta_t \leq 1$ - fracción del portafolio invertida en la acción
- Transición: $W_{t+1} = W_t [\beta_t e^{r+\sigma\epsilon_t} + (1 - \beta_t)r_f]$
- Elegimos β_t , $t = 0, 1, \dots, T$ para maximizar $E[\nu(W_T)]$, where $\nu(w) = w^\gamma$ for $0 < \gamma < 1$.

Ejemplo: Optimización de Portafolio

- Estado = valor W_t del portafolio
 - Asumimos que no hay costos asociados a la compra y venta de la acción
- Acción $0 \leq \beta_t \leq 1$ - fracción del portafolio invertida en la acción
- Transición: $W_{t+1} = W_t [\beta_t e^{r+\sigma\epsilon_t} + (1 - \beta_t)r_f]$
- Elegimos β_t , $t = 0, 1, \dots, T$ para maximizar $E[\nu(W_T)]$, where $\nu(w) = w^\gamma$ for $0 < \gamma < 1$.
- La solución es constante en el tiempo: $\beta_t^* = \beta^*(\gamma)$

Ejemplo: Optimización de Portafolio

- La solución es constante en el tiempo: $\beta_t^* = \beta^*(\gamma)$



Ejemplo: Optimización de Portafolio con Consumo

- Estado = valor W_t del portafolio
 - Asumimos que no hay costos asociados a la compra y venta de la acción
- Acción $0 \leq \beta_t \leq 1$ y $0 \leq \delta_t \leq 1$
 - en cada periodo t , consumimos $W_t \delta_t$
 - invertimos una fracción β_t del restante en el activo y el resto en la caja de ahorros.

Ejemplo: Optimización de Portafolio con Consumo

- Estado = valor W_t del portafolio
 - Asumimos que no hay costos asociados a la compra y venta de la acción
- Acción $0 \leq \beta_t \leq 1$ y $0 \leq \delta_t \leq 1$
 - en cada periodo t , consumimos $W_t \delta_t$
 - invertimos una fracción β_t del restante en el activo y el resto en la caja de ahorros.
- Transición: $W_{t+1} = W_t \delta_t [\beta_t e^{r + \sigma \epsilon_t} + (1 - \beta_t) r_f]$

Ejemplo: Optimización de Portafolio con Consumo

- Estado = valor W_t del portafolio
 - Asumimos que no hay costos asociados a la compra y venta de la acción
- Acción $0 \leq \beta_t \leq 1$ y $0 \leq \delta_t \leq 1$
 - en cada periodo t , consumimos $W_t \delta_t$
 - invertimos una fracción β_t del restante en el activo y el resto en la caja de ahorros.
- Transición: $W_{t+1} = W_t \delta_t [\beta_t e^{r + \sigma \epsilon_t} + (1 - \beta_t) r_f]$
- Recompensa: $\nu(W_t \delta_t)$

Ejemplo: Optimización de Portafolio con Consumo

- Estado = valor W_t del portafolio
 - Asumimos que no hay costos asociados a la compra y venta de la acción
- Acción $0 \leq \beta_t \leq 1$ y $0 \leq \delta_t \leq 1$
 - en cada periodo t , consumimos $W_t \delta_t$
 - invertimos una fracción β_t del restante en el activo y el resto en la caja de ahorros.
- Transición: $W_{t+1} = W_t \delta_t [\beta_t e^{r+\sigma \epsilon_t} + (1 - \beta_t) r_f]$
- Recompensa: $\nu(W_t \delta_t)$
- Criterio de optimalidad: $\max_u \mathbb{E} \left[\sum_{t=0}^{\infty} \alpha^t \nu(W_t \delta_t) \right]$