

Aprendizaje por Refuerzo - Métodos Computacionales

Clase 4

- Computación en MDPs
 - Iteración de valor
 - Iteración de política
- Desafíos en MDPs
 - Incertidumbre y/o complejidad del ambiente
 - “Curse of dimensionality”
- Métodos de Aprendizaje por Refuerzo
 - Simulación Monte Carlo
 - TD-Learning
 - Q-Learning

Revisión: MDPs

- MDP: tupla (S, A, P, r)

Revisión: MDPs

- MDP: tupla (S, A, P, r)
- Ecuación de Bellman y función valor:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

Revisión: MDPs

- MDP: tupla (S, A, P, r)
- Ecuación de Bellman y función valor:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

- Función de políticas óptimas:

$$u^*(x) = \arg \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

Revisión: MDPs

- MDP: tupla (S, A, P, r)

- Ecuación de Bellman y función valor:


$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

- Función de políticas óptimas:

$$u^*(x) = \arg \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

- Iteración de valor e iteración de política

Ejemplo: Ruta de Casa al Trabajo



Ejemplo: Ruta de Casa al Trabajo

- Estado = posición en el mapa, en las esquinas

$$x = (i, j)$$

- Acciones = desplazamiento, una cuadra por vez:

$$a = \begin{cases} (-1, 0) & \text{N} \\ (1, 0) & \text{S} \\ (0, 1) & \text{E} \\ (0, -1) & \text{O} \end{cases}$$


- Transición (determinística)

$$x^+ = \begin{cases} x + a & \text{si } x \neq x^* \\ x^* & \text{si } x = x^* \end{cases}$$

- Recompensa (castigo, en este caso):

$$r_a(x, w) = \begin{cases} \text{tiempo}(x, x + a, w) & \text{si } x \neq x^* \\ 0 & \text{si } x = x^* \end{cases}$$

$$r_a(x) = \mathbb{E}_w [r_a(x, w)]$$



- Objetivo:
Encontrar política u minimizando


$$\min_u \mathbb{E} \left[\sum_{t=0}^{\infty} r_u(x_t) \right]$$

Ejemplo: Ruta de Casa al Trabajo

- Objetivo:
Encontrar politica u minimizando

$$\min_u E \left[\sum_{t=0}^{\infty} r_u(x_t) \right]$$

- Cómo resolver?
 - Iteración de valores
 - Iteración de políticas
- Implementación en Python



Desafíos Para la Aplicación de MDPs

Información Parcial

Desafíos Para la Aplicación de MDPs

Información Parcial

- 1) Parámetros del modelo desconocidos
 - probabilidades de transición P y recompensas r

Desafíos Para la Aplicación de MDPs

Información Parcial

- 1) Parámetros del modelo desconocidos
 - probabilidades de transición P y recompensas r

- 2) Estado x no siempre puede ser observado.
 - observaciones $h(x, w)$ con ruido w
 - procesos markovianos de decisión parcialmente observables, POMDPs)

Desafíos Para la Aplicación de MDPs

Información Parcial

- 1) Parámetros del modelo desconocidos
 - probabilidades de transición P y recompensas r

- 2) Estado x no siempre puede ser observado.
 - observaciones $h(x, w)$ con ruido w
 - procesos markovianos de decisión parcialmente observables, POMDPs)

Complejidad del Sistema

- 3) “Maldición de la dimensionalidad”

Desafíos Para la Aplicación de MDPs

Información Parcial

- 1) Parámetros del modelo desconocidos
 - probabilidades de transición P y recompensas r

- 2) Estado x no siempre puede ser observado.
 - observaciones $h(x, w)$ con ruido w
 - procesos markovianos de decisión parcialmente observables, POMDPs)

Complejidad del Sistema

- 3) “Maldición de la dimensionalidad”
 - El número de estados crece exponencialmente con el número de variables de estado

Desafíos Para la Aplicación de MDPs

Información Parcial

- 1) Parámetros del modelo desconocidos
 - probabilidades de transición P y recompensas r
- 2) Estado x no siempre puede ser observado.
 - observaciones $h(x, w)$ con ruido w
 - procesos markovianos de decisión parcialmente observables, POMDPs)

Complejidad del Sistema

- 3) “Maldición de la dimensionalidad”
 - El número de estados crece exponencialmente con el número de variables de estado
 - dificultades para almacenar P y r y calcular V^*

Desafíos Para la Aplicación de MDPs

Información Parcial

- 1) Parámetros del modelo desconocidos
 - probabilidades de transición P y recompensas r
- 2) Estado x no siempre puede ser observado.
 - observaciones $h(x, w)$ con ruido w
 - procesos markovianos de decisión parcialmente observables, POMDPs)

Complejidad del Sistema

- 3) “Maldición de la dimensionalidad”
 - El número de estados crece exponencialmente con el número de variables de estado
 - dificultades para almacenar P y r y calcular V^*
 - Similarmente, el número de acciones crece exponencialmente con el número de variables de acción

Desafíos Para la Aplicación de MDPs

Información Parcial

- 1) Parámetros del modelo desconocidos
 - probabilidades de transición P y recompensas r
- 2) Estado x no siempre puede ser observado.
 - observaciones $h(x, w)$ con ruido w
 - procesos markovianos de decisión parcialmente observables, POMDPs)

Complejidad del Sistema

- 3) “Maldición de la dimensionalidad”
 - El número de estados crece exponencialmente con el número de variables de estado
 - dificultades para almacenar P y r y calcular V^*
 - Similarmente, el número de acciones crece exponencialmente con el número de variables de acción

$$\max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

Desafíos Para la Aplicación de MDPs

Información Parcial

- 1) Parámetros del modelo desconocidos
 - probabilidades de transición P y recompensas r
- 2) Estado x no siempre puede ser observado.
 - observaciones $h(x, w)$ con ruido w
 - procesos markovianos de decisión parcialmente observables, POMDPs)

Complejidad del Sistema

- 3) "Curse of dimensionality"
 - número de estados crece exponencialmente con el número de variables de estado
 - dificultades para almacenar P y r y calcular V^*

Similarmente, el número de acciones crece exponencialmente con el número de variables de acción

$$\max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

Desafíos Para la Aplicación de MDPs

Información Parcial

1) Parámetros del modelo desconocidos

- probabilidades de transición P y recompensas r

⇒ aprendizaje

2) Estado x no siempre puede ser observado.

- observaciones $h(x, w)$ con ruido w
- procesos markovianos de decisión parcialmente observables, POMDPs)

Complejidad del Sistema

3) “Maldición de la dimensionalidad”

- El número de estados crece exponencialmente con el número de variables de estado
 - dificultades para almacenar P y r y calcular V^*
- Similarmente, el número de acciones crece exponencialmente con el número de variables de acción

$$\max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

Desafíos Para la Aplicación de MDPs

Información Parcial

1) Parámetros del modelo desconocidos

- probabilidades de transición P y recompensas r

⇒ aprendizaje

2) Estado x no siempre puede ser observado.

- observaciones $h(x, w)$ con ruido w
- procesos markovianos de decisión parcialmente observables, POMDPs)

Complejidad del Sistema

3) “Maldición de la dimensionalidad”

- El número de estados crece exponencialmente con el número de variables de estado
 - dificultades para almacenar P y r y calcular V^*
- Similarmente, el número de acciones crece exponencialmente con el número de variables de acción

$$\max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

⇒ generalización

Desafíos Para la Aplicación de MDPs

Información Parcial

1) Parámetros del modelo desconocidos

- probabilidades de transición P y recompensas r

⇒ aprendizaje

2) Estado x no siempre puede ser observado.

- observaciones $h(x, w)$ con ruido w
- procesos markovianos de decisión parcialmente observables, POMDPs)

⇒ en principio, se convierte en MDP
... en la práctica, muy difícil

Complejidad del Sistema

3) “Maldición de la dimensionalidad”

- El número de estados crece exponencialmente con el número de variables de estado
 - dificultades para almacenar P y r y calcular V^*
- Similarmente, el número de acciones crece exponencialmente con el número de variables de acción

$$\max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$


⇒ generalización

Desafío: Incertidumbre Sobre Parámetros del Modelo

- La metodología está basada en información que no siempre tenemos, en especial las probabilidades de transición P y recompensas r .
- En la práctica, muchas veces no tenemos esos parámetros. Qué hacer?


Desafío: Incertidumbre Sobre Parámetros del Modelo

- La metodología está basada en información que no siempre tenemos, en especial las probabilidades de transición P y recompensas r .
- En la práctica, muchas veces no tenemos esos parámetros. Qué hacer?
 - Aprender a partir de interacciones con el ambiente.




Desafío: Incertidumbre Sobre Parámetros del Modelo

- La metodología está basada en información que no siempre tenemos, en especial las probabilidades de transición P y recompensas r .
- En la práctica, muchas veces no tenemos esos parámetros. Qué hacer?
 - Aprender a partir de interacciones con el ambiente.
 - Con qué datos?




Desafío: Incertidumbre Sobre Parámetros del Modelo

- La metodología está basada en información que no siempre tenemos, en especial las probabilidades de transición P y recompensas r .
- En la práctica, muchas veces no tenemos esos parámetros. Qué hacer?
 - Aprender a partir de interacciones con el ambiente.
 - Con qué datos?




Desafío: Incertidumbre Sobre Parámetros del Modelo

- La metodología está basada en información que no siempre tenemos, en especial las probabilidades de transición P y recompensas r .
- En la práctica, muchas veces no tenemos esos parámetros. Qué hacer?
 - Aprender a partir de interacciones con el ambiente.
 - Con qué datos?




Desafío: Incertidumbre Sobre Parámetros del Modelo

- La metodología está basada en información que no siempre tenemos, en especial las probabilidades de transición P y recompensas r .
- En la práctica, muchas veces no tenemos esos parámetros. Qué hacer?
 - Aprender a partir de interacciones con el ambiente.
 - Con qué datos?




Desafío: Incertidumbre Sobre Parámetros del Modelo

- La metodología está basada en información que no siempre tenemos, en especial las probabilidades de transición P y recompensas r .
- En la práctica, muchas veces no tenemos esos parámetros. Qué hacer?
 - Aprender a partir de interacciones con el ambiente.
 - Con qué datos?
 - trayectorias $(x_{t_i}, a_{t_i}, r_{t_i}, x_{t_i+1}), i = 1, \dots, n$



Desafío: Incertidumbre Sobre Parámetros del Modelo

- La metodología está basada en información que no siempre tenemos, en especial las probabilidades de transición P y recompensas r .
- En la práctica, muchas veces no tenemos esos parámetros. Qué hacer?
 - Aprender a partir de interacciones con el ambiente.
 - Con qué datos?
 - trayectorias $(x_{t_i}, a_{t_i}, r_{t_i}, x_{t_i+1}), i = 1, \dots, n$
 - tuplas $(x_i, a_i, r_i, x_i^+), i = 1, \dots, n$




Aprendizaje por Refuerzo

- Cómo ir de los datos (x_i, a_i, r_i, x_i^+) , $i = 1, \dots, n$ a una política de decisión?

Experiencias
 (x_i, a_i, r_i, x_i^+)
 $i = 1, \dots, n$

Aprendizaje por Refuerzo

- Cómo ir de los datos (x_i, a_i, r_i, x_i^+) , $i = 1, \dots, n$ a una política de decisión?
- **Aprendiendo un modelo**



Aprendizaje por Refuerzo


- Cómo ir de los datos (x_i, a_i, r_i, x_i^+) , $i = 1, \dots, n$ a una política de decisión?

- **Aprendiendo un modelo**

- Aprendizaje supervisado:

$$\hat{r}(x) = \frac{\sum_{i: x_i=x} r_i}{\sum_{i: x_i=x} 1}$$

$$\hat{P}(x, y) = \frac{\sum_{i: x_i=x, x_i^+=y} 1}{\sum_{i: x_i=x} 1}$$



Aprendizaje por Refuerzo

- Cómo ir de los datos (x_i, a_i, r_i, x_i^+) , $i = 1, \dots, n$ a una política de decisión?


- **Aprendiendo un modelo**

- Aprendizaje supervisado:

$$\hat{r}(x) = \frac{\sum_{i: x_i=x} r_i}{\sum_{i: x_i=x} 1}$$

$$\hat{P}(x, y) = \frac{\sum_{i: x_i=x, x_i^+=y} 1}{\sum_{i: x_i=x} 1}$$

- Programación dinámica con $(S, A, \hat{P}, \hat{r})$
→ función valor $\hat{V}$, política $\hat{u}$



Aprendizaje por Refuerzo

- Cómo ir de los datos (x_i, a_i, r_i, x_i^+) , $i = 1, \dots, n$ a una política de decisión?

- **Aprendiendo un modelo**

- Aprendizaje supervisado:


$$\hat{r}(x) = \frac{\sum_{i: x_i=x} r_i}{\sum_{i: x_i=x} 1}$$

$$\hat{P}(x, y) = \frac{\sum_{i: x_i=x, x_i^+=y} 1}{\sum_{i: x_i=x} 1}$$

- Programación dinámica con $(S, A, \hat{P}, \hat{r})$
→ función valor $\hat{V}$, política $\hat{u}$

- **Sin modelo**

- Aprender $\hat{V}$ y/o $\hat{u}$ directamente.



Aprendizaje por Refuerzo

- Cómo ir de los datos (x_i, a_i, r_i, x_i^+) , $i = 1, \dots, n$ a una política de decisión?

- **Aprendiendo un modelo**

- Aprendizaje supervisado:


$$\hat{r}(x) = \frac{\sum_{i: x_i=x} r_i}{\sum_{i: x_i=x} 1}$$

$$\hat{P}(x, y) = \frac{\sum_{i: x_i=x, x_i^+=y} 1}{\sum_{i: x_i=x} 1}$$

- Programación dinámica con $(S, A, \hat{P}, \hat{r})$
→ función valor $\hat{V}$, política $\hat{u}$

- **Sin modelo**

- Aprender $\hat{V}$ y/o $\hat{u}$ directamente.
 - **Aprendizaje por refuerzo**



Aprendizaje por Refuerzo: Por Qué ?

- Única opción cuando no es posible construir un modelo:
 - Necesitamos aprender sobre el ambiente y tomar decisiones en tiempo real
 - Problema enfrentado por seres humanos y animales!
 - El comportamiento del ambiente está sujeto a cambios

Aprendizaje por Refuerzo: Por Qué ?

- Única opción cuando no es posible construir un modelo:
 - Necesitamos aprender sobre el ambiente y tomar decisiones en tiempo real
 - Problema enfrentado por seres humanos y animales!
 - El comportamiento del ambiente está sujeto a cambios
- Menos suposiciones sobre el modelo del ambiente → sistema más robusto

Aprendizaje por Refuerzo: Por Qué ?

- Única opción cuando no es posible construir un modelo:
 - Necesitamos aprender sobre el ambiente y tomar decisiones en tiempo real
 - Problema enfrentado por seres humanos y animales!
 - El comportamiento del ambiente está sujeto a cambios
- Menos suposiciones sobre el modelo del ambiente → sistema más robusto
- También útil en situaciones donde tenemos acceso a un modelo:
 - Modelo explícito y conocido, pero no puede ser tratado analíticamente

Aprendizaje por Refuerzo: Por Qué ?


- Única opción cuando no es posible construir un modelo:
 - Necesitamos aprender sobre el ambiente y tomar decisiones en tiempo real
 - Problema enfrentado por seres humanos y animales!
 - El comportamiento del ambiente está sujeto a cambios
- Menos suposiciones sobre el modelo del ambiente → sistema más robusto
- También útil en situaciones donde tenemos acceso a un modelo:
 - Modelo explícito y conocido, pero no puede ser tratado analíticamente
 - Sistema demasiado grande, almacenamiento de matrices y cálculos difícil o imposible → “Maldición de la dimensionalidad”

Aprendizaje por Refuerzo: Por Qué ?

- Única opción cuando no es posible construir un modelo:
 - Necesitamos aprender sobre el ambiente y tomar decisiones en tiempo real
 - Problema enfrentado por seres humanos y animales!
 - El comportamiento del ambiente está sujeto a cambios
- Menos suposiciones sobre el modelo del ambiente → sistema más robusto
- También útil en situaciones donde tenemos acceso a un modelo:
 - Modelo explícito y conocido, pero no puede ser tratado analíticamente
 - Sistema demasiado grande, almacenamiento de matrices y cálculos difícil o imposible → “Maldición de la dimensionalidad”
 - Modelo disponible solo a través de un simulador


Aprendizaje por Refuerzo: Cómo?

1) Estimación de la función valor $\hat{V}$




Aprendizaje por Refuerzo: Cómo?

- 1) Estimación de la función valor $\hat{V}$
 - Aprendizaje supervisado/Monte Carlo en el caso de MRP
 - Versiones de iteración de valor o iteración de políticas




Aprendizaje por Refuerzo: Cómo?

- 1) Estimación de la función valor $\hat{V}$
 - Aprendizaje supervisado/Monte Carlo en el caso de MRP
 - Versiones de iteración de valor o iteración de políticas
- 2) Optimización directa de la política
 - Consideramos $\hat{u}(x) = \mu(x, \psi)$




Aprendizaje por Refuerzo: Cómo?

- 1) Estimación de la función valor $\hat{V}$
 - Aprendizaje supervisado/Monte Carlo en el caso de MRP
 - Versiones de iteración de valor o iteración de políticas
- 2) Optimización directa de la política
 - Consideramos $\hat{u}(x) = \mu(x, \psi)$
 - Resolvemos $\max_{\psi \in \mathcal{R}^K} \mathbb{E} \left[\sum_{t=0}^{\infty} \alpha^t r_{\hat{u}(x_t, \psi)}(x_t) \right] = \max_{\psi \in \mathcal{R}^K} f(\psi)$




Aprendizaje por Refuerzo: Cómo?

- 1) Estimación de la función valor $\hat{V}$
 - Aprendizaje supervisado/Monte Carlo en el caso de MRP
 - Versiones de iteración de valor o iteración de políticas
- 2) Optimización directa de la política
 - Consideramos $\hat{u}(x) = \mu(x, \psi)$
 - Resolvemos $\max_{\psi \in \mathcal{R}^K} \mathbb{E} \left[\sum_{t=0}^{\infty} \alpha^t r_{\hat{u}(x_t, \psi)}(x_t) \right] = \max_{\psi \in \mathcal{R}^K} f(\psi)$
 - Descenso estocástico de gradientes



Aprendizaje por Refuerzo: Cómo?

- 1) Estimación de la función valor $\hat{V}$
 - Aprendizaje supervisado/Monte Carlo
 - Versiones de iteración de valor o iteración de políticas
- 2) Optimización directa de la política
 - Consideramos $\hat{u}(x) = \mu(x, \psi)$
 - Resolvemos $\max_{\psi \in \mathcal{R}^K} \mathbb{E} \left[\sum_{t=0}^{\infty} \alpha^t r_{\hat{u}(x_t, \psi)}(x_t) \right] = \max_{\psi \in \mathcal{R}^K} f(\psi)$
 - Descenso estocástico de gradientes
- 3) Métodos actor-crítico
 - Combinan $\hat{u}(x) = \mu(x, \psi)$ (actor) con estimación/aproximación de la función valor $\hat{V}$ (crítico)



Estimación de La Función Valor

- La función valor es definida implícitamente por la ecuación de Bellman:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

- Cómo estimarla a partir de datos?
- Empezamos con el caso de una política fija
 - MRP (proceso markoviano con recompensa)

Estimación de La Función Valor: Simulación Monte Carlo

- Con una política fija u :

$$V_u(x) = \mathbb{E} \left[\sum_{t=0}^{\infty} \alpha^t r_u(x_t) | x_0 = x \right]$$

- Si tenemos trayectoria $(x_0, r_0, x_1, r_1, \dots)$, tenemos muestras (x_i, R_i) , $i = 0, 1, \dots$ donde

$$R_i = \sum_{t=i}^{\infty} \alpha^{t-i} r_t$$

- Para cada estado x , con N_x muestras:

:

$$\hat{V}_u(x) = \frac{1}{N_x} \sum_{i: x_i = x} R_i$$

Simulación Monte Carlo: Versión Iterativa

- Para cada estado, debemos calcular

$$\hat{V}_u(x) = \frac{1}{N_x} \sum_{i=1}^{N_x} R_i$$

Simulación Monte Carlo: Versión Iterativa

- Para cada estado, debemos calcular

$$\begin{aligned}\hat{V}_u(x) &= \frac{1}{N_x} \sum_{i=1}^{N_x} R_i \\ &= \frac{N_x-1}{N_x} \left[\frac{1}{N_x-1} \sum_{i=1}^{N_x-1} R_i \right] + \frac{1}{N_x} R_{N_x}\end{aligned}$$

Simulación Monte Carlo: Versión Iterativa

- Para cada estado, debemos calcular

$$\begin{aligned}\hat{V}_u(x) &= \frac{1}{N_x} \sum_{i=1}^{N_x} R_i \\ &= \underbrace{\frac{N_x-1}{N_x} \left[\frac{1}{N_x-1} \sum_{i=1}^{N_x-1} R_i \right]}_{\text{estimativa anterior}} + \frac{1}{N_x} \underbrace{R_{N_x}}_{\text{nueva amuestra}}\end{aligned}$$

Simulación Monte Carlo: Versión Iterativa

- Para cada estado, debemos calcular

$$\begin{aligned}\hat{V}_u(x) &= \frac{1}{N_x} \sum_{i=1}^{N_x} R_i \\ &= \frac{N_x-1}{N_x} \underbrace{\left[\frac{1}{N_x-1} \sum_{i=1}^{N_x-1} R_i \right]}_{\text{estimativa anterior}} + \frac{1}{N_x} \underbrace{R_{N_x}}_{\text{nueva amuestra}}\end{aligned}$$

- Entonces: $\hat{V}_u^N(x) = (1 - \gamma_N) \hat{V}_u^{N-1}(x) + \gamma_N R_N$

Simulación Monte Carlo: Versión Iterativa

- Para cada estado, debemos calcular

$$\begin{aligned}\hat{V}_u(x) &= \frac{1}{N_x} \sum_{i=1}^{N_x} R_i \\ &= \underbrace{\frac{N_x-1}{N_x} \left[\frac{1}{N_x-1} \sum_{i=1}^{N_x-1} R_i \right]}_{\text{estimativa anterior}} + \frac{1}{N_x} \underbrace{R_{N_x}}_{\text{nueva amuestra}}\end{aligned}$$

- Entonces:
$$\begin{aligned}\hat{V}_u^N(x) &= (1 - \gamma_N) \hat{V}_u^{N-1}(x) + \gamma_N R_N \\ &= \hat{V}_u^{N-1}(x) + \underbrace{\gamma_N \left(R_N - \hat{V}_u^{N-1}(x) \right)}_{\text{diferencia temporal}}\end{aligned}$$

TD-Learning

$$\hat{V}_u^N(x) = \hat{V}_u^{N-1}(x) + \gamma_N \left(R_N - \hat{V}_u^{N-1}(x) \right)$$

- Pero debemos seguir trayectoria por muchos periodos más antes de realizar la actualización, para poder estimar

$$R_N = \sum_{t=t_N}^{\infty} \alpha^{t-t_N} r_t$$

- Alternativa:

$$\begin{aligned} R_N &= r_{t_N} + \alpha \sum_{t=t_N+1}^{\infty} \alpha^{t-t_N-1} r_t \\ &\approx r_{t_N} + \alpha \hat{V}_u^N(y) \end{aligned}$$

donde y es el estado siguiente observado en la trayectoria.

TD-Learning

$$\hat{V}_u^N(x) = \hat{V}_u^{N-1}(x) + \gamma_N \left(r_N + \alpha \hat{V}_u^{N-1}(y) - \hat{V}_u^{N-1}(x) \right)$$

- Pero debemos seguir trayectoria por muchos periodos más antes de realizar la actualización, para poder estimar

$$R_N = \sum_{t=t_N}^{\infty} \alpha^{t-t_N} r_t$$

- Alternativa:

$$\begin{aligned} R_N &= r_{t_N} + \alpha \sum_{t=t_N+1}^{\infty} \alpha^{t-t_N-1} r_t \\ &\approx r_{t_N} + \alpha \hat{V}_u^N(y) \end{aligned}$$

donde y es el estado siguiente observado en la trayectoria.

TD-Learning

1. Inicializar $t = 0, V_0$

2. Observar (x_t, r_t, x_{t+1})

3. Actualizar

$$\hat{V}^{t+1}(x_t) = \hat{V}^t(x_t) + \gamma_t \left(r_t + \alpha \hat{V}^t(x_{t+1}) - \hat{V}^t(x_t) \right)$$

4. Actualizar $t = t + 1$, retornar al paso 2.

Un Obstáculo en RL

- En este curso, nos vamos a enfocar en RL basado en estimativas y aproximaciones de la función valor.



Un Obstáculo en RL

- En este curso, nos vamos a enfocar en RL basado en estimativas y aproximaciones de la función valor.



- Conceptualmente, dos pasos:
 - 1) Estimamos $\hat{V} \approx V^*$ a partir de $(x_i, a_i, r_i, x_i^+), i = 1, \dots, n$

Un Obstáculo en RL

- En este curso, nos vamos a enfocar en RL basado en estimativas y aproximaciones de la función valor.



- Conceptualmente, dos pasos:
 - 1) Estimamos $\hat{V} \approx V^*$ a partir de $(x_i, a_i, r_i, x_i^+), i = 1, \dots, n$
 - 2) Calculamos $\hat{u}$ a partir de $\hat{V}$: $\hat{u}(x) = \arg \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) \hat{V}(y) \right\}$

Un Obstáculo en RL

- En este curso, nos vamos a enfocar en RL basado en estimativas y aproximaciones de la función valor.



- Conceptualmente, dos pasos:
 - 1) Estimamos $\hat{V} \approx V^*$ a partir de $(x_i, a_i, r_i, x_i^+), i = 1, \dots, n$
 - 2) Calculamos $\hat{u}$ a partir de $\hat{V}$: $\hat{u}(x) = \arg \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) \hat{V}(y) \right\}$
- Problema: mismo que podamos completar el paso 1), el paso 2) requiere conocimiento de r y P .

Un Obstáculo en RL

- En este curso, nos vamos a enfocar en RL basado en estimativas y aproximaciones de la función valor.



- Conceptualmente, dos pasos:
 - 1) Estimamos $\hat{V} \approx V^*$ a partir de $(x_i, a_i, r_i, x_i^+), i = 1, \dots, n$
 - 2) Calculamos $\hat{u}$ a partir de $\hat{V}$: $\hat{u}(x) = \arg \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) \hat{V}(y) \right\}$
- Problema: mismo que podamos completar el paso 1), el paso 2) requiere conocimiento de r y P .
- Solución basada en la función Q

La Función Q

- Recordemos la ecuación de Bellman:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

- Vamos a definir

$$Q^*(x, a) = r_a(x) + \alpha \sum_y P_a(x, y) V^*(y)$$

La Función Q

- Recordemos la ecuación de Bellman:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

- Vamos a definir

$$Q^*(x, a) = r_a(x) + \alpha \sum_y P_a(x, y) V^*(y)$$

- Q^* satisface a otra ecuación de Bellman:

$$Q^*(x, a) = r_a(x) + \alpha \sum_y P_a(x, y) \max_{a' \in A} Q^*(y, a')$$

La Función Q

- Recordemos la ecuación de Bellman:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

- Vamos a definir

$$Q^*(x, a) = r_a(x) + \alpha \sum_y P_a(x, y) V^*(y)$$

- Q^* satisface a otra ecuación de Bellman:

$$Q^*(x, a) = r_a(x) + \alpha \sum_y P_a(x, y) \max_{a' \in A} Q^*(y, a')$$

- Con una aproximación de $\hat{Q} \approx Q^*$, podemos obtener una política:

$$\hat{u}(x) = \max_{a \in A} \hat{Q}(x, a)$$

Algoritmo de Robins-Monro

$$\begin{aligned} Q^*(x, a) &= r_a(x) + \alpha \sum_y P_a(x, y) \max_{a' \in A} Q^*(y, a') \\ &= \mathbb{E} \left[r_a(x) + \alpha \max_{a' \in A} Q^*(y, a') \mid y' \sim P_a(x, \cdot) \right] \end{aligned}$$

Algoritmo de Robins-Monro

$$\begin{aligned} Q^*(x, a) &= r_a(x) + \alpha \sum_y P_a(x, y) \max_{a' \in A} Q^*(y, a') \\ &= \mathbb{E} \left[r_a(x) + \alpha \max_{a' \in A} Q^*(y, a') \mid y' \sim P_a(x, \cdot) \right] \end{aligned}$$

- RL está basado en que se puede resolver esas ecuaciones utilizando muestras en vez del valor esperado.

Algoritmo de Robins-Monro

$$\begin{aligned} Q^*(x, a) &= r_a(x) + \alpha \sum_y P_a(x, y) \max_{a' \in A} Q^*(y, a') \\ &= \mathbb{E} \left[r_a(x) + \alpha \max_{a' \in A} Q^*(y, a') \mid y' \sim P_a(x, \cdot) \right] \end{aligned}$$

- RL está basado en que se puede resolver esas ecuaciones utilizando muestras en vez del valor esperado.
- La metodología que utilizamos para desarrollar nuestros algoritmos está basada en el algoritmo de Robins-Monro.

Q-Learning

$$\begin{aligned} Q^*(x, a) &= r_a(x) + \alpha \sum_y P_a(x, y) \max_{a' \in A} Q^*(y, a) \\ &= \mathbb{E} \left[r_a(x) + \alpha \max_{a' \in A} Q^*(y, a') \mid y' \sim P_a(x, \cdot) \right] \end{aligned}$$

Algoritmo Q-learning:

- Asumimos muestras $(x_i, a_i, r_i, x_i^+), i = 1, \dots$
- Inicializamos Q_0 según alguna regla (por ejemplo, 0)
- Para cada $i = 1, 2, \dots$, actualizamos:

$$Q_{i+1}(x_i, a_i) = Q_i(x_i, a_i) + \gamma_i \left[r_i + \alpha \max_{a' \in A} Q_i(x_i^+, a') - Q_i(x_i, a_i) \right]$$

$$Q_{i+1}(x, a) = Q_i(x, a) \quad \forall (x, a) \neq (x_i, a_i)$$

Q-Learning - Convergencia

$$Q_{i+1}(x_i, a_i) = Q_i(x_i, a_i) + \gamma_i \left[r_i + \alpha \max_{a' \in A} Q_i(x_i^+, a') - Q_i(x_i, a_i) \right]$$

- Definimos $\Gamma(x, a) = \{i : (x_i, a_i) = (x, a)\}$ como el conjunto de ocurrencias de (x, a) en nuestra muestra.
- Entonces $\lim_{i \rightarrow \infty} Q_i = Q^*$ si:

$$\sum_{i \in \Gamma(x, a)} \gamma_i = \infty, \quad \sum_{i \in \Gamma(x, a)} \gamma_i^2 < \infty, \quad \forall (x, a)$$

Q-Learning - Convergencia

$$Q_{i+1}(x_i, a_i) = Q_i(x_i, a_i) + \gamma_i \left[r_i + \alpha \max_{a' \in A} Q_i(x_i^+, a') - Q_i(x_i, a_i) \right]$$

- Definimos $\Gamma(x, a) = \{i : (x_i, a_i) = (x, a)\}$ como el conjunto de ocurrencias de (x, a) en nuestra muestra.
- Entonces $\lim_{i \rightarrow \infty} Q_i = Q^*$ si:

$$\sum_{i \in \Gamma(x, a)} \gamma_i = \infty, \quad \sum_{i \in \Gamma(x, a)} \gamma_i^2 < \infty, \quad \forall (x, a)$$

- todos los pares (x, a) tienen que ser visitados infinitas veces

Q-Learning - Convergencia

$$Q_{i+1}(x_i, a_i) = Q_i(x_i, a_i) + \gamma_i \left[r_i + \alpha \max_{a' \in A} Q_i(x_i^+, a') - Q_i(x_i, a_i) \right]$$

- Definimos $\Gamma(x, a) = \{i : (x_i, a_i) = (x, a)\}$ como el conjunto de ocurrencias de (x, a) en nuestra muestra.
- Entonces $\lim_{i \rightarrow \infty} Q_i = Q^*$ si:

$$\sum_{i \in \Gamma(x, a)} \gamma_i = \infty, \quad \sum_{i \in \Gamma(x, a)} \gamma_i^2 < \infty, \quad \forall (x, a)$$

- todos los pares (x, a) tienen que ser visitados infinitas veces
- no es necesario visitarlos en ningún orden específico
- retornaremos a ese punto...

Q-Learning - Intuición

$$Q_{i+1}(x_i, a_i) = Q_i(x_i, a_i) + \gamma_i \underbrace{\left[r_i + \alpha \max_{a' \in A} Q_i(x_i^+, a') - Q_i(x_i, a_i) \right]}_{\text{Diferencia temporal (TD)}}$$

- La actualización es intuitiva:
 - la diferencia temporal indica si la observación del valor de la acción a_i en el estado x_i es mejor o peor que nuestra estimativa $Q_i(x_i, a_i)$
 - la estimativa es actualizada en proporción a la diferencia temporal

Q-Learning - Intuición

$$Q_{i+1}(x_i, a_i) = Q_i(x_i, a_i) + \underbrace{\gamma_i \left[r_i + \alpha \max_{a' \in A} Q_i(x_i^+, a') - Q_i(x_i, a_i) \right]}_{\text{Diferencia temporal (TD)}}$$

- La actualización es intuitiva:
 - la diferencia temporal indica si la observación del valor de la acción a_i en el estado x_i es mejor o peor que nuestra estimativa $Q_i(x_i, a_i)$
 - la estimativa es actualizada en proporción a la diferencia temporal
- Q-learning es una versión estocástica de iteración de valor

Exploración vs Explotación

- Q-learning requiere que todos los pares (x, a) de estados y acciones sean visitados infinitas veces
- En la práctica, debemos decidir cómo explorar
- Una opción: elegir siempre la acción “greedy”

$$a_t = \arg \max_a Q_t(x_t, a)$$

- Pero con esa acción, partes del espacio de estados y acciones pueden no ser visitados...
- Solución: políticas ϵ -greedy:

$$a_t = \begin{cases} \arg \max_a Q_t(x_t, a) & \text{con probabilidad } 1 - \epsilon \\ \text{aleatoria} & \text{con probabilidad } \epsilon \end{cases}$$