

Toma Secuencial de Decisiones y Aprendizaje por Refuerzo

Daniela Pucci de Farias

Universidad Torcuato Di Tella

June 2025

Contenidos del Curso

- ▶ Modelado y resolución de problemas de toma de decisiones secuenciales
 - ▶ Procesos markovianos de decisión
 - ▶ Aprendizaje por refuerzo
- ▶ Cronograma:
 - ▶ Clase 1: Introducción a toma de decisiones secuenciales y aprendizaje por refuerzo. Procesos markovianos. Aplicaciones al estudio de regímenes de mercado y análisis de participación de empresas en el mercado.
 - ▶ Clase 2: Procesos Markovianos con Recompensa y Procesos Markovianos de Decisión (MDP). MDPs con horizonte finito. Modelado y algoritmos. Aplicación a precificación dinámica.
 - ▶ Clase 3: MDPs con horizonte infinito. Modelado y algoritmos. Aplicación a optimización de portafolios.
 - ▶ Clase 4: Aprendizaje por refuerzo. Métodos computacionales exactos y por simulación.
 - ▶ Clase 5: Sistemas de larga escala. Métodos de aproximación. Aplicación a precificación de opciones americanas.

Horas de Consulta

- ▶ Anteriormente a las clases teóricas, de 18 a 19h.
- ▶ Ubicación:
 - ▶ 2/6: Aula SV403 (4to piso, edificio Sáenz Valiente).
 - ▶ 9/6: Aula SV402 (4to piso, edificio Sáenz Valiente).
 - ▶ 23/6: Sala 4 (4to piso, edificio ALCORTA).
 - ▶ 30/6: Aula SV101 (1er piso, edificio Sáenz Valiente).
 - ▶ 7/7: Aula SV101 (1er piso, edificio Sáenz Valiente).

Criterio de Evaluación



La nota estará basada en el siguiente esquema de ponderación:

- ▶ Participación en clase, asistencia y puntualidad: 10%
- ▶ Trabajo práctico grupal: 40%
 - ▶ formación de los grupos: 9 de junio
 - ▶ Propuesta de proyecto: 30 de junio
 - ▶ Presentación oral (15 minutos) y relatorio final: 31 de julio
- ▶ Tareas individuales (2 tareas): 50%
 - ▶ Tarea 1: asignada el 2 de junio, fecha de entrega el 16 de junio
 - ▶ Tarea 2: asignada el 9 de junio, fecha de entrega el 23 de junio
- ▶ Tareas y código python (Google Colab) deben ser entregados por el campus virtual

Clase 1


- ▶ Introducción a Toma de Decisiones Secuenciales y Aprendizaje por Refuerzo
- ▶ Procesos Markovianos
 - ▶ Definición
 - ▶ Propiedades
 - ▶ Ejemplos

Aprendizaje Automático (Machine Learning)




Aprendizaje Automático (Machine Learning)

Aprendizaje No Supervisado




- Agrupamiento (clustering)
- Reducción de dimensionalidad
- Extracción de características

Aprendizaje Supervisado



- Clasificación
- Regresión

Aprendizaje Por Refuerzo (Reinforcement Learning)



Aprendizaje Por Refuerzo (Reinforcement Learning)



- ▶ Aprendizaje de estrategias óptimas para situaciones que se extienden en el tiempo
- ▶ La función de “refuerzo” puede ser diseñada para expresar diferentes objetivos
- ▶ Modelo de toma de decisiones secuenciales:
 - ▶ Ambiente tiene un estado que cambia al largo del tiempo
 - ▶ Evolución del estado afectada por decisiones
 - ▶ Función de “refuerzo” afectada por estado y decisiones

Aprendizaje Por Refuerzo (Reinforcement Learning)

- ▶ Dificultades extras vs otros tipos de aprendizaje:
 - ▶ Las consecuencias de una acción actual pueden impactar en el futuro
 - ▶ No hay una señal directa midiendo ese impacto, solo la recompensa inmediata
 - ▶ El ambiente puede ser desconocido
 - ▶ Necesidad de aprender un modelo del ambiente y la acción
 - ▶ Potencialmente muchas acciones posibles
 - ▶ Hay que encontrar una forma eficiente de explorar las acciones

Aprendizaje Por Refuerzo - Juegos

TD-Gammon (1992)



AlphaGo (2015-2017)



Aprendizaje Por Refuerzo - Robótica



Reinforcement Learning in Healthcare: A Survey

Chao Yu, Jiming Liu, *Fellow, IEEE*, and Shamim Nemat


Abstract—As a subfield of machine learning, *reinforcement learning* (RL) aims at empowering one's capabilities in behavioural decision making by using interaction experience with the world and an evaluative feedback. Unlike traditional supervised learning methods that usually rely on one-shot, exhaustive and supervised reward signals, RL tackles with sequential decision making problems with sampled, evaluative and delayed feedback simultaneously. Such distinctive features make RL technique a suitable candidate for developing powerful solutions in a variety of healthcare domains, where diagnosing decisions or treatment regimes are usually characterized by a prolonged and sequential procedure. This survey discusses the broad applications of RL techniques in healthcare domains, in order to provide the research community with systematic understanding of theoretical foundations, enabling methods and techniques, existing challenges, and new insights of this emerging paradigm. By first briefly examining theoretical foundations and key techniques in RL research from efficient and representational directions, we then provide an overview of RL applications in healthcare domains ranging from dynamic treatment regimes in chronic diseases and critical care, automated medical diagnosis from both unstructured and structured clinical data, as well as many other control or scheduling domains that have infiltrated many aspects of a healthcare system. Finally, we summarize the challenges and open issues in current research, and point out some potential solutions and directions for future research.

Index Terms—Reinforcement Learning, Healthcare, Dynamic Treatment Regimes, Critical Care, Chronic Disease, Automated Diagnosis.

feedback and the new state from the environment. The goal of the agent is to learn an optimal policy (i.e., a mapping from the states to the actions) that maximizes the accumulated reward it receives over time. Therefore, agents in RL do not receive direct instructions regarding which action they should take, instead they must learn which actions are the best through trial-and-error interactions with the environment. This adaptive closed-loop feature renders RL distinct from traditional supervised learning methods for regression or classification, in which a list of correct labels must be provided, or from unsupervised learning approaches to dimensionality reduction or density estimation, which aim at finding hidden structures in a collection of example data [11]. Moreover, in comparison with other traditional control-based methods, RL does not require a well-represented mathematical model of the environment, but develops a control policy directly from experience to predict states and rewards during a learning procedure. Since the design of RL is letting an agent controller interact with the system, unknown and time-varying dynamics as well as changing performance requirements can be naturally accounted for by the controller [15]. Lastly, RL is uniquely suited to systems with inherent time delays, in which decisions are performed without immediate knowledge of effectiveness, but evaluated by a long-term future reward.

The above features naturally make RL an attractive solution

Aprendizaje Por Refuerzo - Medicina




Aprendizaje Por Refuerzo - Procesamiento de Lenguaje Natural



Aprendizaje Por Refuerzo - Vehículos Autónomos




Aprendizaje Por Refuerzo - Sistemas de Energia



Aprendizaje Por Refuerzo

- ▶ Marketing (campañas A/B, subastas)
- ▶ Gestión de recursos
- ▶ Finanzas
- ▶ Gestión de cadenas de suministro (supply chain management)
- ▶ Precios dinámicos
- ▶ ...

Toma Secuencial de Decisiones



- ▶ Cómo describir el problema matemáticamente?
- ▶ Aprendizaje por refuerzo basado en Procesos de Decisión Markovianos (Markov Decision Processes - MDPs)

Procesos Markovianos


- ▶ Ejemplo: cómo representar condiciones de mercado?
- ▶ En cada semana, uno de tres posibles estados
- ▶ Cómo evolucionan en el tiempo?
 - ▶ Descripción en términos de probabilidad
 - ▶ En este curso, nos enfocaremos en procesos a tiempo discreto

Procesos Markovianos

Cómo definir matemáticamente el proceso de regímenes de mercado?

- ▶ Espacio de estados S :
 - ▶ $S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$
 - ▶ Estados pueden ser discretos o continuos
- ▶ Evolución en el tiempo
 - ▶ Matriz de transición P :

$$P = \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}$$



Tupla (S, P) define el proceso markoviano

- ▶ Si el número de estados es finito, también decimos cadena markoviana.

Propiedad de Markov

“El futuro del proceso markoviano depende solamente del estado presente.”


- ▶ Proceso de Markov: tupla (S, P)
- ▶ Estados $s_0, s_1, s_2, \dots$ ($s_t \in S$ for $t = 0, 1, 2, \dots$)
- ▶ $\text{Prob}(s_{t+1} = s | s_0, s_1, \dots, s_t) = \text{Prob}(s_{t+1} = s | s_t)$
 - ▶ El estado s_t contiene toda la información relevante para el futuro del proceso
 - ▶ Si conocemos s_t , podemos olvidar $s_{t-1}, s_{t-2}, \dots, s_0$.
 - ▶ $\text{Prob}(s_{t+1} = s | s_t = s') = P(s, s')$
 - ▶ Por ejemplo:

$$\text{Prob}(s_{t+1} = \mathbf{Bajista} | s_t = \mathbf{Alcista}) = P(\mathbf{Alcista}, \mathbf{Bajista}) = 0.075$$

Propiedad de Markov

$$S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$$

$$P = \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}$$




Cuál es la probabilidad de tener un mercado **bajista** en la **próxima semana**

1. después de haber tenido un mercado **alcista** en las últimas 5 **semanas**?
2. después de haber tenido un mercado **alcista** en la última **semana**, y **bajista** en las 4 anteriores?

Distribución Probabilística de Estados

$$S = \{\mathbf{Alcista}, \mathbf{Bajista}, \mathbf{Estable}\}$$

$$P = \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}$$



Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? En 10 semanas?

- Se puede responder a esas preguntas más fácilmente con álgebra lineal!

Distribución Probabilística de Estados

Vamos a representar una distribución probabilística de estados con la variable π_t :

$$\pi_t(s) = \text{Prob}(s_t = s).$$

En nuestro ejemplo, si consideramos que esta semana corresponde a $t = 0$, tenemos $\text{Prob}(s_0 = \mathbf{Altista}) = 0$, $\text{Prob}(s_0 = \mathbf{Bajista}) = 1$, $\text{Prob}(s_0 = \mathbf{Estable}) = 0$.

Entonces:

$$\pi_0 = \begin{bmatrix} 0 & 1 & 0 \end{bmatrix}$$

π_0 es la distribución inicial de estados en el proceso markoviano.

Resulta que $\pi_{t+1} = \pi_t P$ y $\pi_t = \pi_0 P^t$.

Distribución Probabilística de Estados

Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? En 10 semanas?

Resulta que $\pi_t = \pi_0 P^t$.

$$\begin{aligned}\pi_1 &= \pi_0 P \\ &= \begin{bmatrix} 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix} \\ &= \begin{bmatrix} 0.15 & 0.8 & 0.05 \end{bmatrix}\end{aligned}$$

Prob($s_1 = \mathbf{Bajista} | s_0 = \mathbf{Bajista}$) = 0.8

$$\begin{aligned}\pi_2 &= \pi_0 P^2 \\ &= \begin{bmatrix} 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}^2 \\ &= \begin{bmatrix} 0.2675 & 0.66375 & 0.06875 \end{bmatrix}\end{aligned}$$

Distribución Probabilística de Estados

Cuál es la frecuencia de semanas alcistas, bajistas y estables en ese mercado?

Buscamos la **distribución estacionaria** de ese proceso.

- ▶ Tenemos $\pi_{t+1} = \pi_t P$ y estacionariedad implica $\pi_{t+1} = \pi_t = \pi$.
- ▶ Queremos resolver $\pi = \pi P$.
- ▶ Si el número de estados es finito, siempre existe una solución, pero no es necesariamente única.



$$\begin{aligned}\pi_{\infty} &= \pi_0 P^{\infty} \\ &= \begin{bmatrix} 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0.9 & 0.075 & 0.025 \\ 0.15 & 0.8 & 0.05 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}^{\infty} \\ &\approx \begin{bmatrix} 0.625 & 0.3125 & 0.0625 \end{bmatrix}\end{aligned}$$

En ese mercado, **62.5%** de las semanas son alcistas, **31.25%** son bajistas, y **6.25%** son estables.

Ejemplo: Google PageRank

Cuando hacemos una búsqueda en Google, las páginas que satisfacen a nuestras condiciones son presentadas en orden de importancia.


Cómo determinar importancia/ranking?



Ejemplo: Participación en El Mercado

Cadenas markovianas son frecuentemente utilizadas para modelar el comportamiento de usuarios de proveedores adversarios y predecir la participación en el mercado de esos proveedores al largo del tiempo.

- p_{ij} = probabilidad que usuario de proveedor i cambie a proveedor j



Ejemplo: Participación en El Mercado

Table 4: Respondents Brand Switching Behavior

Gains and Losses	Mobile Telecom Operators						Total
	M	V	T	E	A	G	
M	290	38	24	2	36	15	405
V	80	91	22	4	32	6	235
T	83	17	101	4	21	11	237
E	9	6	11	4	0	0	30
A	72	22	21	2	87	5	209
G	38	9	13	1	21	32	114

Source: Author's Computation (2013)

“Prediction of Subscribers’ Brand Switching Behaviour and Ergodic Market Share of Network Service Providers in Ghana Using Markov Chain Model”, Ezekiel Nortey

- ▶ Participación actual derivada de totales
- ▶ Matriz de transición P derivada de la misma forma

Ejemplo: Participación en El Mercado

- Tenemos:

$$\pi_0 = \begin{bmatrix} 0.329 & 0.191 & 0.193 & 0.024 & 0.170 & 0.093 \end{bmatrix}$$

$$P = \begin{bmatrix} 0.716 & 0.094 & 0.059 & 0.005 & 0.089 & 0.037 \\ 0.340 & 0.387 & 0.094 & 0.017 & 0.136 & 0.026 \\ 0.350 & 0.072 & 0.426 & 0.017 & 0.089 & 0.046 \\ 0.300 & 0.200 & 0.367 & 0.133 & 0.000 & 0.000 \\ 0.344 & 0.105 & 0.100 & 0.010 & 0.416 & 0.024 \\ 0.333 & 0.079 & 0.114 & 0.009 & 0.184 & 0.281 \end{bmatrix}$$

- Analisamos el comportamiento de esa cadena markoviana en Python

Ejemplo: Participación en El Mercado

