

Aprendizaje por Refuerzo Métodos Computacionales

Daniela Pucci de Farias

Universidad Torcuato Di Tella

June 2025

Clase 4

- ▶ Computación en MDPs
 - ▶ Iteración de valor
 - ▶ Iteración de política

Clase 4

- ▶ Computación en MDPs
 - ▶ Iteración de valor
 - ▶ Iteración de política
- ▶ Desafíos en MDPs
 - ▶ Incertidumbre y/o complejidad del ambiente
 - ▶ “Curse of dimensionality” (la maldición de la dimensionalidad)

Clase 4

- ▶ Computación en MDPs
 - ▶ Iteración de valor
 - ▶ Iteración de política
- ▶ Desafíos en MDPs
 - ▶ Incertidumbre y/o complejidad del ambiente
 - ▶ “Curse of dimensionality” (la maldición de la dimensionalidad)
- ▶ Métodos de Aprendizaje por Refuerzo
 - ▶ Simulación Monte Carlo
 - ▶ TD-Learning
 - ▶ Q-Learning

Revisión: MDPs

- ▶ MDP: tupla (S, A, P, r)

Revisión: MDPs

- ▶ MDP: tupla (S, A, P, r)
- ▶ Ecuación de Bellman y función valor:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

Revisión: MDPs

- ▶ MDP: tupla (S, A, P, r)
- ▶ Ecuación de Bellman y función valor:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

- ▶ Función de política óptima:

$$u^*(x) = \arg \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

Revisión: MDPs

- ▶ MDP: tupla (S, A, P, r)
- ▶ Ecuación de Bellman y función valor:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

- ▶ Función de política óptima:

$$u^*(x) = \arg \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

- ▶ Algoritmos para resolver la ecuación de Bellman:
 - ▶ iteración de valor
 - ▶ iteración de política

Iteración de Valor

1. Hacemos $t = 0$. Inicializamos $V_0(x)$ con un valor arbitrario, por ejemplo $V_0(x) = 0 \forall x$.
2. Hacemos $t = t + 1$. Calculamos
$$V_{t+1}(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_t(y) \right\}.$$
3. Utilizando un criterio de convergencia para V_t , decidimos si parar o volver al paso 2.

Iteración de Valor

1. Hacemos $t = 0$. Inicializamos $V_0(x)$ con un valor arbitrario, por ejemplo $V_0(x) = 0 \forall x$.
2. Hacemos $t = t + 1$. Calculamos
$$V_{t+1}(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_t(y) \right\}.$$
3. Utilizando un criterio de convergencia para V_t , decidimos si parar o volver al paso 2.

Iteración de Valor

1. Hacemos $t = 0$. Inicializamos $V_0(x)$ con un valor arbitrario, por ejemplo $V_0(x) = 0 \forall x$.
2. Hacemos $t = t + 1$. Calculamos
$$V_{t+1}(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_t(y) \right\}.$$
3. Utilizando un criterio de convergencia para V_t , decidimos si parar o volver al paso 2.

Iteración de Valor

1. Hacemos $t = 0$. Inicializamos $V_0(x)$ con un valor arbitrario, por ejemplo $V_0(x) = 0 \forall x$.
2. Hacemos $t = t + 1$. Calculamos
$$V_{t+1}(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_t(y) \right\}.$$
3. Utilizando un criterio de convergencia para V_t , decidimos si parar o volver al paso 2.
 - Por ejemplo, $\max_x |V_t(x) - V_{t-1}(x)| < \epsilon$ para algún $\epsilon > 0$

Iteración de Política

1. Hacemos $k = 0$. Empezamos con una política arbitraria u_0 .
2. Evaluamos la función valor V_{u_k} asociada con la política u_k . Para eso, debemos resolver:


$$V_{u_k}(x) = r_{u_k}(x) + \alpha \sum_y P_{u_k}(x, y) V_{u_k}(y)$$

Calculamos una nueva política u_{k+1} , que será la **política codiciosa** con respecto a V_{u_k} :

$$u_{k+1}(x) = \arg \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_{u_k}(y) \right\}$$

3. Si $u_k = u_{k+1}$, paramos. Si no, hacemos $t = t + 1$ y volvemos al paso 2.

Ejemplo: Ruta de Casa a La Universidad



Ejemplo: Ruta de Casa a La Universidad

- ▶ Modelo MDP:

Ejemplo: Ruta de Casa a La Universidad

- ▶ Modelo MDP:
 - ▶ Estado = posición en el mapa, en las esquinas $x = (i,j)$

Ejemplo: Ruta de Casa a La Universidad

- ▶ Modelo MDP:

- ▶ Estado = posición en el mapa, en las esquinas $x = (i, j)$
- ▶ Acciones = desplazamiento, una cuadra por vez:

$$A = \{(0, 1), (0, -1), (-1, 0), (1, 0)\} \equiv \{N, S, O, E\}$$

Ejemplo: Ruta de Casa a La Universidad

- ▶ Modelo MDP:

- ▶ Estado = posición en el mapa, en las esquinas $x = (i, j)$
- ▶ Acciones = desplazamiento, una cuadra por vez:

$$A = \{(0, 1), (0, -1), (-1, 0), (1, 0)\} \equiv \{N, S, O, E\}$$

- ▶ Transición (determinística):

$$x_{t+1} = \begin{cases} x + a & \text{if } x_t \neq x^* \\ x^* & \text{if } x_t = x^* \end{cases}$$

Ejemplo: Ruta de Casa a La Universidad

- ▶ Modelo MDP:

- ▶ Estado = posición en el mapa, en las esquinas $x = (i, j)$
- ▶ Acciones = desplazamiento, una cuadra por vez:

$$A = \{(0, 1), (0, -1), (-1, 0), (1, 0)\} \equiv \{N, S, O, E\}$$

- ▶ Transición (determinística):

$$x_{t+1} = \begin{cases} x + a & \text{if } x_t \neq x^* \\ x^* & \text{if } x_t = x^* \end{cases}$$

- ▶ Recompensa (castigo, en este caso):

$$r_a(x) = \begin{cases} E_w [\textit{tiempo}(x, x + a, w)] & \text{if } x \neq x^* \\ 0 & \text{if } x = x^* \end{cases}$$

Ejemplo: Ruta de Casa a La Universidad

- ▶ Modelo MDP:

- ▶ Estado = posición en el mapa, en las esquinas $x = (i, j)$
- ▶ Acciones = desplazamiento, una cuadra por vez:

$$A = \{(0, 1), (0, -1), (-1, 0), (1, 0)\} \equiv \{N, S, O, E\}$$

- ▶ Transición (determinística):

$$x_{t+1} = \begin{cases} x + a & \text{if } x_t \neq x^* \\ x^* & \text{if } x_t = x^* \end{cases}$$

- ▶ Recompensa (castigo, en este caso):

$$r_a(x) = \begin{cases} E_w [\text{tiempo}(x, x + a, w)] & \text{if } x \neq x^* \\ 0 & \text{if } x = x^* \end{cases}$$

- ▶ Criterio de optimalidad:

$$\min_u E \left[\sum_{t=0}^{\infty} r_u(x_t) \right].$$

Ejemplo: Ruta de Casa a La Universidad

- ▶ Modelo MDP:

- ▶ Estado = posición en el mapa, en las esquinas $x = (i, j)$
- ▶ Acciones = desplazamiento, una cuadra por vez:

$$A = \{(0, 1), (0, -1), (-1, 0), (1, 0)\} \equiv \{N, S, O, E\}$$

- ▶ Transición (determinística):

$$x_{t+1} = \begin{cases} x + a & \text{if } x_t \neq x^* \\ x^* & \text{if } x_t = x^* \end{cases}$$

- ▶ Recompensa (castigo, en este caso):

$$r_a(x) = \begin{cases} E_w [\text{tiempo}(x, x + a, w)] & \text{if } x \neq x^* \\ 0 & \text{if } x = x^* \end{cases}$$


- ▶ Criterio de optimalidad:

$$\min_u E \left[\sum_{t=0}^{\infty} r_u(x_t) \right].$$

- ▶ Implementación en Python de iteración de valor e iteración de políticas

Interpretación


- Diagrama para iteración de política



- Algoritmo actor-crítico

Interpretación


- ▶ Diagrama para iteración de política



- ▶ Algoritmo actor-crítico
 - ▶ **Actor** selecciona una política u_k (por ejemplo, codiciosa con respecto a $V_{u_{k-1}}$;

Interpretación


- ▶ Diagrama para iteración de política



- ▶ Algoritmo actor-crítico
 - ▶ **Actor** selecciona una política u_k (por ejemplo, codiciosa con respecto a $V_{u_{k-1}}$;
 - ▶ **Crítico** evalúa la política, generando la función valor V_{u_k}

Interpretación


- ▶ Diagrama para iteración de política



- ▶ Algoritmo actor-crítico
 - ▶ **Actor** selecciona una política u_k (por ejemplo, codiciosa con respecto a $V_{u_{k-1}}$;
 - ▶ **Crítico** evalúa la política, generando la función valor V_{u_k}
- ▶ En iteración de política, V_u es la función valor exacta de u .

Interpretación


- ▶ Diagrama para iteración de política



- ▶ Algoritmo actor-crítico
 - ▶ **Actor** selecciona una política u_k (por ejemplo, codiciosa con respecto a $V_{u_{k-1}}$;
 - ▶ **Crítico** evalúa la política, generando la función valor V_{u_k}
- ▶ En iteración de política, V_u es la función valor exacta de u .
- ▶ Se puede reemplazar V_u con una aproximación $\tilde{V}_u$. Muchos algoritmos de RL tienen esa forma.

Interpretación

- ▶ Diagrama para iteración de política



- ▶ Algoritmo actor-crítico
 - ▶ **Actor** selecciona una política u_k (por ejemplo, codiciosa con respecto a $V_{u_{k-1}}$;
 - ▶ **Crítico** evalúa la política, generando la función valor V_{u_k}
- ▶ En iteración de política, V_u es la función valor exacta de u .
- ▶ Se puede reemplazar V_u con una aproximación $\tilde{V}_u$. Muchos algoritmos de RL tienen esa forma.
- ▶ Iteración de valor puede ser interpretada como un caso límite de actor-crítico:
 - ▶ u_k es la política codiciosa con respecto a V_{k-1}
 - ▶ la evaluación se vuelve
$$\tilde{V}_{u_k}(x) \equiv V_k = r_{u_k}(x) + \alpha \sum_y P_{u_k}(x, y) V_{k-1}(y)$$

Desafíos Para Aplicación de MDPs

- ▶ MDPs representan un paradigma que permite modelar y, en principio, encontrar estrategias óptimas para una amplia gama de situaciones.

Desafíos Para Aplicación de MDPs

- ▶ MDPs representan un paradigma que permite modelar y, en principio, encontrar estrategias óptimas para una amplia gama de situaciones.
- ▶ Pero... en la práctica hay varios desafíos.

Desafíos Para Aplicación de MDPs

- ▶ MDPs representan un paradigma que permite modelar y, en principio, encontrar estrategias óptimas para una amplia gama de situaciones.
- ▶ Pero... en la práctica hay varios desafíos.
- ▶ Ejemplos:

Desafíos Para Aplicación de MDPs

- ▶ MDPs representan un paradigma que permite modelar y, en principio, encontrar estrategias óptimas para una amplia gama de situaciones.
- ▶ Pero... en la práctica hay varios desafíos.
- ▶ Ejemplos:
 - ▶ Precificación personalizada: en principio, un e-commerce podría ajustar precios para cada usuario individualmente

Desafíos Para Aplicación de MDPs

- ▶ MDPs representan un paradigma que permite modelar y, en principio, encontrar estrategias óptimas para una amplia gama de situaciones.
- ▶ Pero... en la práctica hay varios desafíos.
- ▶ Ejemplos:
 - ▶ Precificación personalizada: en principio, un e-commerce podría ajustar precios para cada usuario individualmente
 - ▶ Probabilidad de que el usuario acepte un determinado precio no es conocida de antemano

Desafíos Para Aplicación de MDPs

- ▶ MDPs representan un paradigma que permite modelar y, en principio, encontrar estrategias óptimas para una amplia gama de situaciones.
- ▶ Pero... en la práctica hay varios desafíos.
- ▶ Ejemplos:
 - ▶ Precificación personalizada: en principio, un e-commerce podría ajustar precios para cada usuario individualmente
 - ▶ Probabilidad de que el usuario acepte un determinado precio no es conocida de antemano
 - ▶ Gestión de relaciones con clientes: tomar decisiones de contacto o retención según el estado del cliente

Desafíos Para Aplicación de MDPs

- ▶ MDPs representan un paradigma que permite modelar y, en principio, encontrar estrategias óptimas para una amplia gama de situaciones.
- ▶ Pero... en la práctica hay varios desafíos.
- ▶ Ejemplos:
 - ▶ Precificación personalizada: en principio, un e-commerce podría ajustar precios para cada usuario individualmente
 - ▶ Probabilidad de que el usuario acepte un determinado precio no es conocida de antemano
 - ▶ Gestión de relaciones con clientes: tomar decisiones de contacto o retención según el estado del cliente
 - ▶ El estado emocional del cliente (satisfecho, dudoso, a punto de irse) no se puede observar directamente, solo hay observaciones indirectas

Desafíos Para Aplicación de MDPs

- ▶ MDPs representan un paradigma que permite modelar y, en principio, encontrar estrategias óptimas para una amplia gama de situaciones.
- ▶ Pero... en la práctica hay varios desafíos.
- ▶ Ejemplos:
 - ▶ Precificación personalizada: en principio, un e-commerce podría ajustar precios para cada usuario individualmente
 - ▶ Probabilidad de que el usuario acepte un determinado precio no es conocida de antemano
 - ▶ Gestión de relaciones con clientes: tomar decisiones de contacto o retención según el estado del cliente
 - ▶ El estado emocional del cliente (satisfecho, dudoso, a punto de irse) no se puede observar directamente, solo hay observaciones indirectas
 - ▶ Gestión de inventario con múltiples productos:

Desafíos Para Aplicación de MDPs

- ▶ MDPs representan un paradigma que permite modelar y, en principio, encontrar estrategias óptimas para una amplia gama de situaciones.
- ▶ Pero... en la práctica hay varios desafíos.
- ▶ Ejemplos:
 - ▶ Precificación personalizada: en principio, un e-commerce podría ajustar precios para cada usuario individualmente
 - ▶ Probabilidad de que el usuario acepte un determinado precio no es conocida de antemano
 - ▶ Gestión de relaciones con clientes: tomar decisiones de contacto o retención según el estado del cliente
 - ▶ El estado emocional del cliente (satisfecho, dudoso, a punto de irse) no se puede observar directamente, solo hay observaciones indirectas
 - ▶ Gestión de inventario con múltiples productos:
 - ▶ Tanto el espacio de estados (nivel de inventario de cada producto) y de acciones (cuánto más pedir de cada producto) crecen exponencialmente con el número de productos

Desafíos Para la Aplicación de MDPs

Información Parcial

Desafíos Para la Aplicación de MDPs

Información Parcial

1. Parámetros del modelo desconocidos: probabilidades de transición y recompensas

Desafíos Para la Aplicación de MDPs

Información Parcial

1. Parámetros del modelo desconocidos: probabilidades de transición y recompensas
2. Estado x no siempre puede ser observado.

Desafíos Para la Aplicación de MDPs

Información Parcial

1. Parámetros del modelo desconocidos: probabilidades de transición y recompensas
2. Estado x no siempre puede ser observado.
 - ▶ observaciones $h(x, w)$ con ruido w

Desafíos Para la Aplicación de MDPs

Información Parcial

1. Parámetros del modelo desconocidos: probabilidades de transición y recompensas
2. Estado x no siempre puede ser observado.
 - ▶ observaciones $h(x, w)$ con ruido w
 - ▶ POMDP: proceso markoviano de decisión parcialmente observable

Desafíos Para la Aplicación de MDPs

Información Parcial

1. Parámetros del modelo desconocidos: probabilidades de transición y recompensas
2. Estado x no siempre puede ser observado.
 - ▶ observaciones $h(x, w)$ con ruido w
 - ▶ POMDP: proceso markoviano de decisión parcialmente observable

Complejidad del Sistema

Desafíos Para la Aplicación de MDPs

Información Parcial

1. Parámetros del modelo desconocidos: probabilidades de transición y recompensas
2. Estado x no siempre puede ser observado.
 - ▶ observaciones $h(x, w)$ con ruido w
 - ▶ POMDP: proceso markoviano de decisión parcialmente observable

Complejidad del Sistema

- 3 “Maldición de la dimensionalidad”

Desafíos Para la Aplicación de MDPs

Información Parcial

1. Parámetros del modelo desconocidos: probabilidades de transición y recompensas
2. Estado x no siempre puede ser observado.
 - ▶ observaciones $h(x, w)$ con ruido w
 - ▶ POMDP: proceso markoviano de decisión parcialmente observable

Complejidad del Sistema

- 3 “Maldición de la dimensionalidad”
 - ▶ Número de estados exponencial en el número de variables de estado

Desafíos Para la Aplicación de MDPs

Información Parcial

1. Parámetros del modelo desconocidos: probabilidades de transición y recompensas
2. Estado x no siempre puede ser observado.
 - ▶ observaciones $h(x, w)$ con ruido w
 - ▶ POMDP: proceso markoviano de decisión parcialmente observable

Complejidad del Sistema

- 3 “Maldición de la dimensionalidad”
 - ▶ Número de estados exponencial en el número de variables de estado
 - ▶ Dificultades para almacenar P y r y calcular V^*

Desafíos Para la Aplicación de MDPs

Información Parcial

1. Parámetros del modelo desconocidos: probabilidades de transición y recompensas
2. Estado x no siempre puede ser observado.
 - ▶ observaciones $h(x, w)$ con ruido w
 - ▶ POMDP: proceso markoviano de decisión parcialmente observable

Complejidad del Sistema

- 3 “Maldición de la dimensionalidad”
 - ▶ Número de estados exponencial en el número de variables de estado
 - ▶ Dificultades para almacenar P y r y calcular V^*
 - ▶ Número de acciones exponencial en el número de variables de acción

Desafíos Para la Aplicación de MDPs

Información Parcial

1. Parámetros del modelo desconocidos: probabilidades de transición y recompensas
2. Estado x no siempre puede ser observado.
 - ▶ observaciones $h(x, w)$ con ruido w
 - ▶ POMDP: proceso markoviano de decisión parcialmente observable

Complejidad del Sistema

- 3 “Maldición de la dimensionalidad”
 - ▶ Número de estados exponencial en el número de variables de estado
 - ▶ Dificultades para almacenar P y r y calcular V^*
 - ▶ Número de acciones exponencial en el número de variables de acción
 - ▶
$$\max_{a \in A} \left\{ r_a(x) + \sum_y P_a(x, y) V^*(y) \right\}$$

Desafíos Para la Aplicación de MDPs

Información Parcial

1. Parámetros del modelo desconocidos: probabilidades de transición y recompensas $\Rightarrow$ **aprendizaje**
2. Estado x no siempre puede ser observado.
 - ▶ observaciones $h(x, w)$ con ruido w
 - ▶ POMDP: proceso markoviano de decisión parcialmente observable

Complejidad del Sistema

3 “Maldición de la dimensionalidad”

- ▶ Número de estados exponencial en el número de variables de estado
 - ▶ Dificultades para almacenar P y r y calcular V^*
- ▶ Número de acciones exponencial en el número de variables de acción
 - ▶
$$\max_{a \in A} \left\{ r_a(x) + \sum_y P_a(x, y) V^*(y) \right\}$$

Desafíos Para la Aplicación de MDPs

Información Parcial

1. Parámetros del modelo desconocidos: probabilidades de transición y recompensas $\Rightarrow$ **aprendizaje**
2. Estado x no siempre puede ser observado.
 - ▶ observaciones $h(x, w)$ con ruido w
 - ▶ POMDP: proceso markoviano de decisión parcialmente observable

Complejidad del Sistema

- 3 “Maldición de la dimensionalidad”
 - ▶ Número de estados exponencial en el número de variables de estado
 - ▶ Dificultades para almacenar P y r y calcular V^*
 - ▶ Número de acciones exponencial en el número de variables de acción
 - ▶
$$\max_{a \in A} \left\{ r_a(x) + \sum_y P_a(x, y) V^*(y) \right\}$$

$\Rightarrow$ **generalización**

Desafíos Para la Aplicación de MDPs

Información Parcial

1. Parámetros del modelo desconocidos: probabilidades de transición y recompensas $\Rightarrow$ **aprendizaje**
2. Estado x no siempre puede ser observado.
 - ▶ observaciones $h(x, w)$ con ruido w
 - ▶ POMDP: proceso markoviano de decisión parcialmente observable $\Rightarrow$ **en principio, se convierte en MDP; en la práctica, muy difícil**

Complejidad del Sistema


- 3 “Maldición de la dimensionalidad”
 - ▶ Número de estados exponencial en el número de variables de estado
 - ▶ Dificultades para almacenar P y r y calcular V^*
 - ▶ Número de acciones exponencial en el número de variables de acción
 - ▶
$$\max_{a \in A} \left\{ r_a(x) + \sum_y P_a(x, y) V^*(y) \right\}$$ $\Rightarrow$ **generalización**

Desafío: Incertidumbre Sobre Parámetros del Modelo

- ▶ La metodología está basada en información que no siempre tenemos, en especial las probabilidades de transición P y recompensas r .
- ▶ Qué hacer?

Desafío: Incertidumbre Sobre Parámetros del Modelo

- ▶ La metodología está basada en información que no siempre tenemos, en especial las probabilidades de transición P y recompensas r .
- ▶ Qué hacer?
- ▶ "Aprender" a partir de interacciones con el ambiente.
- ▶ Con qué datos?
 - ▶ trayectorias
 - ▶ solo una: $(x_0, a_0, r_0, x_1, a_1, r_1, \dots, x_N)$ (N puede ser infinito)
 - ▶ multiples: $(x_0^i, a_0^i, r_0^i, x_1^i, a_1^i, r_1^i, \dots, x_N^i)$, $i = 1, \dots, M$
 - ▶ tuplas (x^i, a^i, r^i, y^i) , $i = 1, 2, \dots, N$



Aprendizaje Por Refuerzo

Experiencias

(x^i, a^i, r^i, y^i)

$i = 1, 2, \dots, N$

- ▶ Cómo ir de los datos (x^i, a^i, r^i, y^i) , $i = \dots, N$ a una política de decisión $\hat{u}$?


Aprendizaje Por Refuerzo

Experiencias
 (x^i, a^i, r^i, y^i)
 $i = 1, 2, \dots, N$

Modelo
 $\hat{P}, \hat{r}$


- ▶ Cómo ir de los datos (x^i, a^i, r^i, y^i) , $i = \dots, N$ a una política de decisión $\hat{u}$?
- ▶ **Aprendiendo un modelo**

Aprendizaje Por Refuerzo



- ▶ Cómo ir de los datos (x^i, a^i, r^i, y^i) , $i = \dots, N$ a una política de decisión $\hat{u}$?
- ▶ **Aprendiendo un modelo**
 1. Aprendizaje supervisionado.

Aprendizaje Por Refuerzo




- ▶ Cómo ir de los datos (x^i, a^i, r^i, y^i) , $i = \dots, N$ a una política de decisión $\hat{u}$?

- ▶ **Aprendiendo un modelo**

1. Aprendizaje supervisado.


- ▶ Con $I_x = \{i : x^i = x\}$ y $I_{xy} = \{i : x^i = x, y^i = y\}$, podemos estimar: $\hat{P}(x, y) = \frac{|I_{x,y}|}{|I_x|}$, $\hat{r}(x) = \frac{\sum_{i \in I_x} r_i}{|I_x|}$.

Aprendizaje Por Refuerzo




- ▶ Cómo ir de los datos (x^i, a^i, r^i, y^i) , $i = \dots, N$ a una política de decisión $\hat{u}$?
- ▶ **Aprendiendo un modelo**
 1. Aprendizaje supervisado.
 - ▶ Con $I_x = \{i : x^i = x\}$ y $I_{xy} = \{i : x^i = x, y^i = y\}$, podemos estimar: $\hat{P}(x, y) = \frac{|I_{x,y}|}{|I_x|}$, $\hat{r}(x) = \frac{\sum_{i \in I_x} r_i}{|I_x|}$.
 - ▶ Alternativamente, podemos estimar parámetros del sistema que permiten calcular las transiciones y recompensas (función precio x demanda, retorno y volatilidad de un activo, etc.)

Aprendizaje Por Refuerzo



- ▶ Cómo ir de los datos (x^i, a^i, r^i, y^i) , $i = \dots, N$ a una política de decisión $\hat{u}$?
- ▶ **Aprendiendo un modelo**
 1. Aprendizaje supervisado.
 - ▶ Con $I_x = \{i : x^i = x\}$ y $I_{xy} = \{i : x^i = x, y^i = y\}$, podemos estimar: $\hat{P}(x, y) = \frac{|I_{x,y}|}{|I_x|}$, $\hat{r}(x) = \frac{\sum_{i \in I_x} r_i}{|I_x|}$.
 - ▶ Alternativamente, podemos estimar parámetros del sistema que permiten calcular las transiciones y recompensas (función precio x demanda, retorno y volatilidad de un activo, etc.)
 2. Programación dinámica con $\hat{P}, \hat{r} \Rightarrow \hat{V}, \hat{u}$

Aprendizaje Por Refuerzo



- ▶ Cómo ir de los datos (x^i, a^i, r^i, y^i) , $i = \dots, N$ a una política de decisión $\hat{u}$
- ▶ **Aprendiendo un modelo**
 1. Aprendizaje supervisado.
 - ▶ Con $I_x = \{i : x^i = x\}$ y $I_{xy} = \{i : x^i = x, y^i = y\}$, podemos estimar: $\hat{P}(x, y) = \frac{|I_{xy}|}{|I_x|}$, $\hat{r}(x) = \frac{\sum_{i \in I_x} r_i}{|I_x|}$.
 - ▶ Alternativamente, podemos estimar parámetros del sistema que permiten calcular las transiciones y recompensas (función precio x demanda, retorno y volatilidad de un activo, etc.)
 2. Programación dinámica con $\hat{P}, \hat{r} \Rightarrow \hat{V}, \hat{u}$
- ▶ **Sin modelo**
 - ▶ Aprender $\hat{V}$ y/o $\hat{u}$ directamente de los datos
 $\Rightarrow$ **aprendizaje por refuerzo**

Aprendizaje por Refuerzo: ¿Por Qué?

- ▶ **Esencial cuando no es posible construir un modelo explícito del ambiente**

Aprendizaje por Refuerzo: ¿Por Qué?

- ▶ **Esencial cuando no es posible construir un modelo explícito del ambiente**
 - ▶ Hay que aprender sobre el ambiente **mientras se actúa** en él

Aprendizaje por Refuerzo: ¿Por Qué?

- ▶ **Esencial cuando no es posible construir un modelo explícito del ambiente**
 - ▶ Hay que aprender sobre el ambiente **mientras se actúa** en él
 - ▶ Ejemplo: interacción secuencial con usuarios, robots, mercados

Aprendizaje por Refuerzo: ¿Por Qué?

- ▶ **Esencial cuando no es posible construir un modelo explícito del ambiente**
 - ▶ Hay que aprender sobre el ambiente **mientras se actúa** en él
 - ▶ Ejemplo: interacción secuencial con usuarios, robots, mercados
 - ▶ Situación enfrentada también por humanos y animales

Aprendizaje por Refuerzo: ¿Por Qué?

- ▶ **Esencial cuando no es posible construir un modelo explícito del ambiente**
 - ▶ Hay que aprender sobre el ambiente **mientras se actúa** en él
 - ▶ Ejemplo: interacción secuencial con usuarios, robots, mercados
 - ▶ Situación enfrentada también por humanos y animales
 - ▶ El comportamiento del ambiente puede ser **cambiante**

Aprendizaje por Refuerzo: ¿Por Qué?

- ▶ **Esencial cuando no es posible construir un modelo explícito del ambiente**
 - ▶ Hay que aprender sobre el ambiente **mientras se actúa** en él
 - ▶ Ejemplo: interacción secuencial con usuarios, robots, mercados
 - ▶ Situación enfrentada también por humanos y animales
 - ▶ El comportamiento del ambiente puede ser **cambiante**
 - ▶ No conviene asumir una dinámica fija

Aprendizaje por Refuerzo: ¿Por Qué?

- ▶ **Esencial cuando no es posible construir un modelo explícito del ambiente**
 - ▶ Hay que aprender sobre el ambiente **mientras se actúa** en él
 - ▶ Ejemplo: interacción secuencial con usuarios, robots, mercados
 - ▶ Situación enfrentada también por humanos y animales
 - ▶ El comportamiento del ambiente puede ser **cambiante**
 - ▶ No conviene asumir una dinámica fija
- ▶ **Reduce suposiciones fuertes sobre la dinámica → mayor robustez**

Aprendizaje por Refuerzo: ¿Por Qué?

- ▶ **Esencial cuando no es posible construir un modelo explícito del ambiente**
 - ▶ Hay que aprender sobre el ambiente **mientras se actúa** en él
 - ▶ Ejemplo: interacción secuencial con usuarios, robots, mercados
 - ▶ Situación enfrentada también por humanos y animales
 - ▶ El comportamiento del ambiente puede ser **cambiante**
 - ▶ No conviene asumir una dinámica fija
- ▶ **Reduce suposiciones fuertes sobre la dinámica → mayor robustez**
 - ▶ Aprende directamente de la experiencia, sin modelo paramétrico

Aprendizaje por Refuerzo: ¿Por Qué?

- ▶ **Esencial cuando no es posible construir un modelo explícito del ambiente**
 - ▶ Hay que aprender sobre el ambiente **mientras se actúa** en él
 - ▶ Ejemplo: interacción secuencial con usuarios, robots, mercados
 - ▶ Situación enfrentada también por humanos y animales
 - ▶ El comportamiento del ambiente puede ser **cambiante**
 - ▶ No conviene asumir una dinámica fija
- ▶ **Reduce suposiciones fuertes sobre la dinámica → mayor robustez**
 - ▶ Aprende directamente de la experiencia, sin modelo paramétrico
- ▶ **También útil cuando se dispone de un modelo, pero...**

Aprendizaje por Refuerzo: ¿Por Qué?

- ▶ **Esencial cuando no es posible construir un modelo explícito del ambiente**
 - ▶ Hay que aprender sobre el ambiente **mientras se actúa** en él
 - ▶ Ejemplo: interacción secuencial con usuarios, robots, mercados
 - ▶ Situación enfrentada también por humanos y animales
 - ▶ El comportamiento del ambiente puede ser **cambiante**
 - ▶ No conviene asumir una dinámica fija
- ▶ **Reduce suposiciones fuertes sobre la dinámica → mayor robustez**
 - ▶ Aprende directamente de la experiencia, sin modelo paramétrico
- ▶ **También útil cuando se dispone de un modelo, pero...**
 - ▶ El modelo es demasiado complejo para resolver analíticamente (por ejemplo, no lineal o estocástico)

Aprendizaje por Refuerzo: ¿Por Qué?

- ▶ **Esencial cuando no es posible construir un modelo explícito del ambiente**
 - ▶ Hay que aprender sobre el ambiente **mientras se actúa** en él
 - ▶ Ejemplo: interacción secuencial con usuarios, robots, mercados
 - ▶ Situación enfrentada también por humanos y animales
 - ▶ El comportamiento del ambiente puede ser **cambiante**
 - ▶ No conviene asumir una dinámica fija
- ▶ **Reduce suposiciones fuertes sobre la dinámica → mayor robustez**
 - ▶ Aprende directamente de la experiencia, sin modelo paramétrico
- ▶ **También útil cuando se dispone de un modelo, pero...**
 - ▶ El modelo es demasiado complejo para resolver analíticamente (por ejemplo, no lineal o estocástico)
 - ▶ El sistema tiene dimensión muy alta → “maldición de la dimensionalidad”

Aprendizaje por Refuerzo: ¿Por Qué?

- ▶ **Esencial cuando no es posible construir un modelo explícito del ambiente**
 - ▶ Hay que aprender sobre el ambiente **mientras se actúa** en él
 - ▶ Ejemplo: interacción secuencial con usuarios, robots, mercados
 - ▶ Situación enfrentada también por humanos y animales
 - ▶ El comportamiento del ambiente puede ser **cambiante**
 - ▶ No conviene asumir una dinámica fija
- ▶ **Reduce suposiciones fuertes sobre la dinámica → mayor robustez**
 - ▶ Aprende directamente de la experiencia, sin modelo paramétrico
- ▶ **También útil cuando se dispone de un modelo, pero...**
 - ▶ El modelo es demasiado complejo para resolver analíticamente (por ejemplo, no lineal o estocástico)
 - ▶ El sistema tiene dimensión muy alta → “maldición de la dimensionalidad”
 - ▶ El modelo solo está disponible como un **simulador** (caja negra)

Aprendizaje por Refuerzo: ¿Por Qué?

- ▶ **Esencial cuando no es posible construir un modelo explícito del ambiente**
 - ▶ Hay que aprender sobre el ambiente **mientras se actúa** en él
 - ▶ Ejemplo: interacción secuencial con usuarios, robots, mercados
 - ▶ Situación enfrentada también por humanos y animales
 - ▶ El comportamiento del ambiente puede ser **cambiante**
 - ▶ No conviene asumir una dinámica fija
- ▶ **Reduce suposiciones fuertes sobre la dinámica → mayor robustez**
 - ▶ Aprende directamente de la experiencia, sin modelo paramétrico
- ▶ **También útil cuando se dispone de un modelo, pero...**
 - ▶ El modelo es demasiado complejo para resolver analíticamente (por ejemplo, no lineal o estocástico)
 - ▶ El sistema tiene dimensión muy alta → “maldición de la dimensionalidad”
 - ▶ El modelo solo está disponible como un **simulador** (caja negra)
 - ▶ Ejemplo: videojuegos, simuladores de procesos industriales o financieros

Aprendizaje Por Refuerzo: Cómo?



1. Optimización directa de la política

Aprendizaje Por Refuerzo: Cómo?



1. Optimización directa de la política

- ▶ Consideramos $\hat{u}(x) = u(x, \psi)$ donde $\psi \in \mathbb{R}^K$ son parámetros a calibrar
 - ▶ Comprar más mercadería en cantidad $u(x, \psi) = \psi_0 1(x \leq \psi_1)$

Aprendizaje Por Refuerzo: Cómo?



1. Optimización directa de la política

- ▶ Consideramos $\hat{u}(x) = u(x, \psi)$ donde $\psi \in \mathbb{R}^K$ son parámetros a calibrar
 - ▶ Comprar más mercadería en cantidad $u(x, \psi) = \psi_0 \mathbf{1}(x \leq \psi_1)$
 - ▶ Ofrecer pasaje de avión a precio $u(x, \psi) = \psi_0 + \psi_1 t + \psi_2 x$

- ▶ Resolvemos $\max_{\psi \in \mathbb{R}^K} \mathbb{E} \left[\sum_{t=0}^{\infty} \alpha^t r_{u(x_t, \psi)}(x_t) \right] = \max_{\psi \in \mathbb{R}^K} f(\psi).$

Aprendizaje Por Refuerzo: Cómo?



1. Optimización directa de la política

- ▶ Consideramos $\hat{u}(x) = u(x, \psi)$ donde $\psi \in \mathbb{R}^K$ son parámetros a calibrar
 - ▶ Comprar más mercadería en cantidad $u(x, \psi) = \psi_0 \mathbf{1}(x \leq \psi_1)$
 - ▶ Ofrecer pasaje de avión a precio $u(x, \psi) = \psi_0 + \psi_1 t + \psi_2 x$
 - ▶ Bid para publicidad online: estado $x = (p, v) =$ estimativa actual de (probabilidad p de clic, valor esperado v de compras resultantes del clic), $\text{bid} = u(x, \psi) = \psi_0 + \psi_1 p + \psi_2 v$
- ▶ Resolvemos $\max_{\psi \in \mathbb{R}^K} \mathbb{E} \left[\sum_{t=0}^{\infty} \alpha^t r_{u(x_t, \psi)}(x_t) \right] = \max_{\psi \in \mathbb{R}^K} f(\psi)$.
- ▶ Utilizamos descenso estocástico de gradientes para realizar la optimización.

Aprendizaje Por Refuerzo: Cómo?



1. Optimización directa de la política

- ▶ Consideramos $\hat{u}(x) = u(x, \psi)$ donde $\psi \in \mathbb{R}^K$ son parámetros a calibrar
 - ▶ Comprar más mercadería en cantidad $u(x, \psi) = \psi_0 \mathbf{1}(x \leq \psi_1)$
 - ▶ Ofrecer pasaje de avión a precio $u(x, \psi) = \psi_0 + \psi_1 t + \psi_2 x$
 - ▶ Bid para publicidad online: estado $x = (p, v) =$ estimativa actual de (probabilidad p de clic, valor esperado v de compras resultantes del clic), bid $= u(x, \psi) = \psi_0 + \psi_1 p + \psi_2 v$
 - ▶ Estos ejemplos utilizan parametrizaciones lineales, pero podrían también ser no lineales, incluyendo redes neuronales.
- ▶ Resolvemos $\max_{\psi \in \mathbb{R}^K} \mathbb{E} \left[\sum_{t=0}^{\infty} \alpha^t r_{u(x_t, \psi)}(x_t) \right] = \max_{\psi \in \mathbb{R}^K} f(\psi)$.
- ▶ Utilizamos descenso estocástico de gradientes para realizar la optimización.

Aprendizaje Por Refuerzo: Cómo?



2. Estimación de la función valor

Aprendizaje Por Refuerzo: Cómo?



2. Estimación de la función valor

- ▶ Aprendizaje supervisado/Monte Carlo

Aprendizaje Por Refuerzo: Cómo?



2. Estimación de la función valor

- ▶ Aprendizaje supervisado/Monte Carlo
- ▶ Versiones de iteración de valor o iteración de políticas

Aprendizaje Por Refuerzo: Cómo?



2. Estimación de la función valor

- ▶ Aprendizaje supervisado/Monte Carlo
- ▶ Versiones de iteración de valor o iteración de políticas

3. Métodos actor-crítico

Aprendizaje Por Refuerzo: Cómo?



2. Estimación de la función valor

- ▶ Aprendizaje supervisado/Monte Carlo
- ▶ Versiones de iteración de valor o iteración de políticas

3. Métodos actor-crítico

- ▶ Combinan $\hat{u}(x) = u(x, \psi)$ (actor) con estimación/aproximación de la función valor $\hat{V}$ (crítico)

Aprendizaje Por Refuerzo: Cómo?



2. Estimación de la función valor

- ▶ Aprendizaje supervisado/Monte Carlo
- ▶ Versiones de iteración de valor o iteración de políticas

3. Métodos actor-crítico

- ▶ Combinan $\hat{u}(x) = u(x, \psi)$ (actor) con estimación/aproximación de la función valor $\hat{V}$ (crítico)
- ▶ Utilizados para bajar la variancia de optimización directa de la política

Estimación de La Función Valor

- ▶ La función valor es definida implícitamente por la ecuación de Bellman:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

- ▶ Cómo estimarla a partir de datos?

Estimación de La Función Valor

- ▶ La función valor es definida implícitamente por la ecuación de Bellman:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

- ▶ Cómo estimarla a partir de datos?
- ▶ Empezamos con el caso de una política fija

Estimación de La Función Valor

- ▶ La función valor es definida implícitamente por la ecuación de Bellman:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}$$

- ▶ Cómo estimarla a partir de datos?
- ▶ Empezamos con el caso de una política fija
 - ▶ proceso markoviano con recompensa (MRP)

Estimación de La Función Valor: Simulación Monte Carlo

- ▶ Con una política fija u , tenemos:

$$V(x) \equiv V_u(x) = \mathbb{E} \left[\sum_{t=0}^{\infty} \alpha^t r_u(x_t) | x_t = x \right]$$

Estimación de La Función Valor: Simulación Monte Carlo

- ▶ Con una política fija u , tenemos:

$$V(x) \equiv V_u(x) = \mathbb{E} \left[\sum_{t=0}^{\infty} \alpha^t r_u(x_t) | x_t = x \right]$$

- ▶ A partir de una trayectoria $(x_0, r_0, x_1, r_1, x_2, r_2, \dots)$, podemos construir muestras (x_t, R_t) , $t = 0, 1, \dots$ de la función V :

$$R_t = \sum_{\tau=1}^{\infty} \alpha^{\tau-t} r_{\tau}$$

Estimación de La Función Valor: Simulación Monte Carlo

- ▶ Con una política fija u , tenemos:

$$V(x) \equiv V_u(x) = \mathbb{E} \left[\sum_{t=0}^{\infty} \alpha^t r_u(x_t) | x_t = x \right]$$

- ▶ A partir de una trayectoria $(x_0, r_0, x_1, r_1, x_2, r_2, \dots)$, podemos construir muestras (x_t, R_t) , $t = 0, 1, \dots$ de la función V :

$$R_t = \sum_{\tau=1}^{\infty} \alpha^{\tau-t} r_{\tau}$$

- ▶ Para cada estado x visitado en la trayectoria, definimos $T_x = \{t : x_t = x\}$ y tenemos:

$$\hat{V}(x) = \frac{\sum_{t \in T_x} R_t}{|T_x|}$$

Bootstrapping

- ▶ Monte-Carlo se basa en muestras (x_t, R_t) , $t = 0, 1, \dots$ de la función V , donde $R_t = \sum_{\tau=1}^{\infty} \alpha^{\tau-t} r_{\tau}$

Bootstrapping

- ▶ Monte-Carlo se basa en muestras (x_t, R_t) , $t = 0, 1, \dots$ de la función V , donde $R_t = \sum_{\tau=1}^{\infty} \alpha^{\tau-t} r_{\tau}$
 - ▶ Solo podemos calcular las muestras después de una larga trayectoria

Bootstrapping

- ▶ Monte-Carlo se basa en muestras (x_t, R_t) , $t = 0, 1, \dots$ de la función V , donde $R_t = \sum_{\tau=1}^{\infty} \alpha^{\tau-t} r_{\tau}$
 - ▶ Solo podemos calcular las muestras después de una larga trayectoria
 - ▶ Las muestras tienen variancia que normalmente crece con el tamaño de la trayectoria

Bootstrapping

- ▶ Monte-Carlo se basa en muestras (x_t, R_t) , $t = 0, 1, \dots$ de la función V , donde $R_t = \sum_{\tau=1}^{\infty} \alpha^{\tau-t} r_{\tau}$
 - ▶ Solo podemos calcular las muestras después de una larga trayectoria
 - ▶ Las muestras tienen variancia que normalmente crece con el tamaño de la trayectoria
- ▶ Podemos utilizar **bootstrapping** observando las muestras se relacionan con la función valor:

$$R_t = \sum_{\tau=t}^{\infty} \alpha^{\tau-t} r_{\tau}$$

Bootstrapping

- ▶ Monte-Carlo se basa en muestras (x_t, R_t) , $t = 0, 1, \dots$ de la función V , donde $R_t = \sum_{\tau=1}^{\infty} \alpha^{\tau-t} r_{\tau}$
 - ▶ Solo podemos calcular las muestras después de una larga trayectoria
 - ▶ Las muestras tienen variancia que normalmente crece con el tamaño de la trayectoria
- ▶ Podemos utilizar **bootstrapping** observando las muestras se relacionan con la función valor:

$$\begin{aligned} R_t &= \sum_{\tau=t}^{\infty} \alpha^{\tau-t} r_{\tau} \\ &= r_t + \alpha \sum_{\tau=t+1}^{\infty} \alpha^{\tau-(t+1)} r_{\tau} \end{aligned}$$

Bootstrapping

- ▶ Monte-Carlo se basa en muestras (x_t, R_t) , $t = 0, 1, \dots$ de la función V , donde $R_t = \sum_{\tau=1}^{\infty} \alpha^{\tau-t} r_{\tau}$
 - ▶ Solo podemos calcular las muestras después de una larga trayectoria
 - ▶ Las muestras tienen variancia que normalmente crece con el tamaño de la trayectoria
- ▶ Podemos utilizar **bootstrapping** observando las muestras se relacionan con la función valor:

$$\begin{aligned} R_t &= \sum_{\tau=t}^{\infty} \alpha^{\tau-t} r_{\tau} \\ &= r_t + \alpha \sum_{\tau=t+1}^{\infty} \alpha^{\tau-(t+1)} r_{\tau} \\ &\approx r_t + \alpha [V(x_{t+1}) + \epsilon] \end{aligned}$$

Bootstrapping

- ▶ Monte-Carlo se basa en muestras (x_t, R_t) , $t = 0, 1, \dots$ de la función V , donde $R_t = \sum_{\tau=1}^{\infty} \alpha^{\tau-t} r_{\tau}$
 - ▶ Solo podemos calcular las muestras después de una larga trayectoria
 - ▶ Las muestras tienen variancia que normalmente crece con el tamaño de la trayectoria
- ▶ Podemos utilizar **bootstrapping** observando las muestras se relacionan con la función valor:

$$\begin{aligned} R_t &= \sum_{\tau=t}^{\infty} \alpha^{\tau-t} r_{\tau} \\ &= r_t + \alpha \sum_{\tau=t+1}^{\infty} \alpha^{\tau-(t+1)} r_{\tau} \\ &\approx r_t + \alpha [V(x_{t+1}) + \epsilon] \end{aligned}$$

- ▶ Podemos actualizar $\hat{V}(x_t)$ inmediatamente al observar la transición (x_t, a_t, r_t, x_{t+1}) :

$$\hat{V}(x_t) = (1 - \gamma_t) \hat{V}(x_t) + \gamma_t [r_t + \alpha \hat{V}(x_{t+1})]$$

donde γ_t es la **tasa de aprendizaje**.

TD-Learning

Algoritmo TD-Learning

1. Inicializamos $\hat{V}$ según alguna regla y hacemos $t = 1$.
2. Con observación (x_t, r_t, x_{t+1}) , actualizar

$$\hat{V}(x_t) = \hat{V}(x_t) + \gamma_t \left[r_t + \alpha \hat{V}(x_{t+1}) - \hat{V}(x_t) \right]$$

3. Hacemos $t = t + 1$ y retornamos al paso 2.

TD-Learning

Algoritmo TD-Learning

1. Inicializamos $\hat{V}$ según alguna regla y hacemos $t = 1$.
2. Con observación (x_t, r_t, x_{t+1}) , actualizar

$$\hat{V}(x_t) = \hat{V}(x_t) + \gamma_t \left[r_t + \alpha \hat{V}(x_{t+1}) - \hat{V}(x_t) \right]$$

3. Hacemos $t = t + 1$ y retornamos al paso 2.

- Observamos que

$$\mathbb{E} \left[r_t + \alpha \hat{V}^{t-1}(x_{t+1}) \right] = r(x_t) + \alpha \sum_y P(x, y) \hat{V}(y)$$

- TD-learning es una versión estocástica de iteración por valor

TD-Learning

Algoritmo TD-Learning

1. Inicializamos $\hat{V}$ según alguna regla y hacemos $t = 1$.
2. Con observación (x_t, r_t, x_{t+1}) , actualizar

$$\hat{V}(x_t) = \hat{V}(x_t) + \gamma_t \left[r_t + \alpha \hat{V}(x_{t+1}) - \hat{V}(x_t) \right]$$

3. Hacemos $t = t + 1$ y retornamos al paso 2.

- Observamos que

$$\mathbb{E} \left[r_t + \alpha \hat{V}^{t-1}(x_{t+1}) \right] = r(x_t) + \alpha \sum_y P(x, y) \hat{V}(y)$$

- TD-learning es una versión estocástica de iteración por valor
- Las muestras (x_t, r_t, x_{t+1}) , $t = 0, 1, \dots$ no necesitan ser parte de una trayectoria!

Un Obstáculo en RL

- ▶ En este curso, nos vamos a enfocar en RL basado en estimativas y aproximaciones de la función valor.



Un Obstáculo en RL


- ▶ En este curso, nos vamos a enfocar en RL basado en estimativas y aproximaciones de la función valor.



- ▶ Conceptualmente, dos pasos:

Un Obstáculo en RL


- ▶ En este curso, nos vamos a enfocar en RL basado en estimativas y aproximaciones de la función valor.



- ▶ Conceptualmente, dos pasos:
 1. Estimamos $V^* \approx \hat{V}$ a partir de (x^i, a^i, r^i, y^i) , $i = 1, 2, \dots$

Un Obstáculo en RL

- ▶ En este curso, nos vamos a enfocar en RL basado en estimativas y aproximaciones de la función valor.




- ▶ Conceptualmente, dos pasos:
 1. Estimamos $V^* \approx \hat{V}$ a partir de (x^i, a^i, r^i, y^i) , $i = 1, 2, \dots$
 2. Calculamos $\hat{u}$, la política codiciosa con respecto a $\hat{V}$:

$$\hat{u}(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) \hat{V}(y) \right\}.$$

Un Obstáculo en RL

- ▶ En este curso, nos vamos a enfocar en RL basado en estimativas y aproximaciones de la función valor.




- ▶ Conceptualmente, dos pasos:
 1. Estimamos $V^* \approx \hat{V}$ a partir de (x^i, a^i, r^i, y^i) , $i = 1, 2, \dots$
 2. Calculamos $\hat{u}$, la política codiciosa con respecto a $\hat{V}$:

$$\hat{u}(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) \hat{V}(y) \right\}.$$

- ▶ Problema: mismo que podamos completar el paso 1), el paso 2) requiere conocimiento de P y R .

Un Obstáculo en RL

- ▶ En este curso, nos vamos a enfocar en RL basado en estimativas y aproximaciones de la función valor.



- ▶ Conceptualmente, dos pasos:
 1. Estimamos $V^* \approx \hat{V}$ a partir de (x^i, a^i, r^i, y^i) , $i = 1, 2, \dots$
 2. Calculamos $\hat{u}$, la política codiciosa con respecto a $\hat{V}$:

$$\hat{u}(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) \hat{V}(y) \right\}.$$

- ▶ Problema: mismo que podamos completar el paso 1), el paso 2) requiere conocimiento de P y R .
- ▶ Solución basada en la **función** Q .

La Función Q

- Recordemos la ecuación de Bellman:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}.$$

La Función Q

- Recordemos la ecuación de Bellman:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}.$$

- Vamos a definir

$$Q^*(x, a) = r_a(x) + \alpha \sum_y P_a(x, y) V^*(y).$$

La Función Q

- Recordemos la ecuación de Bellman:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}.$$

- Vamos a definir

$$Q^*(x, a) = r_a(x) + \alpha \sum_y P_a(x, y) V^*(y).$$

- Q^* satisface a otra ecuación de Bellman:

$$Q^*(x, a) = r_a(x) + \alpha \sum_y P_a(x, y) \max_{a' \in A} Q^*(y, a').$$

La Función Q

- ▶ Recordemos la ecuación de Bellman:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}.$$

- ▶ Vamos a definir

$$Q^*(x, a) = r_a(x) + \alpha \sum_y P_a(x, y) V^*(y).$$

- ▶ Q^* satisface a otra ecuación de Bellman:

$$Q^*(x, a) = r_a(x) + \alpha \sum_y P_a(x, y) \max_{a' \in A} Q^*(y, a').$$

- ▶ Con una aproximación $Q^* \approx \hat{Q}$, podemos obtener una política:

$$\hat{u}(x) = \max_{a \in A} \hat{Q}(x, a).$$

La Función Q

- ▶ Recordemos la ecuación de Bellman:

$$V^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V^*(y) \right\}.$$

- ▶ Vamos a definir

$$Q^*(x, a) = r_a(x) + \alpha \sum_y P_a(x, y) V^*(y).$$

- ▶ Q^* satisface a otra ecuación de Bellman:

$$Q^*(x, a) = r_a(x) + \alpha \sum_y P_a(x, y) \max_{a' \in A} Q^*(y, a').$$

- ▶ Con una aproximación $Q^* \approx \hat{Q}$, podemos obtener una política:

$$\hat{u}(x) = \max_{a \in A} \hat{Q}(x, a).$$

- ▶ Podemos encontrar una aproximación $\hat{Q}$ a partir de datos utilizando TD-Learning. Con la función Q , ese método se denomina **Q-Learning**.

Q-Learning

1. Inicializar $\hat{Q}$ según alguna regla y hacemos $t = 1$.
2. Seleccionar acción a^i
3. Con observación (x^i, a^i, r^i, y^i) , actualizar

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]$$

4. Hacer $t = t + 1$ y retornar al paso 2.

Q-Learning - Intuición

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]$$

Q-Learning - Intuición

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \underbrace{\left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]}_{\text{diferencia temporal (TD)}}$$

Q-Learning - Intuición

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \underbrace{\left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]}_{\text{diferencia temporal (TD)}}$$

- La actualización es intuitiva

Q-Learning - Intuición

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \underbrace{\left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]}_{\text{diferencia temporal (TD)}}$$

- ▶ La actualización es intuitiva
 - ▶ la diferencia temporal indica si la observación del valor de la acción a^i en el estado x^i es mejor o peor que nuestra estimativa $Q(x_i, a_i)$

Q-Learning - Intuición

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \underbrace{\left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]}_{\text{diferencia temporal (TD)}}$$

- ▶ La actualización es intuitiva
 - ▶ la diferencia temporal indica si la observación del valor de la acción a^i en el estado x^i es mejor o peor que nuestra estimativa $Q(x_i, a_i)$
 - ▶ la estimativa es actualizada en proporción a la diferencia temporal

Q-Learning - Intuición

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \underbrace{\left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]}_{\text{diferencia temporal (TD)}}$$

- ▶ La actualización es intuitiva
 - ▶ la diferencia temporal indica si la observación del valor de la acción a^i en el estado x^i es mejor o peor que nuestra estimativa $Q(x_i, a_i)$
 - ▶ la estimativa es actualizada en proporción a la diferencia temporal
- ▶ Q-learning también es una versión estocástica de iteración de valor

Q-Learning - Convergencia

► Tenemos:

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]$$

Q-Learning - Convergencia

- ▶ Tenemos:

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]$$

- ▶ Definimos $I_{x,a} = \{i : (x^i, a^i) = (x, a)\}$ como el conjunto de ocurrencias de (x, a) en nuestra muestra.

Q-Learning - Convergencia

- ▶ Tenemos:

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]$$

- ▶ Definimos $I_{x,a} = \{i : (x^i, a^i) = (x, a)\}$ como el conjunto de ocurrencias de (x, a) en nuestra muestra.
- ▶ Entonces $\hat{Q} \rightarrow Q^*$ si:

$$\sum_{i \in I_{x,a}} \gamma_i = \infty, \quad \sum_{i \in I_{x,a}} \gamma_i^2 < \infty \quad \forall (x, a).$$

Q-Learning - Convergencia

- ▶ Tenemos:

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]$$

- ▶ Definimos $I_{x,a} = \{i : (x^i, a^i) = (x, a)\}$ como el conjunto de ocurrencias de (x, a) en nuestra muestra.
- ▶ Entonces $\hat{Q} \rightarrow Q^*$ si:

$$\sum_{i \in I_{x,a}} \gamma_i = \infty, \quad \sum_{i \in I_{x,a}} \gamma_i^2 < \infty \quad \forall (x, a).$$

- ▶ Observaciones:

Q-Learning - Convergencia

- ▶ Tenemos:

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]$$

- ▶ Definimos $I_{x,a} = \{i : (x^i, a^i) = (x, a)\}$ como el conjunto de ocurrencias de (x, a) en nuestra muestra.
- ▶ Entonces $\hat{Q} \rightarrow Q^*$ si:

$$\sum_{i \in I_{x,a}} \gamma_i = \infty, \quad \sum_{i \in I_{x,a}} \gamma_i^2 < \infty \quad \forall (x, a).$$

- ▶ Observaciones:
 - ▶ todos los pares (x, a) tienen que ser visitados "infinitas veces"

Q-Learning - Convergencia

- ▶ Tenemos:

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]$$

- ▶ Definimos $I_{x,a} = \{i : (x^i, a^i) = (x, a)\}$ como el conjunto de ocurrencias de (x, a) en nuestra muestra.
- ▶ Entonces $\hat{Q} \rightarrow Q^*$ si:

$$\sum_{i \in I_{x,a}} \gamma_i = \infty, \quad \sum_{i \in I_{x,a}} \gamma_i^2 < \infty \quad \forall (x, a).$$

- ▶ Observaciones:
 - ▶ todos los pares (x, a) tienen que ser visitados "infinitas veces"
 - ▶ no es necesario visitarlos en ningún orden específico

Q-Learning - Convergencia

- ▶ Tenemos:

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]$$

- ▶ Definimos $I_{x,a} = \{i : (x^i, a^i) = (x, a)\}$ como el conjunto de ocurrencias de (x, a) en nuestra muestra.
- ▶ Entonces $\hat{Q} \rightarrow Q^*$ si:

$$\sum_{i \in I_{x,a}} \gamma_i = \infty, \quad \sum_{i \in I_{x,a}} \gamma_i^2 < \infty \quad \forall (x, a).$$

- ▶ Observaciones:
 - ▶ todos los pares (x, a) tienen que ser visitados "infinitas veces"
 - ▶ no es necesario visitarlos en ningún orden específico
 - ▶ convergencia a Q^* asegurada sin necesidad de seguir una política específica

Exploración vs. Explotación

- ▶ En Q-learning, para garantizar convergencia teórica, es necesario que todos los pares (x, a) sean visitados infinitas veces.

Exploración vs. Explotación

- ▶ En Q-learning, para garantizar convergencia teórica, es necesario que todos los pares (x, a) sean visitados infinitas veces.
- ▶ En la práctica, debemos equilibrar **explotación** (usar lo que ya sabemos) con **exploración** (probar cosas nuevas)

Exploración vs. Explotación

- ▶ En Q-learning, para garantizar convergencia teórica, es necesario que todos los pares (x, a) sean visitados infinitas veces.
- ▶ En la práctica, debemos equilibrar **explotación** (usar lo que ya sabemos) con **exploración** (probar cosas nuevas)
- ▶ Si elegimos siempre la acción codiciosa:
 $a^i = \arg \max_{a \in A} \hat{Q}(x^i, a)$ corremos el riesgo de ignorar acciones que podrían ser mejores

Exploración vs. Explotación

- ▶ En Q-learning, para garantizar convergencia teórica, es necesario que todos los pares (x, a) sean visitados infinitas veces.
- ▶ En la práctica, debemos equilibrar **explotación** (usar lo que ya sabemos) con **exploración** (probar cosas nuevas)
- ▶ Si elegimos siempre la acción codiciosa:
 $a^i = \arg \max_{a \in A} \hat{Q}(x^i, a)$ corremos el riesgo de ignorar acciones que podrían ser mejores
- ▶ Solución clásica: **política ϵ -codiciosa**

$$a^i = \begin{cases} \arg \max_{a \in A} \hat{Q}^{i-1}(x^i, a) & \text{con probabilidad } 1 - \epsilon \\ \text{acción aleatoria} & \text{con probabilidad } \epsilon \end{cases}$$

Exploración vs. Explotación

- ▶ En Q-learning, para garantizar convergencia teórica, es necesario que todos los pares (x, a) sean visitados infinitas veces.
- ▶ En la práctica, debemos equilibrar **explotación** (usar lo que ya sabemos) con **exploración** (probar cosas nuevas)
- ▶ Si elegimos siempre la acción codiciosa:
 $a^i = \arg \max_{a \in A} \hat{Q}(x^i, a)$ corremos el riesgo de ignorar acciones que podrían ser mejores
- ▶ Solución clásica: **política ϵ -codiciosa**

$$a^i = \begin{cases} \arg \max_{a \in A} \hat{Q}^{i-1}(x^i, a) & \text{con probabilidad } 1 - \epsilon \\ \text{acción aleatoria} & \text{con probabilidad } \epsilon \end{cases}$$

- ▶ En general, ϵ puede decaer con el tiempo:

$$\epsilon_t = \frac{1}{1+t}, \quad \text{o bien: } \epsilon_t = \epsilon_0 \cdot \beta^t$$

Exploración vs. Explotación

- ▶ En Q-learning, para garantizar convergencia teórica, es necesario que todos los pares (x, a) sean visitados infinitas veces.
- ▶ En la práctica, debemos equilibrar **explotación** (usar lo que ya sabemos) con **exploración** (probar cosas nuevas)
- ▶ Si elegimos siempre la acción codiciosa:
 $a^i = \arg \max_{a \in A} \hat{Q}(x^i, a)$ corremos el riesgo de ignorar acciones que podrían ser mejores
- ▶ Solución clásica: **política ϵ -codiciosa**

$$a^i = \begin{cases} \arg \max_{a \in A} \hat{Q}^{i-1}(x^i, a) & \text{con probabilidad } 1 - \epsilon \\ \text{acción aleatoria} & \text{con probabilidad } \epsilon \end{cases}$$

- ▶ En general, ϵ puede decaer con el tiempo:

$$\epsilon_t = \frac{1}{1+t}, \quad \text{o bien: } \epsilon_t = \epsilon_0 \cdot \beta^t$$

- ▶ ¿Cuándo es conveniente mantener un poco de exploración incluso al final del entrenamiento?

Tasa de Aprendizaje

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]$$

Tasa de Aprendizaje

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]$$

- ▶ **¿Qué hace la tasa de aprendizaje γ_i ?**
 - ▶ Controla cuánto pesan las nuevas observaciones frente a lo aprendido previamente

Tasa de Aprendizaje

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]$$

- ▶ **¿Qué hace la tasa de aprendizaje γ_i ?**
 - ▶ Controla cuánto pesan las nuevas observaciones frente a lo aprendido previamente
- ▶ Para garantizar convergencia debemos tener:
 $\sum_{i \in I_{x,a}} \gamma_i = \infty, \sum_{i \in I_{x,a}} \gamma_i^2 < \infty \quad \forall (x, a).$

Tasa de Aprendizaje

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]$$

- ▶ **¿Qué hace la tasa de aprendizaje γ_i ?**
 - ▶ Controla cuánto pesan las nuevas observaciones frente a lo aprendido previamente
- ▶ Para garantizar convergencia debemos tener:
 $\sum_{i \in I_{x,a}} \gamma_i = \infty, \sum_{i \in I_{x,a}} \gamma_i^2 < \infty \quad \forall (x, a).$
- ▶ **Si γ_i decae demasiado lentamente:**
 - ▶ Aprendizaje rápido, pero inestable
 - ▶ Q puede oscilar mucho con recompensas ruidosas

Tasa de Aprendizaje

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]$$

- ▶ **¿Qué hace la tasa de aprendizaje γ_i ?**
 - ▶ Controla cuánto pesan las nuevas observaciones frente a lo aprendido previamente
- ▶ Para garantizar convergencia debemos tener:
 $\sum_{i \in I_{x,a}} \gamma_i = \infty, \sum_{i \in I_{x,a}} \gamma_i^2 < \infty \quad \forall (x, a).$
- ▶ **Si γ_i decae demasiado lentamente:**
 - ▶ Aprendizaje rápido, pero inestable
 - ▶ Q puede oscilar mucho con recompensas ruidosas
- ▶ **Si γ_i decae demasiado rápido:**
 - ▶ Aprendizaje lento, puede estancarse
 - ▶ Difícil adaptarse si el entorno cambia

Tasa de Aprendizaje

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]$$

- ▶ **¿Qué hace la tasa de aprendizaje γ_i ?**
 - ▶ Controla cuánto pesan las nuevas observaciones frente a lo aprendido previamente
- ▶ Para garantizar convergencia debemos tener:
 $\sum_{i \in I_{x,a}} \gamma_i = \infty, \sum_{i \in I_{x,a}} \gamma_i^2 < \infty \quad \forall (x, a).$
- ▶ **Si γ_i decae demasiado lentamente:**
 - ▶ Aprendizaje rápido, pero inestable
 - ▶ Q puede oscilar mucho con recompensas ruidosas
- ▶ **Si γ_i decae demasiado rápido:**
 - ▶ Aprendizaje lento, puede estancarse
 - ▶ Difícil adaptarse si el entorno cambia
- ▶ $\alpha_t(x, a) = \frac{1}{1+N_t(x,a)}$ satisface a esas condiciones. En la práctica, otras opciones pueden ser mejores.

Tasa de Aprendizaje

$$\hat{Q}(x^i, a^i) = \hat{Q}(x^i, a^i) + \gamma_i \left[r^i + \alpha \max_{a \in A} \hat{Q}(y^i, a) - \hat{Q}(x^i, a^i) \right]$$

- ▶ **¿Qué hace la tasa de aprendizaje γ_i ?**
 - ▶ Controla cuánto pesan las nuevas observaciones frente a lo aprendido previamente
- ▶ Para garantizar convergencia debemos tener:
 $\sum_{i \in I_{x,a}} \gamma_i = \infty, \sum_{i \in I_{x,a}} \gamma_i^2 < \infty \quad \forall (x, a).$
- ▶ **Si γ_i decae demasiado lentamente:**
 - ▶ Aprendizaje rápido, pero inestable
 - ▶ Q puede oscilar mucho con recompensas ruidosas
- ▶ **Si γ_i decae demasiado rápido:**
 - ▶ Aprendizaje lento, puede estancarse
 - ▶ Difícil adaptarse si el entorno cambia
- ▶ $\alpha_t(x, a) = \frac{1}{1+N_t(x,a)}$ satisface a esas condiciones. En la práctica, otras opciones pueden ser mejores.
- ▶ ¿Cuándo sería útil mantener una tasa de aprendizaje constante en lugar de decreciente?