

Toma de Decisiones Secuenciales y Aprendizaje por Refuerzo

Prof. Daniela Pucci de Farias

Universidad Torcuato di Tella
E-mail: danielapuccidefarias@gmail.com

Resumen y Objetivos del Curso

La toma de decisiones secuenciales bajo incertidumbre es un problema central en múltiples áreas de negocios, ingeniería, finanzas, operaciones y gestión. En este tipo de problemas, las decisiones tomadas en el presente afectan no solo los resultados inmediatos, sino también las opciones y estados futuros del sistema. Modelar y resolver este tipo de dinámicas requiere herramientas capaces de representar explícitamente la evolución temporal, la incertidumbre y el impacto acumulativo de las decisiones.

Uno de los marcos matemáticos más generales y poderosos para abordar este tipo de situaciones son los procesos markovianos de decisión (MDPs), que permiten modelar decisiones secuenciales en entornos inciertos de manera estructurada y computacionalmente tractable. Los MDPs han sido aplicados exitosamente en áreas tan diversas como gestión de inventarios, asignación de recursos, finanzas, marketing, logística, medicina, control de sistemas, robótica y plataformas digitales.

El aprendizaje por refuerzo (reinforcement learning) surge como una extensión computacional de este marco, enfocada en problemas donde el sistema debe aprender a tomar decisiones a partir de la interacción con el entorno. Este paradigma ha sido clave en aplicaciones modernas de inteligencia artificial como AlphaGo, vehículos autónomos, sistemas de recomendación y modelos de lenguaje.

El objetivo del curso es proveer un entendimiento profundo de la metodología de MDPs para toma de decisiones secuenciales bajo incertidumbre, así como una introducción a las ideas fundamentales del aprendizaje por refuerzo, permitiendo a los alumnos:

- formular situaciones reales como MDPs;
- resolver esos modelos utilizando métodos exactos y aproximados;
- comprender los fundamentos computacionales de los métodos de aprendizaje por refuerzo;
- interpretar resultados computacionales con el fin de aplicarlos de manera informada y segura en contextos prácticos.

Métodos y Materiales

Las clases consistirán en análisis teórico, modelado, solución y análisis de aplicaciones, e implementación computacional de algoritmos. La implementación computacional será en Python, por lo que es aconsejable experiencia previa con el lenguaje, especialmente pandas y numpy.

Prerrequisitos

Métodos Estadísticos Aplicados a los Negocios

Fundamentos de Algoritmos

Introducción a Análisis de Datos

Modelos de Decisión y/o Data Mining

Evaluación

La nota estará basada en el siguiente esquema de ponderación:

Participación en clase, asistencia y puntualidad: 10%

Trabajo práctico grupal: 40%

Tareas individuales (4 tareas): 50%

Los alumnos tienen 3 semanas desde que se publican las notas para solicitar una revisión del TP de la materia.

Participación en clase

La participación en clase es una parte importante del diseño del curso, por lo que la misma será permanentemente evaluada. La evaluación de tu participación estará basada principalmente en el nivel de la contribución en cuanto a su riqueza y a tu habilidad para colaborar en el progreso de la discusión.

Tareas y Trabajo práctico (TP)

Habrán cuatro tareas individuales y un trabajo práctico grupal, con fechas de entrega:

- Tarea 1: asignada el 2 de junio, fecha de entrega el 9 de junio
- Tarea 2: asignada el 9 de junio, fecha de entrega el 16 de junio
- Tarea 3: asignada el 23 de junio, fecha de entrega el 30 de junio
- Tarea 4: asignada el 30 de junio, fecha de entrega el 7 de julio
- TP: presentación oral y entrega el 27 de julio

A los efectos del curso, deberán formarse grupos de **a lo sumo 3 personas**. Para los TPs **no se admite colaboración entre miembros de distintos grupos**.

Se espera que todos los integrantes del grupo se comprometan y participen de manera equitativa en la resolución de los TPs. En caso de existir desavenencias entre los miembros, el estudiante afectado deberá comunicarlas al docente previo a la entrega de los mismos. Una vez realizada la entrega, no se admitirán objeciones sobre la participación de los integrantes del grupo.

Es requisito para aprobar el curso la aprobación del TP, para lo que se requiere un promedio mínimo de 60/100. El trabajo práctico no tiene recuperatorio. En caso de no aprobarse este ítem, se deberá recurrir a la materia.

Los trabajos deberán entregarse vía Campus Virtual **en un solo archivo doc o pdf y un notebook de Python**.

Bibliografía complementaria

- [Szepesvári, C. \(2010\). *Algorithms for Reinforcement Learning*. Synthesis Lectures on Artificial Intelligence and Machine Learning, 9. Springer.](#)
- [Sutton, R. S., & Barto, A. G. \(2018\). *Reinforcement learning: An introduction* \(2nd ed.\). The MIT Press.](#)
- [Bertsekas, D. P. \(2023\). *A Course in Reinforcement Learning*. Athena Scientific.](#)
- [TRao, A., & Jelvis, T. \(2022\). *Foundations of Reinforcement Learning with Applications in Finance*. Chapman & Hall/CRC Mathematics and Artificial Intelligence Series.](#)
- [Powell, W. \(2026\) *Sequential Decisions Analytics and Modeling*.](#)

Contenidos del Curso

Módulo 1. Introducción a la toma de decisiones secuenciales y procesos markovianos

Introducción al problema de toma de decisiones secuenciales bajo incertidumbre y a su formulación matemática mediante procesos markovianos. Distinción entre decisiones estáticas y dinámicas. Representación de problemas mediante el marco agente–ambiente. Procesos markovianos y procesos markovianos con recompensa (MRPs). Conceptos de estado, transición, recompensa y función valor. Aplicaciones a problemas de negocios y gestión, incluyendo control de stock, regímenes de mercado y análisis de participación de empresas en el mercado.

Lectura optativa

T. Ansah-Narh, E.N.N. Nortey, K.D. Amponsah. *Prediction of subscribers' brand switching behaviour and ergodic market share of network service providers in Ghana using Markov chain model*. Global Journal of Business Research, 2013

Módulo 2. Procesos markovianos de decisión (MDPs) y programación dinámica

Procesos markovianos de decisión (MDPs) como marco para modelar decisiones secuenciales bajo incertidumbre. Estados, acciones, transiciones dinámicas y recompensas. Horizonte finito e infinito. Función valor y políticas de decisión. Ecuación de Bellman. Métodos de resolución exactos, incluyendo inducción hacia atrás, iteración de valor e iteración de políticas. Factores de descuento y criterios de optimalidad. Diseño de la función de recompensa. Aplicaciones a precificación dinámica, revenue management y optimización de portafolios.

Módulo 3. Aprendizaje por refuerzo y métodos basados en simulación

Limitaciones de MDPs en entornos de gran escala o con dinámica desconocida. Aprendizaje por refuerzo como metodología para aprender decisiones a partir de datos e interacción con el entorno. Enfoques model-based y model-free. Estimación de funciones valor mediante métodos Monte Carlo y diferencias temporales. TD-learning y Q-learning. Función Q y aprendizaje de políticas óptimas. Introducción a arquitecturas de aproximación y al uso de simulación para resolver problemas secuenciales complejos. Aplicación a problemas de navegación y precificación de opciones.

Lecturas optativas

- [F. A. Longstaff and E. S. Schwartz, Valuing American Options by Simulation: A Simple Least-Squares Approach, Review of Financial Studies vol. 14, 2001.](#)
- [Li, Y., Szepesvari, C., & Schuurmans, D. \(2009\). Learning exercise policies for American options. Journal of Machine Learning Research, 5, 352-359.](#)