

Toma de Decisiones Secuenciales y Aprendizaje por Refuerzo

Daniela Pucci de Farias

Universidad Torcuato Di Tella

Clase 1

Toma de decisiones secuenciales

¿Qué creen que significa?

¿Dónde se utiliza?

- ▶ Ejemplos:
 - ▶ precios dinámicos
 - ▶ decisiones de inversión
 - ▶ gestión de inventario
 - ▶ control de producción

¿Dónde se utiliza?

- ▶ Ejemplos:
 - ▶ precios dinámicos
 - ▶ decisiones de inversión
 - ▶ gestión de inventario
 - ▶ control de producción
- ▶ Muchas decisiones importantes:
 - ▶ se toman a lo largo del tiempo
 - ▶ están sujetas a incertidumbre
 - ▶ tienen impacto sobre posibilidades y resultados futuros

¿Qué se llevan de este curso?

- ▶ Sin un buen marco:
 - ▶ decisiones miopes
 - ▶ reglas ad hoc

¿Qué se llevan de este curso?

- ▶ Sin un buen marco:
 - ▶ decisiones miopes
 - ▶ reglas ad hoc
- ▶ En este curso van a aprender a:
 - ▶ **estructurar** estos problemas
 - ▶ **evaluar** consecuencias futuras
 - ▶ **tomar decisiones de forma consistente**

Contenidos del Curso

- ▶ Modelado y resolución de problemas de toma de decisiones secuenciales

Contenidos del Curso

- ▶ Modelado y resolución de problemas de toma de decisiones secuenciales
 - ▶ Procesos markovianos de decisión
 - ▶ Aprendizaje por refuerzo

Contenidos del Curso

- ▶ Modelado y resolución de problemas de toma de decisiones secuenciales
 - ▶ Procesos markovianos de decisión
 - ▶ Aprendizaje por refuerzo
- ▶ Cronograma:

Contenidos del Curso

- ▶ Modelado y resolución de problemas de toma de decisiones secuenciales
 - ▶ Procesos markovianos de decisión
 - ▶ Aprendizaje por refuerzo
- ▶ Cronograma:
 - ▶ Clase 1: Introducción a toma de decisiones secuenciales y aprendizaje por refuerzo. Procesos markovianos. Aplicaciones al estudio de regímenes de mercado y análisis de participación de empresas en el mercado.

Contenidos del Curso

- ▶ Modelado y resolución de problemas de toma de decisiones secuenciales
 - ▶ Procesos markovianos de decisión
 - ▶ Aprendizaje por refuerzo
- ▶ Cronograma:
 - ▶ Clase 1: Introducción a toma de decisiones secuenciales y aprendizaje por refuerzo. Procesos markovianos. Aplicaciones al estudio de regímenes de mercado y análisis de participación de empresas en el mercado.
 - ▶ Clase 2: Procesos Markovianos con Recompensa y Procesos Markovianos de Decisión (MDP). MDPs con horizonte finito. Modelado y algoritmos. Aplicación a precificación dinámica.

Contenidos del Curso

- ▶ Modelado y resolución de problemas de toma de decisiones secuenciales
 - ▶ Procesos markovianos de decisión
 - ▶ Aprendizaje por refuerzo
- ▶ Cronograma:
 - ▶ Clase 1: Introducción a toma de decisiones secuenciales y aprendizaje por refuerzo. Procesos markovianos. Aplicaciones al estudio de regímenes de mercado y análisis de participación de empresas en el mercado.
 - ▶ Clase 2: Procesos Markovianos con Recompensa y Procesos Markovianos de Decisión (MDP). MDPs con horizonte finito. Modelado y algoritmos. Aplicación a precificación dinámica.
 - ▶ Clase 3: MDPs con horizonte infinito. Modelado y algoritmos. Aplicación a optimización de portafolios.

Contenidos del Curso

- ▶ Modelado y resolución de problemas de toma de decisiones secuenciales
 - ▶ Procesos markovianos de decisión
 - ▶ Aprendizaje por refuerzo
- ▶ Cronograma:
 - ▶ Clase 1: Introducción a toma de decisiones secuenciales y aprendizaje por refuerzo. Procesos markovianos. Aplicaciones al estudio de regímenes de mercado y análisis de participación de empresas en el mercado.
 - ▶ Clase 2: Procesos Markovianos con Recompensa y Procesos Markovianos de Decisión (MDP). MDPs con horizonte finito. Modelado y algoritmos. Aplicación a precificación dinámica.
 - ▶ Clase 3: MDPs con horizonte infinito. Modelado y algoritmos. Aplicación a optimización de portafolios.
 - ▶ Clase 4: Aprendizaje por refuerzo. Métodos computacionales exactos y por simulación.

Contenidos del Curso

- ▶ Modelado y resolución de problemas de toma de decisiones secuenciales
 - ▶ Procesos markovianos de decisión
 - ▶ Aprendizaje por refuerzo
- ▶ Cronograma:
 - ▶ Clase 1: Introducción a toma de decisiones secuenciales y aprendizaje por refuerzo. Procesos markovianos. Aplicaciones al estudio de regímenes de mercado y análisis de participación de empresas en el mercado.
 - ▶ Clase 2: Procesos Markovianos con Recompensa y Procesos Markovianos de Decisión (MDP). MDPs con horizonte finito. Modelado y algoritmos. Aplicación a precificación dinámica.
 - ▶ Clase 3: MDPs con horizonte infinito. Modelado y algoritmos. Aplicación a optimización de portafolios.
 - ▶ Clase 4: Aprendizaje por refuerzo. Métodos computacionales exactos y por simulación.
 - ▶ Clase 5: Sistemas de larga escala. Métodos de aproximación. Aplicación a precificación de opciones americanas.

Horas de Consulta

- ▶ Anteriormente a las clases teóricas, de 18 a 19h.
- ▶ Ubicación:
 - ▶ 2/6: Aula SV403 (4to piso, edificio Sáenz Valiente).
 - ▶ 9/6: Aula SV402 (4to piso, edificio Sáenz Valiente).
 - ▶ 23/6: Sala 4 (4to piso, edificio ALCORTA).
 - ▶ 30/6: Aula SV101 (1er piso, edificio Sáenz Valiente).
 - ▶ 7/7: Aula SV101 (1er piso, edificio Sáenz Valiente).

Criterio de Evaluación

La nota estará basada en el siguiente esquema de ponderación:

- ▶ Participación en clase, asistencia y puntualidad: 10 %

Criterio de Evaluación

La nota estará basada en el siguiente esquema de ponderación:

- ▶ Participación en clase, asistencia y puntualidad: 10 %
- ▶ Trabajo práctico grupal: 40 %

Criterio de Evaluación

La nota estará basada en el siguiente esquema de ponderación:

- ▶ Participación en clase, asistencia y puntualidad: 10 %
- ▶ Trabajo práctico grupal: 40 %
 - ▶ formación de los grupos: 9 de junio
 - ▶ Propuesta de proyecto: 30 de junio
 - ▶ Presentación oral (15 minutos) y relatorio final: 31 de julio

Criterio de Evaluación

La nota estará basada en el siguiente esquema de ponderación:

- ▶ Participación en clase, asistencia y puntualidad: 10 %
- ▶ Trabajo práctico grupal: 40 %
 - ▶ formación de los grupos: 9 de junio
 - ▶ Propuesta de proyecto: 30 de junio
 - ▶ Presentación oral (15 minutos) y relatorio final: 31 de julio
- ▶ Tareas individuales (2 tareas): 50 %

Criterio de Evaluación

La nota estará basada en el siguiente esquema de ponderación:

- ▶ Participación en clase, asistencia y puntualidad: 10 %
- ▶ Trabajo práctico grupal: 40 %
 - ▶ formación de los grupos: 9 de junio
 - ▶ Propuesta de proyecto: 30 de junio
 - ▶ Presentación oral (15 minutos) y relatorio final: 31 de julio
- ▶ Tareas individuales (2 tareas): 50 %
 - ▶ Tarea 1: asignada el 2 de junio, fecha de entrega el 16 de junio
 - ▶ Tarea 2: asignada el 9 de junio, fecha de entrega el 23 de junio

Criterio de Evaluación

La nota estará basada en el siguiente esquema de ponderación:

- ▶ Participación en clase, asistencia y puntualidad: 10 %
- ▶ Trabajo práctico grupal: 40 %
 - ▶ formación de los grupos: 9 de junio
 - ▶ Propuesta de proyecto: 30 de junio
 - ▶ Presentación oral (15 minutos) y relatorio final: 31 de julio
- ▶ Tareas individuales (2 tareas): 50 %
 - ▶ Tarea 1: asignada el 2 de junio, fecha de entrega el 16 de junio
 - ▶ Tarea 2: asignada el 9 de junio, fecha de entrega el 23 de junio
- ▶ Tareas y código python (Google Colab) deben ser entregados por el campus virtual

Modelando Toma de Decisiones Secuenciales

- ▶ Ejemplos:
 - ▶ precios dinámicos
 - ▶ decisiones de inversión
 - ▶ gestión de inventario
 - ▶ control de producción
 - ▶ agentes que interactúan con un entorno

Modelando Toma de Decisiones Secuenciales

- ▶ Ejemplos:
 - ▶ precios dinámicos
 - ▶ decisiones de inversión
 - ▶ gestión de inventario
 - ▶ control de producción
 - ▶ agentes que interactúan con un entorno
- ▶ Una pregunta:

¿Cómo estructuramos estos problemas?


Modelando Toma de Decisiones Secuenciales

- ▶ Ejemplos:
 - ▶ precios dinámicos
 - ▶ decisiones de inversión
 - ▶ gestión de inventario
 - ▶ control de producción
 - ▶ agentes que interactúan con un entorno
- ▶ Una pregunta:


¿Cómo estructuramos estos problemas?
- ▶ Idealmente:

un único marco que sirva para todos


Un Marco Para Toma de Decisiones Secuenciales




Un Marco Para Toma de Decisiones Secuenciales



Un Marco Para Toma de Decisiones Secuenciales




Un Marco Para Toma de Decisiones Secuenciales




¿Cómo representar el problema matemáticamente?

Procesos Markovianos de Decisión (MDPs)




- Componentes para un modelo de toma de decisiones secuenciales:

Procesos Markovianos de Decisión (MDPs)



- La función de recompensa puede ser diseñada para expresar diferentes objetivos

Procesos Markovianos de Decisión (MDPs)



- ▶ La función de recompensa puede ser diseñada para expresar diferentes objetivos
- ▶ Toma de decisiones secuenciales: Desarrollo de estrategias óptimas para situaciones que se extienden en el tiempo, en ambientes sujetos a incertidumbre.
 - ▶ Aprendizaje por refuerzo/reinforcement learning: toma de decisiones secuenciales donde aprendizaje se hace necesario por ausencia de modelo y/o complejidad del problema
- ▶ Para formalizar la descripción de MDPs, vamos a empezar con un **ambiente autónomo**, y gradualmente agregar

Modelando Un Ambiente Autónomo

- ▶ Ejemplo: cómo representar condiciones de mercado?


Modelando Un Ambiente Autónomo

- ▶ Ejemplo: cómo representar condiciones de mercado?
- ▶ En cada semana, uno de tres posibles estados




Modelando Un Ambiente Autónomo

- ▶ Ejemplo: cómo representar condiciones de mercado?
- ▶ En cada semana, uno de tres posibles estados
- ▶ Cómo evolucionan en el tiempo?




Modelando Un Ambiente Autónomo

- ▶ Ejemplo: cómo representar condiciones de mercado?
- ▶ En cada semana, uno de tres posibles estados
- ▶ Cómo evolucionan en el tiempo?
 - ▶ Descripción en términos de probabilidad



Procesos Markovianos


Cómo definir matemáticamente el proceso de regímenes de mercado?



Procesos Markovianos

Cómo definir matemáticamente el proceso de regímenes de mercado?

- ▶ Espacio de estados S :
 - ▶ $S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$
 - ▶ Estados pueden ser discretos o continuos
- ▶ Evolución en el tiempo




from/to	Alcista 2	Bajista	Estable
Alcista			
Bajista			
Estable			

Procesos Markovianos

Cómo definir matemáticamente el proceso de regímenes de mercado?

- ▶ Espacio de estados S :
 - ▶ $S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$
 - ▶ Estados pueden ser discretos o continuos
- ▶ Evolución en el tiempo




from/to	Alcista 2	Bajista	Estable
Alcista	0.9		
Bajista			
Estable			

Procesos Markovianos

Cómo definir matemáticamente el proceso de regímenes de mercado?

- ▶ Espacio de estados S :
 - ▶ $S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$
 - ▶ Estados pueden ser discretos o continuos
- ▶ Evolución en el tiempo




from/to	Alcista	Bajista	Estable
Alcista	0.9	0.075	
Bajista			
Estable			

Procesos Markovianos

Cómo definir matemáticamente el proceso de regímenes de mercado?

- ▶ Espacio de estados S :
 - ▶ $S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$
 - ▶ Estados pueden ser discretos o continuos
- ▶ Evolución en el tiempo




from/to	Alcista 2	Bajista	Estable
Alcista	0.9	0.075	0.025
Bajista			
Estable			

Procesos Markovianos

Cómo definir matemáticamente el proceso de regímenes de mercado?

- ▶ Espacio de estados S :
 - ▶ $S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$
 - ▶ Estados pueden ser discretos o continuos
- ▶ Evolución en el tiempo




from/to	Alcista 2	Bajista	Estable
Alcista	0.9	0.075	0.025
Bajista	0.15	0.8	0.05
Estable	0.25	0.25	0.5

Procesos Markovianos

Cómo definir matemáticamente el proceso de regímenes de mercado?

- ▶ Espacio de estados S :
 - ▶ $S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$
 - ▶ Estados pueden ser discretos o continuos
- ▶ Evolución en el tiempo
 - ▶ Matriz de transición P :

$$P = \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}$$



Tupla (S, P) define el proceso markoviano

- ▶ Si el número de estados es finito, también decimos cadena markoviana.

Propiedad de Markov

“El futuro del proceso markoviano depende solamente del estado presente.”

Propiedad de Markov

“El futuro del proceso markoviano depende solamente del estado presente.”

- ▶ Proceso de Markov: tupla (S, P)

Propiedad de Markov

“El futuro del proceso markoviano depende solamente del estado presente.”

- ▶ Proceso de Markov: tupla (S, P)
- ▶ Estados $s_0, s_1, s_2, \dots$ ($s_t \in S$ for $t = 0, 1, 2, \dots$)

Propiedad de Markov

“El futuro del proceso markoviano depende solamente del estado presente.”

- ▶ Proceso de Markov: tupla (S, P)
- ▶ Estados $s_0, s_1, s_2, \dots$ ($s_t \in S$ for $t = 0, 1, 2, \dots$)
- ▶ $\text{Prob}(s_{t+1} = s | s_0, s_1, \dots, s_t) = \text{Prob}(s_{t+1} = s | s_t)$

Propiedad de Markov

“El futuro del proceso markoviano depende solamente del estado presente.”

- ▶ Proceso de Markov: tupla (S, P)
- ▶ Estados $s_0, s_1, s_2, \dots$ ($s_t \in S$ for $t = 0, 1, 2, \dots$)
- ▶ $\text{Prob}(s_{t+1} = s | s_0, s_1, \dots, s_t) = \text{Prob}(s_{t+1} = s | s_t)$
 - ▶ El estado s_t contiene toda la información relevante para el futuro del proceso
 - ▶ Si conocemos s_t , podemos olvidar $s_{t-1}, s_{t-2}, \dots, s_0$.

Propiedad de Markov

“El futuro del proceso markoviano depende solamente del estado presente.”

- ▶ Proceso de Markov: tupla (S, P)
- ▶ Estados $s_0, s_1, s_2, \dots$ ($s_t \in S$ for $t = 0, 1, 2, \dots$)
- ▶ $\text{Prob}(s_{t+1} = s | s_0, s_1, \dots, s_t) = \text{Prob}(s_{t+1} = s | s_t)$
 - ▶ El estado s_t contiene toda la información relevante para el futuro del proceso
 - ▶ Si conocemos s_t , podemos olvidar $s_{t-1}, s_{t-2}, \dots, s_0$.
 - ▶ $\text{Prob}(s_{t+1} = s | s_t = s') = P(s, s')$

Propiedad de Markov

“El futuro del proceso markoviano depende solamente del estado presente.”


- ▶ Proceso de Markov: tupla (S, P)
- ▶ Estados $s_0, s_1, s_2, \dots$ ($s_t \in S$ for $t = 0, 1, 2, \dots$)
- ▶ $\text{Prob}(s_{t+1} = s | s_0, s_1, \dots, s_t) = \text{Prob}(s_{t+1} = s | s_t)$
 - ▶ El estado s_t contiene toda la información relevante para el futuro del proceso
 - ▶ Si conocemos s_t , podemos olvidar $s_{t-1}, s_{t-2}, \dots, s_0$.
 - ▶ $\text{Prob}(s_{t+1} = s | s_t = s') = P(s, s')$
 - ▶ Por ejemplo:

$$\text{Prob}(s_{t+1} = \mathbf{Bajista} | s_t = \mathbf{Alcista}) = P(\mathbf{Alcista}, \mathbf{Bajista}) = 0,075$$

Propiedad de Markov

$$S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$$

$$P = \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}$$




Cuál es la probabilidad de tener un mercado **bajista** en la **próxima semana**

1. después de haber tenido un mercado **alcista** en las últimas 5 semanas?
2. después de haber tenido un mercado **alcista** en la última semana, y **bajista** en las 4 anteriores?

Propiedad de Markov

$$S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$$

$$P = \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}$$




Cuál es la probabilidad de tener un mercado **bajista** en la **próxima semana**

1. después de haber tenido un mercado **alcista** en las **últimas 5 semanas?**
2. después de haber tenido un mercado **alcista** en la **última semana**, y **bajista** en las **4 anteriores?**

Propiedad de Markov

$$S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$$

$$P = \begin{bmatrix} 0,9 & \textcolor{red}{0,075} & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}$$




Cuál es la probabilidad de tener un mercado **bajista** en la **próxima semana**

1. después de haber tenido un mercado **alcista** en las últimas 5 semanas?
2. después de haber tenido un mercado **alcista** en la última semana, y **bajista** en las 4 anteriores?

Distribución Probabilística de Estados

$$S = \{\mathbf{Alcista}, \mathbf{Bajista}, \mathbf{Estable}\}$$

$$P = \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}$$




Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? En 10 semanas?

Distribución Probabilística de Estados

$$S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$$

$$P = \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}$$




Si esta semana el mercado es bajista, **cuál es la probabilidad de que sea bajista en la próxima semana?** En 2 semanas? En 10 semanas?

- La probabilidad de que sea bajista en la próxima semana es 0.8.

Distribución Probabilística de Estados

$$S = \{\mathbf{Alcista}, \mathbf{Bajista}, \mathbf{Estable}\}$$

$$P = \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}$$




Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? **En 2 semanas?** En 10 semanas?

Distribución Probabilística de Estados

$$S = \{\mathbf{Alcista}, \mathbf{Bajista}, \mathbf{Estable}\}$$

$$P = \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}$$




Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? **En 2 semanas?** En 10 semanas?

- Podemos enumerar las posibilidades y sumarlas. . .

Distribución Probabilística de Estados

$$S = \{\mathbf{Alcista}, \mathbf{Bajista}, \mathbf{Estable}\}$$

$$P = \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}$$




Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? **En 2 semanas?** En 10 semanas?

- Podemos enumerar las posibilidades y sumarlas. . .
 $\text{Prob}(\mathbf{Alcista}, \mathbf{Bajista}) + \text{Prob}(\mathbf{Bajista}, \mathbf{Bajista}) + \text{Prob}(\mathbf{Estable}, \mathbf{Bajista})$

Distribución Probabilística de Estados

$$S = \{\mathbf{Alcista}, \mathbf{Bajista}, \mathbf{Estable}\}$$

$$P = \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}$$




Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? **En 2 semanas?** En 10 semanas?

- Podemos enumerar las posibilidades y sumarlas. . .
 $\text{Prob}(\mathbf{Alcista}, \mathbf{Bajista}) + \text{Prob}(\mathbf{Bajista}, \mathbf{Bajista}) + \text{Prob}(\mathbf{Estable}, \mathbf{Bajista})$
 $= 0,15 * 0,075 + 0,8 * 0,8 + 0,05 * 0,25$
 $= 0,66375$

Distribución Probabilística de Estados

$$S = \{\mathbf{Alcista}, \mathbf{Bajista}, \mathbf{Estable}\}$$

$$P = \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}$$




Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? **En 10 semanas?**

Distribución Probabilística de Estados

$$S = \{\text{Alcista}, \text{Bajista}, \text{Estable}\}$$

$$P = \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}$$



Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? **En 10 semanas?**

- Se puede responder a esas preguntas más fácilmente con álgebra lineal!

Distribución Probabilística de Estados

Vamos a representar una distribución probabilística de estados con la variable π_t :

$$\pi_t(s) = \text{Prob}(s_t = s).$$

Distribución Probabilística de Estados

Vamos a representar una distribución probabilística de estados con la variable π_t :

$$\pi_t(s) = \text{Prob}(s_t = s).$$

En nuestro ejemplo, si consideramos que esta semana corresponde a $t = 0$, tenemos $\text{Prob}(s_0 = \mathbf{Altista}) = 0$, $\text{Prob}(s_0 = \mathbf{Bajista}) = 1$, $\text{Prob}(s_0 = \mathbf{Estable}) = 0$.

Distribución Probabilística de Estados

Vamos a representar una distribución probabilística de estados con la variable π_t :

$$\pi_t(s) = \text{Prob}(s_t = s).$$

En nuestro ejemplo, si consideramos que esta semana corresponde a $t = 0$, tenemos $\text{Prob}(s_0 = \mathbf{Altista}) = 0$, $\text{Prob}(s_0 = \mathbf{Bajista}) = 1$, $\text{Prob}(s_0 = \mathbf{Estable}) = 0$.

Entonces:

$$\pi_0 = \begin{bmatrix} 0 & 1 & 0 \end{bmatrix}$$

Distribución Probabilística de Estados

Vamos a representar una distribución probabilística de estados con la variable π_t :

$$\pi_t(s) = \text{Prob}(s_t = s).$$

En nuestro ejemplo, si consideramos que esta semana corresponde a $t = 0$, tenemos $\text{Prob}(s_0 = \mathbf{Altista}) = 0$, $\text{Prob}(s_0 = \mathbf{Bajista}) = 1$, $\text{Prob}(s_0 = \mathbf{Estable}) = 0$.

Entonces:

$$\pi_0 = \begin{bmatrix} 0 & 1 & 0 \end{bmatrix}$$

π_0 es la distribución inicial de estados en el proceso markoviano.

Distribución Probabilística de Estados

Vamos a representar una distribución probabilística de estados con la variable π_t :

$$\pi_t(s) = \text{Prob}(s_t = s).$$

En nuestro ejemplo, si consideramos que esta semana corresponde a $t = 0$, tenemos $\text{Prob}(s_0 = \mathbf{Altista}) = 0$, $\text{Prob}(s_0 = \mathbf{Bajista}) = 1$, $\text{Prob}(s_0 = \mathbf{Estable}) = 0$.

Entonces:

$$\pi_0 = \begin{bmatrix} 0 & 1 & 0 \end{bmatrix}$$

π_0 es la distribución inicial de estados en el proceso markoviano.

Resulta que $\pi_{t+1} = \pi_t P$ y $\pi_t = \pi_0 P^t$.

Distribución Probabilística de Estados

Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? En 10 semanas?

Distribución Probabilística de Estados

Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? En 10 semanas?

Resulta que $\pi_t = \pi_0 P^t$.

$$\begin{aligned}\pi_1 &= \pi_0 P \\ &= \begin{bmatrix} 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix} \\ &= \begin{bmatrix} 0,15 & \mathbf{0,8} & 0,05 \end{bmatrix}\end{aligned}$$

$\text{Prob}(s_1 = \mathbf{Bajista} | s_0 = \mathbf{Bajista}) = 0,8$

Distribución Probabilística de Estados

Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? En 10 semanas?

Resulta que $\pi_t = \pi_0 P^t$.

$$\begin{aligned}\pi_2 &= \pi_0 P^2 \\ &= \begin{bmatrix} 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}^2 \\ &= \begin{bmatrix} 0,2675 & 0,66375 & 0,06875 \end{bmatrix}\end{aligned}$$

$\text{Prob}(s_2 = \mathbf{Bajista} | s_0 = \mathbf{Bajista}) = 0,66375$

Distribución Probabilística de Estados

Si esta semana el mercado es bajista, cuál es la probabilidad de que sea bajista en la próxima semana? En 2 semanas? En 10 semanas?

Resulta que $\pi_t = \pi_0 P^t$.

$$\begin{aligned}\pi_{10} &= \pi_0 P^{10} \\ &= \begin{bmatrix} 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}^{10} \\ &= \begin{bmatrix} 0,59159 & 0,34310 & 0,06532 \end{bmatrix}\end{aligned}$$

$\text{Prob}(s_{10} = \mathbf{Bajista} | s_0 = \mathbf{Bajista}) = 0,34310$

Distribución Probabilística de Estados

Cuál es la frecuencia de semanas alcistas, bajistas y estables en ese mercado?

Distribución Probabilística de Estados

Cuál es la frecuencia de semanas alcistas, bajistas y estables en ese mercado?

Buscamos la **distribución estacionaria** de ese proceso.

Distribución Probabilística de Estados

Cuál es la frecuencia de semanas alcistas, bajistas y estables en ese mercado?

Buscamos la **distribución estacionaria** de ese proceso.

- ▶ Tenemos $\pi_{t+1} = \pi_t \times P$ y estacionariedad implica $\pi_{t+1} = \pi_t = \pi$.

Distribución Probabilística de Estados

Cuál es la frecuencia de semanas alcistas, bajistas y estables en ese mercado?

Buscamos la **distribución estacionaria** de ese proceso.

- ▶ Tenemos $\pi_{t+1} = \pi_t \times P$ y estacionariedad implica $\pi_{t+1} = \pi_t = \pi$.
- ▶ Queremos resolver $\pi = \pi P$.

Distribución Probabilística de Estados

Cuál es la frecuencia de semanas alcistas, bajistas y estables en ese mercado?

Buscamos la **distribución estacionaria** de ese proceso.

- ▶ Tenemos $\pi_{t+1} = \pi_t \times P$ y estacionariedad implica $\pi_{t+1} = \pi_t = \pi$.
- ▶ Queremos resolver $\pi = \pi P$.
- ▶ Si el número de estados es finito, siempre existe una solución, pero no es necesariamente única.

Distribución Probabilística de Estados

Cuál es la frecuencia de semanas alcistas, bajistas y estables en ese mercado?

Buscamos la **distribución estacionaria** de ese proceso.

- ▶ Tenemos $\pi_{t+1} = \pi_t P$ y estacionariedad implica $\pi_{t+1} = \pi_t = \pi$.
- ▶ Queremos resolver $\pi = \pi P$.
- ▶ Si el número de estados es finito, siempre existe una solución, pero no es necesariamente única.

$$\begin{aligned}\pi_{\infty} &= \pi_0 P^{\infty} \\ &= \begin{bmatrix} 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}^{\infty} \\ &\approx \begin{bmatrix} 0,625 & 0,3125 & 0,0625 \end{bmatrix}\end{aligned}$$

Distribución Probabilística de Estados

Cuál es la frecuencia de semanas alcistas, bajistas y estables en ese mercado?

Buscamos la **distribución estacionaria** de ese proceso.


- ▶ Tenemos $\pi_{t+1} = \pi_t P$ y estacionariedad implica $\pi_{t+1} = \pi_t = \pi$.
- ▶ Queremos resolver $\pi = \pi P$.
- ▶ Si el número de estados es finito, siempre existe una solución, pero no es necesariamente única.

$$\begin{aligned}\pi_{\infty} &= \pi_0 P^{\infty} \\ &= \begin{bmatrix} 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}^{\infty} \\ &\approx \begin{bmatrix} 0,625 & 0,3125 & 0,0625 \end{bmatrix}\end{aligned}$$

En ese mercado, **62.5 %** de las semanas son alcistas, **31.25 %** son bajistas, y **6.25 %** son estables.

Ejemplo: Participación en El Mercado


Cadenas markovianas son frecuentemente utilizadas para modelar el comportamiento de usuarios de proveedores adversarios y predecir la participación en el mercado de esos proveedores al largo del tiempo.



Ejemplo: Participación en El Mercado

Cadenas markovianas son frecuentemente utilizadas para modelar el comportamiento de usuarios de proveedores adversarios y predecir la participación en el mercado de esos proveedores al largo del tiempo.

- p_{ij} = probabilidad que usuario de proveedor i cambie a proveedor j



Ejemplo: Participación en El Mercado

Table 4: Respondents Brand Switching Behavior

Gains and Losses	Mobile Telecom Operators						Total
	M	V	T	E	A	G	
M	290	38	24	2	36	15	405
V	80	91	22	4	32	6	235
T	83	17	101	4	21	11	237
E	9	6	11	4	0	0	30
A	72	22	21	2	87	5	209
G	38	9	13	1	21	32	114

Source: Author's Computation (2013)

“Prediction of Subscribers’ Brand Switching Behaviour and Ergodic Market Share of Network Service Providers in Ghana Using Markov Chain Model”, Ezekiel Nortey

Ejemplo: Participación en El Mercado

Table 4: Respondents Brand Switching Behavior

Gains and Losses	Mobile Telecom Operators						Total
	M	V	T	E	A	G	
M	290	38	24	2	36	15	405
V	80	91	22	4	32	6	235
T	83	17	101	4	21	11	237
E	9	6	11	4	0	0	30
A	72	22	21	2	87	5	209
G	38	9	13	1	21	32	114

Source: Author's Computation (2013)

- Participación actual derivada de totales

$$\begin{aligned}\pi_0 &= \left[\begin{array}{cccccc} 405 & 235 & 237 & 30 & 209 & 114 \end{array} \right] / 1230 \\ &= \left[\begin{array}{cccccc} 0,33 & 0,19 & 0,19 & 0,02 & 0,17 & 0,09 \end{array} \right]\end{aligned}$$

Ejemplo: Participación en El Mercado

Table 4: Respondents Brand Switching Behavior

Gains and Losses	Mobile Telecom Operators						Total
	M	V	T	E	A	G	
M	290	38	24	2	36	15	405
V	80	91	22	4	32	6	235
T	83	17	101	4	21	11	237
E	9	6	11	4	0	0	30
A	72	22	21	2	87	5	209
G	38	9	13	1	21	32	114

Source: Author's Computation (2013)

- Participación actual derivada de totales

$$\begin{aligned}\pi_0 &= \left[405 \quad 235 \quad 237 \quad 30 \quad 209 \quad 114 \right] / 1230 \\ &= \left[0,33 \quad 0,19 \quad 0,19 \quad 0,02 \quad 0,17 \quad 0,09 \right]\end{aligned}$$

- Matriz de transición P derivada de la misma forma
 - Por ejemplo $P(M, V) = 38/405 = 0,094$.

Ejemplo: Participación en El Mercado

► Tenemos:

$$\pi_0 = \begin{bmatrix} 0,329 & 0,191 & 0,193 & 0,024 & 0,170 & 0,093 \end{bmatrix}$$

$$P = \begin{bmatrix} 0,716 & 0,094 & 0,059 & 0,005 & 0,089 & 0,037 \\ 0,340 & 0,387 & 0,094 & 0,017 & 0,136 & 0,026 \\ 0,350 & 0,072 & 0,426 & 0,017 & 0,089 & 0,046 \\ 0,300 & 0,200 & 0,367 & 0,133 & 0,000 & 0,000 \\ 0,344 & 0,105 & 0,100 & 0,010 & 0,416 & 0,024 \\ 0,333 & 0,079 & 0,114 & 0,009 & 0,184 & 0,281 \end{bmatrix}$$

Ejemplo: Participación en El Mercado


- Tenemos:

$$\pi_0 = \begin{bmatrix} 0,329 & 0,191 & 0,193 & 0,024 & 0,170 & 0,093 \end{bmatrix}$$

$$P = \begin{bmatrix} 0,716 & 0,094 & 0,059 & 0,005 & 0,089 & 0,037 \\ 0,340 & 0,387 & 0,094 & 0,017 & 0,136 & 0,026 \\ 0,350 & 0,072 & 0,426 & 0,017 & 0,089 & 0,046 \\ 0,300 & 0,200 & 0,367 & 0,133 & 0,000 & 0,000 \\ 0,344 & 0,105 & 0,100 & 0,010 & 0,416 & 0,024 \\ 0,333 & 0,079 & 0,114 & 0,009 & 0,184 & 0,281 \end{bmatrix}$$

- Analisamos el comportamiento de esa cadena markoviana en Python

Ejemplo: Participación en El Mercado



La Elección de Estado

- ▶ Queremos describir cómo evoluciona el sistema

La Elección de Estado

- ▶ Queremos describir cómo evoluciona el sistema
- ▶ Definimos:
 - ▶ **Estado**: resumen de la información relevante (propiedad de Markov)

La Elección de Estado

- ▶ Queremos describir cómo evoluciona el sistema
- ▶ Definimos:
 - ▶ **Estado**: resumen de la información relevante (propiedad de Markov)
- ▶ Idea clave:
 - ▶ El estado debe contener lo necesario para predecir el futuro

La Elección de Estado

- ▶ Queremos describir cómo evoluciona el sistema
- ▶ Definimos:
 - ▶ **Estado**: resumen de la información relevante (propiedad de Markov)
- ▶ Idea clave:
 - ▶ El estado debe contener lo necesario para predecir el futuro
- ▶ Si falta información:
 - ▶ El modelo será incorrecto

La Elección de Estado

- ▶ Queremos describir cómo evoluciona el sistema
- ▶ Definimos:
 - ▶ **Estado**: resumen de la información relevante (propiedad de Markov)
- ▶ Idea clave:
 - ▶ El estado debe contener lo necesario para predecir el futuro
- ▶ Si falta información:
 - ▶ El modelo será incorrecto
- ▶ Si hay información redundante:
 - ▶ El espacio de estados será más largo del necesario, complejizando innecesariamente el tratamiento computacional del problema

La Elección de Estado

- ▶ Queremos describir cómo evoluciona el sistema
- ▶ Definimos:
 - ▶ **Estado**: resumen de la información relevante (propiedad de Markov)
- ▶ Idea clave:
 - ▶ El estado debe contener lo necesario para predecir el futuro
- ▶ Si falta información:
 - ▶ El modelo será incorrecto
- ▶ Si hay información redundante:
 - ▶ El espacio de estados será más largo del necesario, complejizando innecesariamente el tratamiento computacional del problema
- ▶ En la práctica, la elección del estado puede exigir tradeoffs entre captar la información relevante y controlar la complejidad computacional.

La Elección de Estado

- ▶ En el ejemplo de regímenes de mercado, ¿qué representa el estado que elijimos? Y ¿cómo puede fallar en la práctica?

La Elección de Estado

- ▶ En el ejemplo de regímenes de mercado, ¿qué representa el estado que elijimos? Y ¿cómo puede fallar en la práctica?
- ▶ Pensemos en otros ambientes con incertidumbre. ¿Cómo modelarlos como process markovianos?

Pero falta algo

- ▶ Hasta ahora:
 - ▶ Sabemos cómo evoluciona el sistema

Pero falta algo

- ▶ Hasta ahora:
 - ▶ Sabemos cómo evoluciona el sistema
- ▶ Pero:
 - ▶ No todos los estados son iguales

Pero falta algo

- ▶ Hasta ahora:
 - ▶ Sabemos cómo evoluciona el sistema
- ▶ Pero:
 - ▶ No todos los estados son iguales
- ▶ Necesitamos medir qué tan buenos son, según algún criterio que nos interese

Función de Recompensa

- ▶ Para toma de decisiones, normalmente estamos interesados en uno o más objetivos:

Función de Recompensa

- ▶ Para toma de decisiones, normalmente estamos interesados en uno o más objetivos:
 - ▶ Maximizar ganancias

Función de Recompensa

- ▶ Para toma de decisiones, normalmente estamos interesados en uno o más objetivos:
 - ▶ Maximizar ganancias
 - ▶ Minimizar costos

Función de Recompensa

- ▶ Para toma de decisiones, normalmente estamos interesados en uno o más objetivos:
 - ▶ Maximizar ganancias
 - ▶ Minimizar costos
 - ▶ Ganar un juego, o cumplir con una meta

Función de Recompensa

- ▶ Para toma de decisiones, normalmente estamos interesados en uno o más objetivos:
 - ▶ Maximizar ganancias
 - ▶ Minimizar costos
 - ▶ Ganar un juego, o cumplir con una meta
 - ▶ Minimizar riesgos

Función de Recompensa

- ▶ Para toma de decisiones, normalmente estamos interesados en uno o más objetivos:
 - ▶ Maximizar ganancias
 - ▶ Minimizar costos
 - ▶ Ganar un juego, o cumplir con una meta
 - ▶ Minimizar riesgos
 - ▶ ???

Función de Recompensa

- ▶ Para toma de decisiones, normalmente estamos interesados en uno o más objetivos:
 - ▶ Maximizar ganancias
 - ▶ Minimizar costos
 - ▶ Ganar un juego, o cumplir con una meta
 - ▶ Minimizar riesgos
 - ▶ ???
- ▶ Expresamos el objetivo a través de la **función de recompensa**

Proceso Markoviano con Recompensa

- ▶ Proceso markoviano: tupla (S, P)

Proceso Markoviano con Recompensa

- ▶ Proceso markoviano: tupla (S, P)
- ▶ Con recompensa: tupla (S, P, r)

Proceso Markoviano con Recompensa


- ▶ Proceso markoviano: tupla (S, P)
- ▶ Con recompensa: tupla (S, P, r)
 - ▶ $r(x) = \text{recompensa (o costo) de estar en el estado } x$

Proceso Markoviano con Ricompensa

- ▶ Proceso markoviano: tupla (S, P)
- ▶ Con recompensa: tupla (S, P, r)
 - ▶ $r(x) = \text{recompensa (o costo) de estar en el estado } x$
- ▶ Ejemplo: regímenes de mercado

Proceso Markoviano con Recompensa

- ▶ Proceso markoviano: tupla (S, P)
- ▶ Con recompensa: tupla (S, P, r)
 - ▶ $r(x) = \text{recompensa (o costo) de estar en el estado } x$
- ▶ Ejemplo: regímenes de mercado



- ▶ ¿Cómo definir la función recompensa en este contexto?

Función de recompensa

- Definimos:

$$r(x)$$

Función de recompensa

- Definimos:

$$r(x)$$

- Interpreta ganancia o costo en el estado x

Función de recompensa

- Definimos:

$$r(x)$$

- Interpreta ganancia o costo en el estado x
- Ejemplo:

$$r(\text{Alcista}) = 0,005, \quad r(\text{Bajista}) = -0,005, \quad r(\text{Estable}) = 0$$

Función de recompensa

- Definimos:


$$r(x)$$

- Interpreta ganancia o costo en el estado x
- Ejemplo:

$$r(\text{Alcista}) = 0,005, \quad r(\text{Bajista}) = -0,005, \quad r(\text{Estable}) = 0$$

- Ahora podemos evaluar trayectorias

Proceso con recompensa



- Invertir \$1 $\rightarrow$ $\$(1 + r(x))$ después de una semana

Evaluando una trayectoria

- ▶ Estados: x_0, x_1, x_2

Evaluando una trayectoria

- ▶ Estados: x_0, x_1, x_2
- ▶ Ganancia total (intereses simples para facilitar):

$$r(x_0) + r(x_1) + r(x_2)$$

Evaluando una trayectoria

- ▶ Estados: x_0, x_1, x_2
- ▶ Ganancia total (intereses simples para facilitar):

$$r(x_0) + r(x_1) + r(x_2)$$

- ▶ No conocemos el futuro $\rightarrow$ usamos valor esperado
 - ▶ Empezando con una semana en estado x_0 , la ganancia total en 3 semanas será:

$$E[r(x_0) + r(x_1) + r(x_2)|x_0]$$

Evaluando una trayectoria

- ▶ Estados: x_0, x_1, x_2
- ▶ Ganancia total (intereses simples para facilitar):

$$r(x_0) + r(x_1) + r(x_2)$$

- ▶ No conocemos el futuro $\rightarrow$ usamos valor esperado
 - ▶ Empezando con una semana en estado x_0 , la ganancia total en 3 semanas será:

$$E[r(x_0) + r(x_1) + r(x_2)|x_0]$$

- ▶ ¿El valor esperado es con respecto a qué?

Idea central

- ▶ Queremos evaluar estados considerando el futuro

Idea central

- ▶ Queremos evaluar estados considerando el futuro
- ▶ Definimos la **función valor**
 - ▶ En el ejemplo de regímenes de mercado, captura la ganancia esperada en 3 semanas, dado el estado de la semana actual (x_0 = Alcista, Bajista o Estable):

$$V(x_0) = E[r(x_0) + r(x_1) + r(x_2)|x_0]$$

Idea central

- ▶ Queremos evaluar estados considerando el futuro
- ▶ Definimos la **función valor**
 - ▶ En el ejemplo de regímenes de mercado, captura la ganancia esperada en 3 semanas, dado el estado de la semana actual (x_0 = Alcista, Bajista o Estable):

$$V(x_0) = E[r(x_0) + r(x_1) + r(x_2)|x_0]$$

- ▶ Intuición:
 - ▶ Qué tan bueno es estar en un estado hoy

Función Valor - Intuición

- Cómo podríamos construir un jugador de ajedrez?



Función Valor - Intuición

- ▶ Cómo podríamos construir un jugador de ajedrez?



- ▶ Si tuviéramos una función para evaluar la probabilidad de ganar el juego a partir de cada posición, podríamos elegir la mejor acción

Función Valor - Intuición

- ▶ Cómo podríamos construir un jugador de ajedrez?



- ▶ Si tuviéramos una función para evaluar la probabilidad de ganar el juego a partir de cada posición, podríamos elegir la mejor acción
- ▶ Esa función existe y es bien definida para MRP y MDP. Se denomina **función valor**.

Función valor como tabla

- ▶ Pensemos la función valor como una tabla.
- ▶ Filas: estados x
- ▶ Columnas: tiempo t

$x \backslash t$	0	1	2
Alcista	?	?	?
Bajista	?	?	?
Estable	?	?	?

$V_t(x)$ = ganancia esperada empezando a partir de la semana t , con estado x .

Función valor como tabla

- Pensemos la función valor como una tabla.
- Filas: estados x
- Columnas: tiempo t

$x \backslash t$	0	1	2
Alcista	?	?	?
Bajista	?	?	?
Estable	?	?	?


$V_t(x)$ = ganancia esperada empezando a partir de la semana t , con estado x .

Idea clave

Resolver el problema = llenar esta tabla.


Recursión

- El concepto de función valor es central para la toma de decisiones secuenciales.




Recursión

- ▶ El concepto de función valor es central para la toma de decisiones secuenciales.
- ▶ Otro concepto que vamos a utilizar es la idea de **recursión**.




Recursión

- ▶ El concepto de función valor es central para la toma de decisiones secuenciales.
- ▶ Otro concepto que vamos a utilizar es la idea de **recursión**.
- ▶ Para eso, vamos a representar el proceso con un nuevo grafo, utilizando el tiempo como segundo eje.




Recursión

- ▶ El concepto de función valor es central para la toma de decisiones secuenciales.
- ▶ Otro concepto que vamos a utilizar es la idea de **recursión**.
- ▶ Para eso, vamos a representar el proceso con un nuevo grafo, utilizando el tiempo como segundo eje.




Recursión

- ▶ El concepto de función valor es central para la toma de decisiones secuenciales.
- ▶ Otro concepto que vamos a utilizar es la idea de **recursión**.
- ▶ Para eso, vamos a representar el proceso con un nuevo grafo, utilizando el tiempo como segundo eje.




Recursión

- ▶ El concepto de función valor es central para la toma de decisiones secuenciales.
- ▶ Otro concepto que vamos a utilizar es la idea de **recursión**.
- ▶ Para eso, vamos a representar el proceso con un nuevo grafo, utilizando el tiempo como segundo eje.




Recursión

- ▶ El concepto de función valor es central para la toma de decisiones secuenciales.
- ▶ Otro concepto que vamos a utilizar es la idea de **recursión**.
- ▶ Para eso, vamos a representar el proceso con un nuevo grafo, utilizando el tiempo como segundo eje.



Recursión

- ▶ El concepto de función valor es central para la toma de decisiones secuenciales.
- ▶ Otro concepto que vamos a utilizar es la idea de **recursión**.
- ▶ Para eso, vamos a representar el proceso con un nuevo grafo, utilizando el tiempo como segundo eje.



Recursión hacia atrás

- ▶ Empezamos desde el final.

$$V_2(x) = r(x)$$

Recursión hacia atrás

- ▶ Empezamos desde el final.

$$V_2(x) = r(x)$$

- ▶ Luego usamos recursión:

$$V_t(x) = r(x) + \sum_y P(x, y) V_{t+1}(y)$$

Recursión hacia atrás

- ▶ Empezamos desde el final.

$$V_2(x) = r(x)$$


- ▶ Luego usamos recursión:

$$V_t(x) = r(x) + \sum_y P(x, y) V_{t+1}(y)$$

Idea


Propagamos valores hacia atrás en el tiempo.

Calculando La Función Valor Por Recursión



$V_t(x)$ = ganancia total esperada empezando en el estado x en tiempo t .


Calculando La Función Valor Por Recursión



$V_t(x)$ = ganancia total esperada empezando en el estado x en tiempo t .

1. Calculamos $V_2(x) = r(x)$.


Calculando La Función Valor Por Recursión



$V_t(x)$ = ganancia total esperada empezando en el estado x en tiempo t .

1. Calculamos $V_2(x) = r(x)$.


Calculando La Función Valor Por Recursión



$V_t(x)$ = ganancia total esperada empezando en el estado x en tiempo t .

1. Calculamos $V_2(x) = r(x)$.
2. Retrocedemos una semana y calculamos
$$V_1(x) = r(x) + \sum_y P(x, y) V_2(y)$$

Calculando La Función Valor Por Recursión




$V_t(x)$ = ganancia total esperada empezando en el estado x en tiempo t .

1. Calculamos $V_2(x) = r(x)$.
2. Retrocedemos una semana y calculamos $V_1(x) = r(x) + \sum_y P(x, y) V_2(y)$

$$V_1(\mathbf{A}) = r(\mathbf{A}) + \sum_y P(\mathbf{A}, y) V_2(y)$$

Calculando La Función Valor Por Recursión




$V_t(x)$ = ganancia total esperada empezando en el estado x en tiempo t .

1. Calculamos $V_2(x) = r(x)$.
2. Retrocedemos una semana y calculamos $V_1(x) = r(x) + \sum_y P(x, y) V_2(y)$

$$\begin{aligned} V_1(\mathbf{A}) &= r(\mathbf{A}) + \sum_y P(\mathbf{A}, y) V_2(y) \\ &= 0,005 + 0,9 \times 0,005 + 0,075 \times (-0,005) + 0,025 \times 0 \end{aligned}$$

Calculando La Función Valor Por Recursión




$V_t(x)$ = ganancia total esperada empezando en el estado x en tiempo t .

1. Calculamos $V_2(x) = r(x)$.
2. Retrocedemos una semana y calculamos

$$V_1(x) = r(x) + \sum_y P(x, y) V_2(y)$$

$$\begin{aligned} V_1(\mathbf{A}) &= r(\mathbf{A}) + \sum_y P(\mathbf{A}, y) V_2(y) \\ &= 0,005 + 0,9 \times 0,005 + 0,075 \times (-0,005) + 0,025 \times 0 \\ &= 0,009125 \end{aligned}$$

Calculando La Función Valor Por Recursión



$V_t(x)$ = ganancia total esperada empezando en el estado x en tiempo t .


1. Calculamos $V_2(x) = r(x)$.
2. Retrocedemos una semana y calculamos

$$V_1(x) = r(x) + \sum_y P(x, y) V_2(y)$$

$$\begin{aligned} V_1(\mathbf{A}) &= r(\mathbf{A}) + \sum_y P(\mathbf{A}, y) V_2(y) \\ &= 0,005 + 0,9 \times 0,005 + 0,075 \times (-0,005) + 0,025 \times 0 \\ &= 0,009125 \end{aligned}$$

Repetimos el mismo procedimiento con $x = \mathbf{Bajista}$ y $x = \mathbf{Estable}$.

Calculando La Función Valor Por Recursión



$V_t(x)$ = ganancia total esperada empezando en el estado x en tiempo t .

1. Calculamos $V_2(x) = r(x)$.
2. Retrocedemos una semana y calculamos
$$V_1(x) = r(x) + \sum_y P(x, y) V_2(y)$$
3. Retrocedemos otra semana y calculamos
$$V_0(x) = r(x) + \sum_y P(x, y) V_1(y).$$

Calculando La Función Valor Por Recursión

$t = 0$	$V_0(x)$	$t = 1$	$V_1(x)$	$t = 2$	$V_2(x)$
Alcista 0.005	0.01259375	Alcista 0.005	0.009125	Alcista 0.005	0.005
Bajista -0.005	-0.01023125	Bajista -0.005	-0.00825	Bajista -0.005	-0.005
Estable 0	0.00021875	Estable 0	0	Estable 0	0

$V_t(x)$ = ganancia total esperada empezando en el estado x en tiempo t .

1. Calculamos $V_2(x) = r(x)$.
2. Retrocedemos una semana y calculamos $V_1(x) = r(x) + \sum_y P(x, y) V_2(y)$
3. Retrocedemos otra semana y calculamos $V_0(x) = r(x) + \sum_y P(x, y) V_1(y)$.

La Función Valor

- Con esos cálculos, tenemos:

$x \backslash t$	0	1	2
Alcista	0.01259375	0.009125	0.005
Bajista	-0.01023125	-0.00825	-0.005
Estable	0.00021875	0	0

La Función Valor

- ▶ Con esos cálculos, tenemos:

$x \backslash t$	0	1	2
Alcista	0.01259375	0.009125	0.005
Bajista	-0.01023125	-0.00825	-0.005
Estable	0.00021875	0	0

- ▶ Interpretación:

La Función Valor

- ▶ Con esos cálculos, tenemos:

$x \backslash t$	0	1	2
Alcista	0.01259375	0.009125	0.005
Bajista	-0.01023125	-0.00825	-0.005
Estable	0.00021875	0	0

- ▶ Interpretación:

- ▶ $V_0(\text{Alcista}) = 0,01259375 \mapsto$ si la semana actual es alcista, esperamos ganancia de **0.01259375 en 3 semanas**
- ▶ $V_1(\text{Bajista}) = -0,00825 \mapsto$ si la semana actual es bajista, esperamos pérdida de **0.00825 en 2 semanas**

Generalizando hasta acá: MRP

- ▶ Proceso markoviano con recompensa definido por la tupla (S, P, r)

Generalizando hasta acá: MRP

- ▶ Proceso markoviano con recompensa definido por la tupla (S, P, r)
- ▶ Distintas maneras de combinar $r(x_t)$, $t = 0, 1, \dots$ en un único criterio (suma, multiplicación, medidas de riesgo)

Generalizando hasta acá: MRP

- ▶ Proceso markoviano con recompensa definido por la tupla (S, P, r)
- ▶ Distintas maneras de combinar $r(x_t)$, $t = 0, 1, \dots$ en un único criterio (suma, multiplicación, medidas de riesgo)
- ▶ Una de las definiciones más comúnmente utilizadas es la recompensa total:

$$V_t(x) = \mathbb{E} \left[\sum_{\tau=t}^T r(x_\tau) | x_t = x \right]$$

- ▶ T es el **horizonte** (finito)

Generalizando hasta acá: Recursión

- Definimos $V_t(x)$ recursivamente:

$$\begin{aligned}V_T(x) &= r(x) \\ V_t(x) &= r(x) + \sum_y P(x, y) V_{t+1}(y)\end{aligned}$$

Generalizando hasta acá: Recursión

- Definimos $V_t(x)$ recursivamente:

$$\begin{aligned} V_T(x) &= r(x) \\ V_t(x) &= r(x) + \sum_y P(x, y) V_{t+1}(y) \end{aligned}$$

Generalizando hasta acá: Recursión

- Definimos $V_t(x)$ recursivamente:

$$\begin{aligned} V_T(x) &= r(x) \\ V_t(x) &= r(x) + \sum_y P(x, y) V_{t+1}(y) \end{aligned}$$

Generalizando hasta acá: Recursión

- Definimos $V_t(x)$ recursivamente:

$$\begin{aligned}V_T(x) &= r(x) \\ V_t(x) &= r(x) + \sum_y P(x, y) V_{t+1}(y)\end{aligned}$$

- Podemos usar notación de matrices para simplificar las ecuaciones:

$$\begin{aligned}V_T &= r \\ V_t &= r + P V_{t+1}, \quad t = 0, \dots, T-1\end{aligned}$$

donde $r \in \Re^{|S|}$, $V_t \in \Re^{|S|}$, $P \in \Re^{|S| \times |S|}$.

Generalizando hasta acá: Recursión

- Definimos $V_t(x)$ recursivamente:

$$\begin{aligned}V_T(x) &= r(x) \\V_t(x) &= r(x) + \sum_y P(x, y) V_{t+1}(y)\end{aligned}$$

- Podemos usar notación de matrices para simplificar las ecuaciones:

$$\begin{aligned}V_T &= r \\V_t &= r + P V_{t+1}, \quad t = 0, \dots, T - 1\end{aligned}$$

donde $r \in \mathbb{R}^{|S|}$, $V_t \in \mathbb{R}^{|S|}$, $P \in \mathbb{R}^{|S| \times |S|}$.

- Podemos implementar el algoritmo en Python.

Observaciones

- Asumimos que r y P no dependen de t , entonces el proceso markoviano es homogéneo en el tiempo. Pero se puede extender el resultado al caso en que dependen de t :

$$\begin{aligned}V_T &= r_T \\V_t &= r_t + \alpha P_t V_{t+1}, \quad t = 0, \dots, T-1\end{aligned}$$

Observaciones

- Asumimos que r y P no dependen de t , entonces el proceso markoviano es homogéneo en el tiempo. Pero se puede extender el resultado al caso en que dependen de t :

$$\begin{aligned}V_T &= r_T \\V_t &= r_t + \alpha P_t V_{t+1}, \quad t = 0, \dots, T-1\end{aligned}$$

- También asumimos que la recompensa es determinística, pero podemos incorporar casos en que es aleatoria:

$$\bar{r}(x) = E_w[r(x, w)]$$

Observaciones

- Asumimos que r y P no dependen de t , entonces el proceso markoviano es homogéneo en el tiempo. Pero se puede extender el resultado al caso en que dependen de t :

$$\begin{aligned}V_T &= r_T \\V_t &= r_t + \alpha P_t V_{t+1}, \quad t = 0, \dots, T-1\end{aligned}$$

- También asumimos que la recompensa es determinística, pero podemos incorporar casos en que es aleatoria:

$$\bar{r}(x) = E_w[r(x, w)]$$

- Si la recompensa depende del próximo estado además del actual, también se puede incorporar utilizando:

$$\bar{r}(x) = E[r(x, x_{t+1}) | x_t = x] = \sum_y P(x, y) r(x, y)$$

Ejemplo: gestión de inventario

¿Cómo decidir cuánto stock mantener al largo del tiempo?

Ejemplo: gestión de inventario

¿Cómo decidir cuánto stock mantener al largo del tiempo?

- ▶ La demanda es incierta
- ▶ Las decisiones hoy afectan el futuro
- ▶ ¿Qué costos están involucrados?

Descripción del problema

En cada período $t = 0, 1, \dots, T$:

- ▶ Tenemos un nivel de inventario
- ▶ Ocurre una demanda aleatoria
- ▶ El inventario cambia

Descripción del problema

En cada período $t = 0, 1, \dots, T$:

- ▶ Tenemos un nivel de inventario
- ▶ Ocurre una demanda aleatoria
- ▶ El inventario cambia

¿Qué necesitamos modelar?

¿Cuál debería ser el estado?

Primera opción:

- ▶ Solo el inventario actual

$$X_t = \text{inventario en } t$$

¿Cuál debería ser el estado?

Primera opción:

- ▶ Solo el inventario actual

$$X_t = \text{inventario en } t$$

Pregunta: ¿esto siempre alcanza?

¿Cuál debería ser el estado?

Primera opción:

- ▶ Solo el inventario actual

$$X_t = \text{inventario en } t$$

Pregunta: ¿esto siempre alcanza?

Si la demanda es completamente aleatoria:

- ▶ Sí, el inventario resume toda la información relevante

¿Cuál debería ser el estado?

Primera opción:

- ▶ Solo el inventario actual

$$X_t = \text{inventario en } t$$

Pregunta: ¿esto siempre alcanza?

Si la demanda es completamente aleatoria:

- ▶ Sí, el inventario resume toda la información relevante

Si la demanda tiene patrón (ej: estacionalidad):

- ▶ Tal vez necesitamos incluir:
 - ▶ el tiempo t
 - ▶ o una variable de “estado de demanda”

Espacio de estados

Supongamos:

$$S = \{0, 1, 2, \dots, N\}$$

Espacio de estados

Supongamos:

$$S = \{0, 1, 2, \dots, N\}$$

- ▶ 0: sin stock
- ▶ N : capacidad máxima

Espacio de estados

Supongamos:

$$S = \{0, 1, 2, \dots, N\}$$

- ▶ 0: sin stock
- ▶ N : capacidad máxima

Interpretación:

- ▶ Estado = unidades disponibles

¿Cómo evoluciona el sistema?

Demanda aleatoria:

$D_t \sim$ Distribución conocida

¿Cómo evoluciona el sistema?

Demanda aleatoria:

$D_t \sim$ Distribución conocida

Transición:

$$X_{t+1} = \begin{cases} X_t - D_t & \text{if } X_t - D_t \geq n \\ N & \text{if } X_t - D_t < n \end{cases}$$

¿Cómo evoluciona el sistema?

Demanda aleatoria:

$D_t \sim$ Distribución conocida

Transición:

$$X_{t+1} = \begin{cases} X_t - D_t & \text{if } X_t - D_t \geq n \\ N & \text{if } X_t - D_t < n \end{cases}$$

Hoy: las decisiones están fijas, volver al nivel máximo N si el nivel queda por debajo de un límite n .

Probabilidades de transición

Recordemos la dinámica:

$$X_{t+1} = \begin{cases} X_t - D_t & \text{si } X_t - D_t \geq n \\ N & \text{si } X_t - D_t < n \end{cases}$$

Probabilidades de transición

Recordemos la dinámica:

$$X_{t+1} = \begin{cases} X_t - D_t & \text{si } X_t - D_t \geq n \\ N & \text{si } X_t - D_t < n \end{cases}$$

Queremos calcular:

$$P_{ij} = \mathbb{P}(X_{t+1} = j \mid X_t = i)$$

Probabilidades de transición

Recordemos la dinámica:

$$X_{t+1} = \begin{cases} X_t - D_t & \text{si } X_t - D_t \geq n \\ N & \text{si } X_t - D_t < n \end{cases}$$

Queremos calcular:

$$P_{ij} = \mathbb{P}(X_{t+1} = j \mid X_t = i)$$

Caso 1: transición sin reposición ($j \geq n$)

$$P_{ij} = \mathbb{P}(D_t = i - j), \quad \text{para } j \in \{n, \dots, i\}$$

Probabilidades de transición

Recordemos la dinámica:

$$X_{t+1} = \begin{cases} X_t - D_t & \text{si } X_t - D_t \geq n \\ N & \text{si } X_t - D_t < n \end{cases}$$

Queremos calcular:

$$P_{ij} = \mathbb{P}(X_{t+1} = j \mid X_t = i)$$

Caso 1: transición sin reposición ($j \geq n$)

$$P_{ij} = \mathbb{P}(D_t = i - j), \quad \text{para } j \in \{n, \dots, i\}$$

Caso 2: reposición a N

$$P_{iN} = \mathbb{P}(X_t - D_t < n) = \mathbb{P}(D_t > i - n)$$

Probabilidades de transición

Recordemos la dinámica:

$$X_{t+1} = \begin{cases} X_t - D_t & \text{si } X_t - D_t \geq n \\ N & \text{si } X_t - D_t < n \end{cases}$$

Queremos calcular:

$$P_{ij} = \mathbb{P}(X_{t+1} = j \mid X_t = i)$$

Caso 1: transición sin reposición ($j \geq n$)

$$P_{ij} = \mathbb{P}(D_t = i - j), \quad \text{para } j \in \{n, \dots, i\}$$

Caso 2: reposición a N

$$P_{iN} = \mathbb{P}(X_t - D_t < n) = \mathbb{P}(D_t > i - n)$$

En otro caso:

$$P_{ij} = 0$$

¿Cómo definimos la recompensa?

Opciones comunes:

¿Cómo definimos la recompensa?

Opciones comunes:

- ▶ Ingresos por ventas
- ▶ Costo de mantener inventario
- ▶ Penalización por faltantes

¿Cómo definimos la recompensa?

Opciones comunes:

- ▶ Ingresos por ventas
- ▶ Costo de mantener inventario
- ▶ Penalización por faltantes

Ejemplo:

$$r(i) = \text{beneficio esperado en estado } i$$

¿Cómo definimos la recompensa?

Opciones comunes:

- ▶ Ingresos por ventas
- ▶ Costo de mantener inventario
- ▶ Penalización por faltantes

Ejemplo:

$r(i)$ = beneficio esperado en estado i

Pregunta:

- ▶ ¿depende solo del estado?
- ▶ ¿o también de la demanda realizada?

Ejemplo de recompensa

Una posible definición:

$$r(i) = \mathbb{E}[\text{ventas} - \text{costos} \mid X_t = i]$$

Ejemplo de recompensa

Una posible definición:

$$r(i) = \mathbb{E}[\text{ventas} - \text{costos} \mid X_t = i]$$

Ejemplo simple:

$$r(i) = p \cdot \mathbb{E}[\text{mín}(i, D_t)] - c \cdot i$$

Ejemplo de recompensa

Una posible definición:

$$r(i) = \mathbb{E}[\text{ventas} - \text{costos} \mid X_t = i]$$

Ejemplo simple:

$$r(i) = p \cdot \mathbb{E}[\text{mín}(i, D_t)] - c \cdot i$$

- ▶ p : precio
- ▶ c : costo de holding

Horizonte

Horizonte finito:

$$t = 0, 1, \dots, T$$

Horizonte

Horizonte finito:

$$t = 0, 1, \dots, T$$

Interpretación:

- ▶ Problema de planificación a T períodos

Horizonte

Horizonte finito:

$$t = 0, 1, \dots, T$$

Interpretación:

- ▶ Problema de planificación a T períodos

Alternativa:

- ▶ horizonte infinito (más adelante)

Modelo como MRP

Tenemos:

- ▶ Estados: $S = \{0, \dots, N\}$
- ▶ Transiciones: P_{ij}
- ▶ Recompensas: $r(i)$
- ▶ Horizonte: T

Modelo como MRP

Tenemos:

- ▶ Estados: $S = \{0, \dots, N\}$
- ▶ Transiciones: P_{ij}
- ▶ Recompensas: $r(i)$
- ▶ Horizonte: T

¡Es un Markov Reward Process!

Extensión natural

¿Y si pudiéramos decidir cuánto reponer?

Extensión natural

¿Y si pudiéramos decidir cuánto reponer?

- ▶ Aparece una acción U_t
- ▶ Cambian las transiciones
- ▶ Cambian las recompensas

Extensión natural

¿Y si pudiéramos decidir cuánto reponer?

- ▶ Aparece una acción U_t
- ▶ Cambian las transiciones
- ▶ Cambian las recompensas

→ Markov Decision Process (MDP)