

Clase 1: El Marco de Decisiones Secuenciales

Métodos para la Gestión - Business School

Daniela Pucci de Farias

Universidad Torcuato Di Tella

Sesión de 180 Minutos

¿Qué se llevan de este curso?

- **Sin un buen marco:**

- Decisiones miopes (enfocadas solo en hoy).
- Reglas *ad hoc* basadas en intuición, no en datos.

- **Con este curso aprenderán a:**

- Modelar problemas complejos de negocios.
- Usar algoritmos para encontrar la estrategia óptima.
- Entender el balance entre "aprender" y "ganar".

Agenda: Bloque 1 (60 min)

La Intuición del Manager

- 1 Definición de Decisiones Secuenciales.
- 2 ¿Dónde fallan los modelos estáticos?
- 3 El Dilema: Exploración vs. Explotación.
- 4 El Marco Agente-Ambiente en RL.

¿Qué es una Decisión Secuencial?

"¿Qué creen que significa?"

¿Qué es una Decisión Secuencial?

"¿Qué creen que significa?"

- No es una decisión aislada (ej. comprar una casa).
- Es una **trayectoria**:
 - 1 Tomo una decisión hoy.
 - 2 El mundo cambia (o yo lo cambio).
 - 3 Mañana enfrento una nueva situación basada en lo que hice hoy.

Dinámico vs. Estático: El Inventario

Visión Estática: "Optimiza el pedido de hoy para minimizar el costo de hoy."

Visión Secuencial: "Si pido de más hoy, tendré costos de almacenamiento mañana, pero si pido de menos, perderé clientes que no volverán."

Insight

Las decisiones secuenciales consideran el **Costo de Oportunidad** del futuro.

[Image of the Reinforcement Learning agent-environment loop]

- El **Agente** es el tomador de decisiones (nosotros, o un algoritmo).
- Tiene un objetivo claro: Maximizar la recompensa total a largo plazo.
- No conoce necesariamente todas las reglas del juego al principio.

- El **Ambiente** es todo lo que está fuera del control del manager.
- Responde a las acciones del agente.
- **Incertidumbre:** El ambiente es estocástico (probabilístico).
- Ejemplo: Lanzamos un producto (Acción) y la demanda puede ser Alta, Media o Baja (Respuesta del Ambiente).

Exploración vs. Explotación

Es el desafío fundamental de la Inteligencia Artificial y de la Estrategia:

- **Explotación:** Sacar provecho de la mejor opción conocida hasta ahora.
- **Exploración:** Probar opciones desconocidas para ver si son mejores.

"Si solo explotas, te quedas atrás. Si solo exploras, nunca ganas dinero."

Discusión: El Dilema del Menú

Eres el dueño de un restaurante exitoso.

- **Opción A (Explotación):** Mantener los 5 platos que siempre se venden bien. Ingreso seguro.
- **Opción B (Exploración):** Quitar 2 platos para probar recetas innovadoras. Podrías duplicar clientes o perder a los actuales.

Pregunta: ¿De qué factores depende que elijas explorar o explotar? (Tiempo, Capital, Competencia).

Modelado y Cadenas de Markov

- 1 La Propiedad de Markov: ¿Qué es un .Estado?
- 2 Matrices de Transición.
- 3 Caso de Estudio: Ghana Telecom (Market Share).
- 4 El concepto de Estado Estacionario.

El concepto de Estado (s_t)

El estado es un resumen" de la situación actual.

- **Estado Pobre:** "Ventas de ayer".
- **Estado Rico:** "Inventario actual + Tendencia de demanda + Precios de competencia".

Regla de Oro

El estado debe contener toda la información necesaria para predecir el futuro *sin mirar el pasado remoto*.

Matemáticamente:

$$P(s_{t+1}|s_t, a_t, s_{t-1}, a_{t-1}, \dots) = P(s_{t+1}|s_t, a_t)$$

En palabras de negocios: "Sabendo dónde estamos hoy (s_t) y qué decidimos hacer (a_t), el pasado es irrelevante para lo que pasará mañana."

Caso: Participación de Mercado

Imagina el mercado de telecomunicaciones en Ghana (Datos reales simplificados). Existen dos competidores principales: **Operador M** y **Operador V**.

- Queremos predecir cómo se moverán los clientes entre ellos.
- Necesitamos entender las probabilidades de "Lealtad" y "Fuga".

- **De los clientes de M:**

- 71.6 % se quedan en M el próximo mes.
- 28.4 % se pasan a V.

- **De los clientes de V:**

- 38.7 % se quedan en V.
- 61.3 % se pasan a M.

La Matriz de Transición (P)

Representamos esto como una matriz:

$$P = \begin{pmatrix} 0,716 & 0,284 \\ 0,613 & 0,387 \end{pmatrix}$$

- Las filas deben sumar 1 (todos los clientes terminan en algún lado).
- Los elementos P_{ij} son las probabilidades de ir del estado i al j .

¿Dónde estaremos mañana?

Si hoy la cuota de mercado es $x_t = [M, V]$, mañana será:

$$x_{t+1} = x_t \cdot P$$

Ejemplo: Si hoy M tiene el 33 % y V el 67 % ($x_0 = [0,33, 0,67]$):

$$[0,33, 0,67] \times \begin{pmatrix} 0,716 & 0,284 \\ 0,613 & 0,387 \end{pmatrix} = [0,647, 0,353]$$

Resultado: ¡En un solo mes M saltó del 33 % al 64.7 %!

¿Qué pasa en el infinito?

Si seguimos multiplicando $x_t \cdot P \cdot P \cdot P \dots$ llegamos al **Estado Estacionario** (π).

- Es el equilibrio del mercado.
- No depende de quién empezó ganando hoy.
- Depende únicamente de las probabilidades de la matriz.

Pregunta para el Manager de V

Tu cuota está cayendo hacia el equilibrio. Tienes dos opciones de inversión:

- 1 **Inversión en Marketing:** Subir tu retención de 38 % a 45 %.
- 2 **Inversión en Ventas:** Robar el 35 % de M en lugar del 28 %.

¿Cuál tiene mayor impacto en el equilibrio de largo plazo? (Lo resolveremos en el Lab).

15 MINUTOS

Preparen sus computadoras para el Bloque de Python.

Laboratorio de Simulación y Recompensas

- 1 Implementación en Python (Numpy).
- 2 Simulación de trayectorias.
- 3 Definiendo la Recompensa (r): Margen vs. Volumen.
- 4 Introducción al Horizonte de decisión.

Paso 1: Configuración Inicial

```
import numpy as np

# Matriz de transición (Ghana Case)
P = np.array([[0.716, 0.284],
               [0.613, 0.387]])

# Estado inicial (M=33%, V=67%)
x = np.array([0.33, 0.67])
```

Paso 2: Evolución a 12 meses

```
print("Mes 0:", x)
for mes in range(1, 13):
    x = np.dot(x, P)
    print(f"Mes {mes}: {np.round(x, 3)}")
```

Tarea en clase: Observen en qué mes los números dejan de cambiar significativamente.

Paso 3: El Estado Estacionario

Podemos elevar la matriz a una potencia grande (P^{100}):

```
P_inf = np.linalg.matrix_power(P, 100)
print("Equilibrio Teórico:\n", P_inf[0])
```

Esto nos dice el market share "final" si no cambiamos nuestra estrategia.

Definiendo la Recompensa (r)

Un MDP necesita saber qué queremos maximizar.

- **No es solo dinero bruto.**
- Es una función $r(s, a)$ que da feedback al agente.

Ejemplo en Gestión de Inventario:

$$r = (\text{Ventas} \times \text{Precio}) - (\text{Costo Stock}) - (\text{Penalidad Faltante})$$

Trampa del Manager: Recompensas Mal Diseñadas

¿Qué pasa si premiamos a un algoritmo de ventas solo por "Número de unidades vendidas"?

Trampa del Manager: Recompensas Mal Diseñadas

¿Qué pasa si premiamos a un algoritmo de ventas solo por "Número de unidades vendidas"?

- El algoritmo pondrá precio \$0.
- **Consecuencia:** Vende todo, pero quiebra la empresa.

Lección

La recompensa debe capturar el **Margen Neto**, no solo el volumen.

Profundizando en el Margen

Imagina el estado i (unidades en stock).

$$r(i) = p \cdot E[\text{mín}(i, D)] - c \cdot i$$

Donde:

- p : Precio de venta.
- D : Demanda aleatoria.
- c : Costo de mantener cada unidad.

Pregunta: ¿Por qué usamos el valor esperado $E[\dots]$? (Porque la demanda es incierta).

¿Hasta cuándo planeamos?

- **Horizonte Finito:** El problema termina en T . (Ej: Temporada navideña, vuelo de avión).
- **Horizonte Infinito:** El negocio continúa indefinidamente. (Ej: Mantenimiento de una represa).

La estrategia óptima cambia radicalmente si sabemos que "mañana cerramos".

- Típico en presupuestos anuales.
- **El efecto "Fin de Año"**: Los managers suelen tomar decisiones agresivas en diciembre para cumplir metas, aunque dañen enero.
- El MDP nos ayudará a evitar esta miopía.

Conclusiones de la Clase 1

- 1 El mundo es secuencial y markoviano.
- 2 Los datos de transición (Ghana) predicen el futuro.
- 3 Definir bien la recompensa (r) es más importante que el algoritmo.

- **Lectura:** Revisen el concepto de Programación Dinámica.
- **Clase 2:** Veremos la **Ecuación de Bellman**.
- Aprenderemos a decidir cuánto cobrar por un pasaje de avión dependiendo de cuántos días faltan.

¡Gracias por su participación!