

Toma de Decisiones Secuenciales y Aprendizaje por Refuerzo

Daniela Pucci de Farias

Universidad Torcuato Di Tella

Modulo 1: Intro y MRPs

- **Modelado y resolución de problemas de toma de decisiones secuenciales bajo incertidumbre.**
- **Programa**
 - **Módulo 1: Procesos markovianos y procesos markovianos con recompensa.**
 - Aplicaciones a control de stock, regímenes de mercado y análisis de participación de empresas en el mercado.
 - **Módulo 2: Procesos markovianos de decisión (MDPs).**
 - Aplicaciones a precificación dinámica, gestión de recursos y optimización de portafolios.
 - **Módulo 3: Aprendizaje por refuerzo.**
 - Aplicación a problemas de navegación y precificación de opciones.

Criterio de Evaluación

La nota estará basada en el siguiente esquema de ponderación:

- Participación en clase, asistencia y puntualidad: 10 %
- Trabajo práctico grupal: 40 %
 - formación de los grupos: 8 de junio
 - Propuesta de proyecto: 29 de junio
 - Presentación oral (15 minutos) y relatorio final: 27 de julio
- Tareas individuales (4 tareas): 50 %
 - Tarea 1: asignada el 2 de junio, fecha de entrega el 9 de junio
 - Tarea 2: asignada el 9 de junio, fecha de entrega el 16 de junio
 - Tarea31: asignada el 23 de junio, fecha de entrega el 30 de junio
 - Tarea 2: asignada el 30 de junio, fecha de entrega el 7 de julio
- Tareas y código python (Google Colab) deben ser entregados por el campus virtual

¿Qué es una Decisión Secuencial?

“¿Qué creen que significa?”

- **Ejemplo: “¿compro esta casa o no?”**

- No es una decisión aislada.
- El problema secuencial **considera una decisión y su impacto en el futuro**: “¿compro hoy o sigo buscando?” o “¿compro o ahorro para el futuro?”.
- Incertidumbres son incorporadas.
- Cada acción puede utilizar información disponible hasta el momento en que debe ser tomada.

- **Dependencia Temporal y Dinámica:**

- La acción de hoy depende de lo que ha pasado anteriormente y altera las opciones disponibles mañana.
- El entorno evoluciona con incertidumbre.

Ejemplo: Gestión de Stock

Visión Miópica: "Optimiza el pedido de hoy para minimizar el costo de hoy."

o

Visión Estática: "Planifica una secuencia rígida de acciones futuras basándose únicamente en la información disponible hoy."

Visión Secuencial: "Si pido de más hoy, tendré costos de almacenamiento mañana; si pido de menos, perderé clientes bajo incertidumbre. Decido hoy considerando ese impacto futuro, sabiendo que mañana podré ajustar mi decisión con la nueva información disponible."

Insight

Las decisiones secuenciales consideran el **Costo de Oportunidad** del futuro y se adaptan dinámicamente la información que va siendo revelada.

Resumiendo: en toma de decisiones secuenciales...

- Las decisiones se toman a lo largo del tiempo.
- Están sujetas a incertidumbre.
- Tienen impacto sobre posibilidades y resultados futuros.

¿Dónde se utiliza?

- Ejemplos:

- precios dinámicos
- decisiones de inversión
- gestión de stock
- control de producción
- agentes que interactúan con un entorno


- Una pregunta:

¿Cómo estructuramos estos problemas?

- Idealmente:

un único marco que sirva para todos

El Marco: Agente y Ambiente



¿Cómo representar el problema matemáticamente?

El Marco Matemático: Jerarquía de Modelos

Para representar estos problemas matemáticamente, utilizamos los **procesos markovianos de decisión (MDPs)**.

- Es el formalismo estándar para la toma de decisiones secuenciales.
- Para dominar los MDPs, iremos de lo más simple (sistemas pasivos) a lo más complejo (sistemas con control):
 - 1 **Procesos markovianos:** Solo dinámica. El sistema evoluciona solo.
 - 2 **Procesos markovianos con recompensa (MRP):** Dinámica + Recompensas (evaluación).
 - 3 **Procesos markovianos de decisión (MDP):** Dinámica + Recompensas + **Control**.

Hoy: Procesos markovianos

Modelaremos la evolución de sistemas autónomos integrando la incertidumbre, utilizando los **procesos markovianos** para formalizar el cambio y el azar.

- **Ejemplo:** ¿Cómo representar condiciones de mercado?
- En cada semana, el mercado se encuentra en uno de tres estados posibles.
- ¿Cómo evolucionan en el tiempo?
 - Descripción probabilística utilizando grafos (**nodos** = estados, **arcos** = transiciones).
 - Nos enfocaremos en procesos a tiempo discreto: **procesos markovianos**.

¿Cómo definir matemáticamente el proceso de regímenes de mercado?

- **Espacio de estados S**

- $S = \{\text{Alcista, Bajista, Estable}\}$
- Los estados pueden ser discretos o continuos.

- **Matriz de transición P**

$$P = \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}$$

Definición Fundamental

La tupla (S, P) define el proceso markoviano. Si S es finito, lo denominamos **cadena de Markov**.

Supongamos que hoy observamos que el mercado es **Bajista**. Como responsables de una estrategia de inversión o logística, necesitamos proyectar el estado del sistema en distintos horizontes:

- **Corto Plazo (Persistencia e Inercia):** ¿Qué tan probable es que el mercado *siga* siendo bajista la próxima semana? ¿Cambia mucho esa probabilidad en la semana 2?
- **Mediano Plazo (Disipación de la Información):** A medida que miramos más lejos (ej. semanas 4 u 8), ¿la condición inicial de hoy sigue pesando, o el sistema se vuelve más impredecible?
- **Largo Plazo (Comportamiento Estructural):** En el límite, cuando el tiempo tiende a infinito, ¿las probabilidades dependen de dónde empezamos hoy, o convergen a un equilibrio estable del mercado?

Representamos la probabilidad de estar en cada estado en el tiempo t con el vector π_t :

$$\pi_t(s) = \text{Prob}(s_t = s)$$

En nuestro ejemplo, si hoy ($t = 0$) el mercado es **Bajista**:

$$\pi_0 = [0 \quad 1 \quad 0]$$

¿Cómo evolucionan esas probabilidades en el tiempo?

Evolución de la Incertidumbre

Si esta semana es **Bajista**, ¿cuál es la probabilidad de ser bajista en el futuro?

- En la próxima semana ($t = 1$)?


$$\pi_1 = [0,15 \text{ } \mathbf{0,8} \text{ } 0,05]$$

- En 2 semanas ($t = 2$)?

$$\pi_2 = [0,267 \text{ } \mathbf{0,663} \text{ } 0,068]$$

- En 10 semanas ($t = 10$)?

$$\pi_{10} = \pi_0 P^{10} \approx [0,591 \text{ } \mathbf{0,343} \text{ } 0,065]$$



Dinámica del Sistema

$$\pi_{t+1} = \pi_t P$$

$$\text{Por inducción: } \pi_t = \pi_0 P^t$$

¿Cuál es la frecuencia de largo plazo de cada régimen en este mercado?
Buscamos la **distribución estacionaria** (π).

- Estacionariedad implica que el sistema ya no cambia: $\pi = \pi P$.
- Resolvemos el sistema sujeto a que las probabilidades sumen 1.

$$\pi_{\infty} = \lim_{t \rightarrow \infty} \pi_0 P^t \approx [0,625 \quad \mathbf{0,3125} \quad 0,0625]$$

Conclusión de Negocio

A largo plazo, el mercado será **Alcista el 62.5 %** del tiempo, **Bajista el 31.25 %** y **Estable el 6.25 %**.

Formalización: La Propiedad de Markov

Para realizar los cálculos anteriores, hemos asumido algo crítico:

"El futuro depende solo del estado presente, no de cómo llegamos a él."

Definition (Propiedad de Markov)

$$P(s_{t+1} \mid s_t, s_{t-1}, \dots, s_0) = P(s_{t+1} \mid s_t)$$

Ejercicio de reflexión: ¿Cambia la probabilidad de un mercado bajista la próxima semana si...

- 1 ...llevamos 5 semanas en racha alcista?
- 2 ...hoy es alcista, pero ayer fue un desastre bajista?

La Propiedad de Markov: Consecuencias

Para realizar los cálculos anteriores, hemos asumido algo crítico:

"El futuro depende solo del estado presente, no de cómo llegamos a él."

Definition (Propiedad de Markov)

$$P(s_{t+1} \mid s_t, s_{t-1}, \dots, s_0) = P(s_{t+1} \mid s_t)$$

- Para un manager, esto simplifica la vida: no necesitamos recordar toda la historia de la empresa.
- **Solo importa el "hoy"**: Si el estado actual está bien diseñado, contiene toda la información necesaria para el futuro.

La Elección del Estado: El Arte del Modelado

El éxito de un modelo depende de qué incluimos (y qué omitimos) en el **Estado**.

- **Suficiencia (Propiedad de Markov):** El estado debe ser un resumen de la historia que contenga *toda* la información necesaria para predecir el futuro.
 - **Riesgo:** Si falta información relevante, el modelo será incorrecto.
- **Eficiencia (Maldición de la dimensionalidad):** Incluir información redundante aumenta el tamaño de S innecesariamente.
 - **Riesgo:** Complejidad computacional inmanejable.
- **El Trade-off del Manager:** En la práctica, debemos balancear la precisión del modelo frente a la viabilidad de resolverlo.

Reflexión: Regímenes de Mercado

En nuestro ejemplo, ¿es suficiente saber que hoy es Alcista? ¿Qué otras variables podrían influir en el cambio de estado?

Debate: ¿Qué podemos modelar como procesos markovianos?

El Desafío

Identifiquen procesos en distintas industrias (Energía, Logística, Finanzas, etc.) que sigan la lógica de "el presente basta para predecir el futuro".

Enfoque del modelado:

- **Estado (S):** ¿Qué información mínima es indispensable hoy?
- **Transición (P):** ¿Qué eventos disparan el cambio?
- **Incertidumbre:** ¿De dónde surge?

Pero falta algo: La Valoración

- **Hasta ahora:** Sabemos cómo evoluciona el sistema (dinámica).
- **La realidad:** No todos los estados tienen el mismo valor para nosotros.
- **Necesidad:** Medir qué tan bueno es estar en un estado según nuestros objetivos.

Pasamos de describir el mundo a evaluarlo.

La Función de Recompensa

En la toma de decisiones, buscamos alcanzar objetivos específicos:

- Maximizar ganancias / Ingresos.
- Minimizar costos operativos / Riesgos.
- Cumplir metas (ej. ganar un juego o alcanzar un nivel de inventario).

Definición

Expresamos estos objetivos a través de la **función de recompensa** $r(s)$, que asigna un valor numérico inmediato a cada estado.

Proceso Markoviano con Recompensa (MRP)

Formalmente, añadimos una nueva dimensión a nuestro modelo:

- Proceso Markoviano: Tupla (S, P)
- **MRP:** Tupla (S, P, r)
 - Donde $r(s)$ es la recompensa (o costo) de estar en el estado s .

Modelando el Valor del Mercado

Definamos los retornos semanales para cada régimen de mercado:

$$r(\text{Alcista}) = +0,005, \quad r(\text{Bajista}) = -0,005, \quad r(\text{Estable}) = 0$$

- $r(s) > 0$: Ganancia (incentivo).
- $r(s) < 0$: Costo o pérdida (penalidad).

Hacia la Evaluación

Con $r(s)$ definido, ya no solo predecimos el estado futuro, sino que podemos **evaluar trayectorias** completas de inversión.

Aplicación: Gestión de Stock

Queremos evaluar nuestra estrategia n/N de gestión de stock para compararla bajo distintos parámetros n y N .

¿Qué debemos considerar antes de formalizar el modelo?

- 1 **Criterio de Optimalidad:** ¿Qué costos y beneficios están involucrados?
- 2 **Estado:** ¿Basta saber el stock actual? ¿Qué otros factores pueden ser importantes?
- 3 **Incertidumbre:** ¿Modelo de demanda? ¿Otras fuentes de incertidumbre?

El Dilema del Modelador

¿Qué pasa al agregar más y más detalles al modelo?

Realismo vs Tratabilidad: ¿Qué información sacrificarías primero para que el modelo sea resoluble?

¿Cómo traducimos la realidad a un modelo MRP?

- **Estado (S):** La "foto" del almacén. ¿Qué variables resumen la información relevante del pasado?
- **Dinámica (P):** Transiciones de estado, impactadas por incertidumbre.
- **Recompensa (R):** ¿Costos y recompensas?
- **Horizonte (T):** Planificación ¿mensual? ¿trimestral? ¿perpetua?

Discusión: ¿Qué constituye el estado?

El estado s debe contener **toda** la información necesaria para predecir el futuro.

- ¿Qué variables son importantes?

Punto de Partida: Modelo Simplificado

Para comenzar, asumiremos un entorno ideal:


- 1 **Demanda i.i.d.:** D_t es independiente del pasado y sigue la misma distribución.
- 2 **Entrega inmediata:** Cuando el nivel de stock baja a n , se repone en el próximo periodo, volviendo a nivel N (*Lead Time* = 0).
- 3 **Estado:** $X_t \in \{0, 1, \dots, N\}$ (Solo el inventario actual).

Matriz de Transición

La transición de estados está dada por $X_{t+1} = f(X_t, D_t)$:

$$X_{t+1} = \begin{cases} X_t - D_t & \text{if } X_t - D_t > n \\ N & \text{if } X_t - D_t \leq n \end{cases}$$

¿Cómo convertimos la función $f(X_t, D_t)$ en una matriz de transición P ?



Mapeo de Probabilidades:

- Si $n+1 \leq j \leq i$: $P_{ij} = \mathbb{P}(D_t = i-j)$
- Si $j = N$: $P_{iN} = \mathbb{P}(D_t \geq i-n)$

La Función de Recompensa

La recompensa inmediata $r(X_t, D_t)$ balancea los ingresos operativos con los costos de estructura en cada periodo t :

$$r(X_t, D_t) = \underbrace{p \cdot \min(X_t, D_t)}_{\text{Ventas}} - \underbrace{h \cdot X_t}_{\text{Stock}} - \underbrace{\pi \cdot \max(0, D_t - X_t)}_{\text{Quiebre}} - \underbrace{K \cdot \mathbb{I}(X_t - D_t \leq n)}_{\text{Orden}}$$

Donde los parámetros económicos están definidos por:

- p : Precio de venta unitario.
- h : Costo unitario de mantener inventario (bodega, seguros, capital inmovilizado).
- π : Penalidad por demanda insatisfecha ($\pi > p$).

La recompensa en ese caso no depende solo del estado sino también de la demanda. Pero la podemos remplazar por

$$r(s) = \mathbb{E}_D [r(s, D)]$$

Dada una situación formalizada como un Proceso de Recompensa de Markov (MRP), nos interesa cuantificar las ganancias o costos esperados en el tiempo:

- **Retorno Esperado bajo Cambios de Régimen:** Si invertimos \$1 en el mercado bajo las condiciones actuales, ¿cuál es el retorno acumulado esperado al cabo de un horizonte de 3 semanas?
- **Análisis de Políticas Fijas:** Considerando un horizonte de planeación de 3 meses, qué parametrización de control de stock es mejor como una estrategia (s, S) , ¿ $(10, 100)$ o $(25, 75)$?

A continuación, desarrollaremos las herramientas analíticas necesarias para responder formalmente a estos interrogantes.

Consideremos una secuencia de estados durante 3 semanas: s_0, s_1, s_2 .

- **Retorno Total (Interés Simple):**

$$G = r(s_0) + r(s_1) + r(s_2)$$

- **El problema:** No conocemos el futuro (es estocástico).
- **La solución:** Usamos el **valor esperado**.

Valor Esperado de la Trayectoria

Dado que empezamos en s_0 , el valor esperado es:

$$E[r(s_0) + r(s_1) + r(s_2) \mid s_0]$$

- **Pregunta:** ¿Con respecto a qué distribución se calcula esta esperanza? Con respecto a las probabilidades de transición P .

Idea Central: Mirar hacia el futuro

No nos basta con la recompensa inmediata; queremos evaluar estados considerando lo que vendrá después.

- Definimos la **función de valor** $V_t(s)$:
 - En nuestro ejemplo, captura la ganancia esperada acumulada (ej. en 3 semanas) dado el estado actual s_0 :

$$V_2(s_0) = E[r(s_0) + r(s_1) + r(s_2) \mid s_0]$$

- **Intuición:** Es una métrica de "horizonte lejano". Nos dice qué tan prometedor es estar en un estado hoy si planeamos seguir en el sistema.

Intuición de la Función Valor

¿Cómo construiríamos un programa que juegue al ajedrez?



La Función de Valor como "Lookup Table"

Pensemos en la función de valor como una tabla de consulta donde cada celda responde: *"¿Cuánto espero ganar si empiezo acá?"*

Estado (s)	Semana 0	Semana 1	Semana 2
Alcista	$V_2(\text{Alc})$	$V_1(\text{Alc})$	$V_0(\text{Alc})$
Bajista	$V_2(\text{Baj})$	$V_1(\text{Baj})$	$V_0(\text{Baj})$
Estable	$V_2(\text{Est})$	$V_1(\text{Est})$	$V_0(\text{Est})$


- Cada fila representa un estado de nuestro espacio S .
- Cada columna representa el tiempo restante o el horizonte.

El Objetivo del curso

Aprenderemos algoritmos (como Programación Dinámica o RL) cuyo fin es **llenar esta tabla con los valores correctos**.

Recursión y el Grafo de Tiempo

- El concepto de función valor es central para la toma de decisiones.
- Utilizaremos la **recursión**: resolver problemas complejos dividiéndolos en sub-problemas más simples.
- Para visualizarlo, expandimos nuestro grafo de estados en el eje del tiempo).



Calculando el Valor por Recursión

Caso Base ($t = 0$): $V_0(s) = r(s)$

Paso de Inducción ($t > 0$): $V_t(s) = r(s) + \sum_{s'} P(s, s') V_{t-1}(s')$

Función Valor Para Regímenes de Mercado

Estado \ Tiempo	Hoy ($t = 2$)	Semana 1 ($t = 1$)	Fin ($t = 0$)
Alcista	0.01259	0.009125	0.005
Bajista	-0.01023	-0.00825	-0.005
Estable	0.00219	0	0

Generalización Matricial del MRP

Resolvemos el sistema completo de forma eficiente usando álgebra lineal.

Algoritmo de Horizonte Finito (MRP)

Sea $\mathbf{r}$ el vector de recompensas y P la matriz de transición:

$$\mathbf{V}_0 = \mathbf{r}$$

$$\mathbf{V}_t = \mathbf{r} + P\mathbf{V}_{t-1} \quad \text{para } t = 1, \dots, T$$

- Esta forma recursiva es la base de la **Programación Dinámica**.
- Implementación directa en Python.
- Nos permite llenar la tabla de valores completa para cualquier horizonte T .

Resumiendo: El MRP

Un **Proceso Markoviano con Recompensa** se define por la tupla (S, P, r) .

- La métrica más común es la **recompensa total esperada** para un horizonte T :

$$V_T(s) = E \left[\sum_{\tau=0}^T r(s_\tau) \mid s_0 = s \right]$$

- $V_t(s)$ se denomina la **función de valor**.

Algoritmo en Forma Matricial

Para implementar en Python, usamos vectores:

$$\mathbf{V}_0 = \mathbf{r}$$

$$\mathbf{V}_t = \mathbf{r} + P\mathbf{V}_{t-1}$$

Donde $\mathbf{V}_t, \mathbf{r} \in \mathbb{R}^{|S|}$ y $P \in \mathbb{R}^{|S| \times |S|}$.

- Asumimos que r y P no dependen de t , entonces el proceso markoviano es homogéneo en el tiempo. Pero se puede extender el resultado al caso en que dependen de t :

$$\begin{aligned}V_0 &= r_0 \\V_t &= r_t + P_t V_{t-1}, \quad t = 1, \dots, T\end{aligned}$$

- También asumimos que la recompensa es determinística, pero podemos incorporar casos en que es aleatoria:

$$\bar{r}(x) = E_w [r(x, w)]$$

- Si la recompensa depende del próximo estado además del actual, también se puede incorporar utilizando:

$$\bar{r}(x) = E [r(x, x_{t+1}) | x_t = x] = \sum_y P(x, y) r(x, y)$$

- En la aplicación a gestión de stock, ¿es nuestra estrategia (s, S) la mejor posible? ¿Por qué fijar el punto de reposición en n y no en $n - 1$? ¿Por qué el tope en N y no el doble? ¿Es posible que otra estructura de política obtenga mejores resultados?
- **Próxima Clase: Del MRP al MDP**
 - **Control Activo:** El gerente ya no sigue una regla; elige la mejor acción según el estado del mundo, adaptándose a múltiples situaciones.

MRPs y MDPs: Un Marco Poderoso

Estamos ante una herramienta flexible para modelar casi cualquier escenario de ****toma de decisiones secuenciales bajo incertidumbre****.

Repaso de Componentes Clave:

- **Estado (S):** La información necesaria para decidir (Propiedad de Markov).
- **Dinámica (P):** Probabilidades de transición.
- **Recompensa (R):** El feedback inmediato del entorno.

La Función de Valor (V)

Es el núcleo del marco: no solo mira el beneficio de hoy, sino el **acumulado esperado a futuro**. Es el puente entre la acción actual y sus consecuencias a largo plazo.

Aplicaciones: Logística, finanzas, robótica, gestión de redes y más.