

Procesos Markovianos de Decisión

Daniela Pucci de Farias

Universidad Torcuato Di Tella

June 2025

Clase 2


- ▶ Tarea 2: Fecha de entrega 23 de junio
- ▶ Trabajo Práctico: Definir los grupos (hasta 3 participantes) y agregarlos en la planilla "Planificación de Grupos"
- ▶ Contenidos de hoy:
 - ▶ Procesos markovianos con recompensa
 - ▶ Resolución por recursión
 - ▶ La función valor
 - ▶ Procesos markovianos de decisión
 - ▶ Espacio de acciones
 - ▶ Políticas de decisión
 - ▶ Algoritmo de programación dinámica
 - ▶ Aplicación: Precificación dinámica
 - ▶ Diseño de la función de recompensa

Proceso Markoviano

- ▶ Proceso markoviano nos da un modelo del ambiente:
 - ▶ Tupla (S, P)
 - ▶ S = espacio de estados
 - ▶ P = matriz de transición
 - ▶ Propiedad de Markov: El estado contiene toda la información histórica que es relevante para el futuro
- ▶ Para toma de decisiones, normalmente estamos interesados en uno o más objetivos:
 - ▶ Maximizar ganancias
 - ▶ Minimizar costos
 - ▶ Ganar un juego, o cumplir con una meta
 - ▶ Minimizar riesgos
 - ▶ ???
- ▶ Expresamos el objetivo a través de la **función de recompensa**

Proceso Markoviano con Recompensa

- ▶ Proceso markoviano: tupla (S, P)
- ▶ Con recompensa: tupla (S, P, r)
 - ▶ $r(x)$ = recompensa (o costo) de estar en el estado x
- ▶ Ejemplo: regímenes de mercado



- ▶ Ganancia o pérdida dependiendo del estado
- ▶ Interpretación: Inversión de \$1 resulta en $\$(1 + r(x))$ al final de una semana con estado x
- ▶ $r(\mathbf{Alcista}) = 0.005$, $r(\mathbf{Bajista}) = -0.005$, $r(\mathbf{Estable}) = 0$
- ▶ Invirtiendo \$1 hoy, cuánta plata habrá después de 3 semanas?

Proceso Markoviano con Recompensa

Invirtiendo \$1 hoy, cuánta plata habrá después de 3 semanas?

- ▶ Consideramos la secuencia de estados x_0, x_1, x_2 .
- ▶ La ganancia es

$$(1 + r(x_0))(1 + r(x_1))(1 + r(x_2)) - 1$$

$$E[(1 + r(x_0))(1 + r(x_1))(1 + r(x_2)) | x_0 = x] - 1$$

- ▶ En $t = 0$, no sabemos cuáles serán los próximos estados x_1, x_2 . Utilizamos el valor esperado!
- ▶ **Cómo calcularlo?**

Una Aproximación

$$\begin{aligned} & \mathbb{E}[(1 + r(x_0))(1 + r(x_1))(1 + r(x_2)) | x_0 = x] - 1 \\ &= \mathbb{E} \left[\sum_{t=0}^2 r(x_t) | x_0 = x \right] + \\ & \underbrace{\mathbb{E} \left[\sum_{t=0}^1 \sum_{\tau=t+1}^2 r(x_t)r(x_\tau) | x_0 = x \right] + \mathbb{E} [r(x_0)r(x_1)r(x_2) | x_0 = x]}_{\approx 0} \\ &\approx \mathbb{E} \left[\sum_{t=0}^2 r(x_t) | x_0 = x \right] \end{aligned}$$

Como r es pequeño, los productos $r(x)r(y)$ son mucho menores que $r(x)$, así que vamos a simplificar la expresión.

- ▶ Vamos a derivar un algoritmo para calcular el valor esperado.
- ▶ También es posible trabajar con la expresión multiplicativa, pero la suma es más comúnmente utilizada.

Evaluando MRPs - Intuición


- ▶ Cómo podríamos construir un jugador de ajedrez?




- ▶ Si tuviéramos una función para evaluar la probabilidad de ganar el juego a partir de cada posición, podríamos elegir la mejor acción
- ▶ Esa función existe y es bien definida para MRPs y MDPs. Se denomina **función valor**.

Evaluando MRPs - Intuición

- ▶ El concepto de función valor es central para la toma de decisiones secuenciales.
- ▶ Otro concepto que vamos a utilizar es la idea de **recursión**.
- ▶ Para eso, vamos a representar el proceso con un nuevo grafo, utilizando el tiempo como segundo eje.



Calculando La Función Valor Por Recursión



$V_t(x)$ = ganancia total esperada empezando en el estado x en tiempo t .

1. Calculamos $V_2(x) = r(x)$.
2. Retrocedemos una semana y calculamos $V_1(x) = r(x) + \sum_y P(x, y) V_2(y)$
3. Retrocedemos otra semana y calculamos $V_0(x) = r(x) + \sum_y P(x, y) V_1(y)$.

► Invertiendo \$1 at $t = 0$, si la semana actual es alcista se espera tener \$1.01259375 después de 3 semanas.

La Función Valor



- ▶ Proceso markoviano con recompensa definido por la tupla (S, P, r)
- ▶ Distintas maneras de combinar $r(x_t)$, $t = 0, 1, \dots$ en un único criterio (suma, multiplicación, medidas de riesgo)
- ▶ Una de las definiciones más comúnmente utilizadas es la recompensa total:

$$V_t(x) = \mathbb{E} \left[\sum_{\tau=t}^T r(x_\tau) | x_t = x \right]$$

- ▶ T es el **horizonte** (finito)

La Función Valor

- ▶ La función valor expresa la ganancia esperada, presente y futura, a partir del estado x
- ▶ Si tenemos una evaluación de cada estado, la podemos utilizar para tomar decisiones
- ▶ Por ejemplo, si tenemos dos acciones posibles en un estado x :



- ▶ Podemos comparar $r_1(x) + \sum_{x'} P_1(x, x') V(x')$ y $r_2(x) + \sum_{x'} P_2(x, x') V(x')$ para decidir qué acción tomar.

Factores de Descuento

- ▶ Tenés dos opciones: ganar \$100 hoy, o ganar \$100 en un año. Es lo mismo?
- ▶ Se puede expandir la definición introduciendo un factor de descuento:

$$V_t(x) = \mathbb{E} \left[\sum_{\tau=t}^T \alpha^{\tau-t} r(x_\tau) | x_t = x \right]$$

- ▶ Descontamos la recompensa $r(x_\tau)$ en el periodo τ por $\alpha^{\tau-t}$
 - ▶ Cuando más grande $\tau - t$, más grande el descuento
- ▶ Interpretación económica (\$1 vale más en el presente que en el futuro)
- ▶ Menos confianza en lo que pasará en el futuro distante que cercano
- ▶ $\alpha = 0$ implica que el criterio de valoración es miope (solo la recompensa inmediata $r(x_t)$ es considerada)
- ▶ $\alpha = 1$ es equivalente a no tener un factor de descuento

Programación Dinámica

- Definimos $V_t(x)$ recursivamente:

$$\begin{aligned}V_T(x) &= r(x) \\V_t(x) &= \mathbb{E} \left[\sum_{\tau=t}^T \alpha^{\tau-t} r(x_\tau) \mid x_t = x \right] \\&= r(x) + \alpha \mathbb{E} \left[\mathbb{E} \left[\sum_{\tau=t+1}^T \alpha^{\tau-(t+1)} r(x_\tau) \mid x_{t+1} = y \right] \mid x_t = x \right] \\&= r(x) + \alpha \sum_y P(x, y) V_{t+1}(y)\end{aligned}$$

- Podemos usar notación de matrices para simplificar las ecuaciones:

$$\begin{aligned}V_T &= r \\V_t &= r + \alpha P V_{t+1}, \quad t = 0, \dots, T-1\end{aligned}$$

donde $r \in \mathbb{R}^{|S|}$, $V_t \in \mathbb{R}^{|S|}$, $P \in \mathbb{R}^{|S| \times |S|}$.

- Podemos implementar el algoritmo en Python.

Observaciones

- Asumimos que r y P no dependen de t , entonces el proceso markoviano es homogéneo en el tiempo. Pero se puede extender el resultado al caso en que dependen de t :

$$\begin{aligned}V_T &= r_T \\V_t &= r_t + \alpha P_t V_{t+1}, \quad t = 0, \dots, T - 1\end{aligned}$$


- También asumimos que la recompensa es determinística, pero podemos incorporar casos en que es aleatoria:

$$\bar{r}(x) = E_w [r(x, w)]$$

- Si la recompensa depende del próximo estado además del actual, también se puede incorporar utilizando:

$$\bar{r}(x) = E [r(x, x_{t+1}) | x_t = x] = \sum_y P(x, y) r(x, y)$$

Procesos Markovianos de Decisión



- ▶ Hasta ahora, consideramos procesos markovianos (S, P, r)
- ▶ Ahora agregaremos decisiones:
 - ▶ Espacio de Estados S
 - ▶ Espacio de Acciones A
 - ▶ Recompensa $r_a(x)$ y probabilidad de transición $P_a(x, y)$
 - ▶ Ahora dependen de la acción a además del estado x
- ▶ Proceso Markoviano de Decisión caracterizado por la tupla (S, A, P, r)


Ejemplo: Precios Dinámicos

Un vuelo tiene capacidad para 100 pasajeros. A cada día llega un posible pasajero que acepta pagar un precio máximo m por el vuelo. Ese precio es desconocido a la aerolínea y distribuido con probabilidades $\text{Prob}(m = 50) = 1/2$, $\text{Prob}(m = 70) = 1/3$, $\text{Prob}(m = 120) = 1/6$.

Qué precio la aerolínea debe ofrecer a cada día para maximizar su ganancia?

Ejemplo: Precios Dinámicos - Modelo MDP - (S, A, P, r)

Un vuelo tiene capacidad para 100 pasajeros. A cada día llega un posible pasajero que acepta pagar un precio máximo m por el vuelo. Ese precio es desconocido a la aerolínea y distribuido con probabilidades $\text{Prob}(m = 50) = 1/2$, $\text{Prob}(m = 70) = 1/3$, $\text{Prob}(m = 120) = 1/6$.



a	$P_a(x, x+1) = \text{Prob}(m \geq a) = p_a$	$r_a(x) = a p_a$
50	1	50
70	0.5	35
120	1/6	20

Ejemplo: Precios Dinámicos - Modelo MDP - (S, A, P, r)

Un vuelo tiene capacidad para 100 pasajeros. A cada día llega un posible pasajero que acepta pagar un precio máximo m por el vuelo. Ese precio es desconocido a la aerolínea y distribuido con probabilidades $\text{Prob}(m = 50) = 1/2$, $\text{Prob}(m = 70) = 1/3$, $\text{Prob}(m = 120) = 1/6$.

- ▶ **Espacio de estados** $S = \{0, 1, \dots, 100\}$
 - ▶ Estado x corresponde a la ocupación actual del avión, entonces $S = \{0, 1, \dots, 100\}$
- ▶ **Espacio de acciones** $A = \{50, 70, 120\}$
 - ▶ Acción a corresponde al precio cotizado cuando llega un posible pasajero, entonces $A = \{50, 70, 120\}$

Ejemplo: Precios Dinámicos - Modelo MDP - (S, A, P, r)

Un vuelo tiene capacidad para 100 pasajeros. A cada día llega un posible pasajero que acepta pagar un precio máximo m por el vuelo. Ese precio es desconocido a la aerolínea y distribuido con probabilidades $\text{Prob}(m = 50) = 1/2$, $\text{Prob}(m = 70) = 1/3$, $\text{Prob}(m = 120) = 1/6$.

► Matriz de transición

- Con el vuelo lleno (estado $x = 100$), asumiendo que no se permiten cancelaciones: $P_a(100, 100) = 1$ (el vuelo se mantiene lleno)
- Si $x < 100$, si ofrecemos un asiento a precio a , el posible pasajero acepta ese precio si $m \geq a$. Entonces:

$$P_a(x, x+1) = \text{Prob}(m \geq a) \equiv p_a, \quad \forall x < 100, a \in A$$

$$P_a(x, x) = \text{Prob}(m < a) \equiv 1 - p_a, \quad \forall x < 100, a \in A$$

► Recompensa

- Si el posible pasajero acepta el precio, recibimos a ; si no acepta, no recibimos nada. Entonces:

$$r_a(x) = ap_a, \quad \forall x = 0, \dots, 99, a \in A$$

$$r_a(100) = 0, \quad \forall a \in A$$

Políticas de Decisión

- ▶ Dado un MDP, necesitamos determinar cómo tomar acciones. Estrategias especificando qué acción tomar son denominadas **políticas de decisión**.

- ▶ Qué información debemos utilizar al tomar una acción?
Una opción son políticas que utilizan toda la información que tenemos hasta ese momento:

$$a_t = u_t(x_0, a_0, r_0, x_1, a_1, r_1, \dots, x_{t-1}, a_{t-1}, r_{t-1}, x_t).$$

Otro extremo serían políticas que no utilizan ninguna información: $a_t = u$.

- ▶ Queremos encontrar políticas a_t que optimicen un criterio de optimalidad. Consideremos la recompensa total esperada:

$$\max_u \mathbb{E} \left[\sum_{t=0}^T r_{a_t}(x_t) \right]$$

- ▶ Resulta que, para obtener optimalidad, es suficiente que la política dependa solamente del estado actual:

$$a_t = u_t(x_t)$$

Política Óptima

- ▶ $u_t : S \mapsto A$ es una política indicando, para cada periodo t y estado x , una acción $a = u_t(x)$.
- ▶ Existe una política óptima u^* que maximiza la suma esperada de recompensas.
- ▶ Nuestro problema se vuelve:

$$\max_u \mathbb{E} \left[\sum_{t=0}^T r_u(x_t) \right]$$

- ▶ Considerando el horizonte T , el número de políticas posibles es $|A|^{|S| \times T}$
 - ▶ Número de políticas crece exponencialmente con el número de estados y el horizonte
- ▶ Pero podemos resolver el problema con más eficiencia. . .


Principio de Optimalidad

“Una política es óptima si, cualquiera sea el estado inicial y la primera acción tomada, las decisiones subsiguientes constituyen también una política óptima desde el nuevo estado.” — Richard Bellman

- ▶ Por ejemplo, si deseamos tomar el camino más corto entre puntos A y B , y ese camino pasa por un punto C , entonces el subcamino entre C y B es el más corto entre esos dos puntos.
- ▶ En general para MDPs, la política óptima empezando en el periodo $t + 1$ es óptima también para el problema empezando en el periodo t , entonces se puede resolver por recursión, empezando por $t = T$ y retrocediendo hasta $t = 0$.

Programación Dinámica Para MDPs

1. En $t = T$, elegimos $u_T^*(x) = \arg \max_{a \in A} r_a(x)$. El valor de estar en un estado x en $t = T$ es $V_T^*(x) = \max_a r_a(x)$.
2. Si conocemos el valor óptimo para cada estado x en el periodo $T + 1$: $V_{T+1}^*(x) = \max_u \mathbb{E} \left[\sum_{\tau=t+1}^T \alpha^{\tau-(t+1)} r_u(x_\tau) | x_{t+1} = x \right]$ podemos encontrar el valor y la política óptima en el periodo t



Para cada acción a , recibimos: $r_a(x) + \alpha \sum_y P_a(x, y) V_{t+1}^*(y)$
La mejor acción maximiza esa expresión. Entonces:

$$\begin{aligned} V_t^*(x) &= \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_{t+1}^*(y) \right\} \\ u_t^*(x) &= \arg \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_{t+1}^*(y) \right\} \end{aligned}$$

Programación Dinámica Para MDPs

1. Hacemos $t = T$. Calculamos

$$V_T^*(x) = \max_a r_a(x).$$

2. Hacemos $t = t - 1$. Calculamos

$$V_t^*(x) = \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_{t+1}^*(y) \right\}$$

.


3. Si $t = 0$, fin. Si no, volvemos al paso 2.

Derivamos la política óptima a partir de la función valor V^* :

$$u_t^*(x) = \arg \max_{a \in A} \left\{ r_a(x) + \alpha \sum_y P_a(x, y) V_{t+1}^*(y) \right\}$$

Ejemplo: Precios Dinámicos - Modelo MDP - (S, A, P, r)


Un vuelo tiene capacidad para 100 pasajeros. A cada día llega un posible pasajero que acepta pagar un precio máximo m por el vuelo. Ese precio es desconocido a la aerolínea y distribuido con probabilidades $\text{Prob}(m = 50) = 1/2$, $\text{Prob}(m = 70) = 1/3$, $\text{Prob}(m = 120) = 1/6$.



a	$P_a(x, x + 1)$	$r_a(x)$
50	1	50
70	0.5	35
120	1/6	20


Vamos a encontrar la política óptima con Python.

Precios Dinámicos - Política Óptima



Precios Dinámicos - Ganancia

Ganancia esperada empezando con el avión vacío



Estructura de Políticas

- ▶ En el ejemplo anterior, la política óptima tiene una estructura intuitiva.
- ▶ En otras aplicaciones, también se espera que la política óptima tenga ciertas características.
 - ▶ Gestión de inventarios: comprar más mercadería basándose en límites.
 - ▶ Navegación: objetivos pueden ser equivalentes a buscar el camino más corto.
- ▶ En situaciones prácticas, a veces es preferible una política con estructura interpretable a una más compleja.
- ▶ En situaciones de aprendizaje por refuerzo, se puede directamente reducir la búsqueda a políticas con ciertas estructuras.

Diseño de La Función de Recompensa

- Gestión de inventario (maximizar ganancia)

$$r(x, a) = E[\alpha \min(d, x + a) - \beta(x + a)]$$

donde el estado x es el nivel x de inventario, la acción a define cuánto aumentar el inventario, y d es una variable aleatoria representando la demanda.

- Navegación (tiempo a destino)

$$r(x) = \begin{cases} 1 & \text{if } x \neq x^* \\ 0 & \text{if } x = x^* \end{cases}$$

donde el estado x es la posición y x^* es la posición final.

- Juego de ajedrez

$$r(x) = \begin{cases} 1 & \text{if } x \in A \\ -1 & \text{if } x \in B \\ 0 & \text{if } x \notin A \cup B \end{cases}$$

donde el estado x es la configuración del tablero y A , B son los conjuntos de configuraciones donde el jugador gana y pierde, respectivamente.

Diseño de La Función de Recompensa:

- ▶ En algunas situaciones, es necesario combinar varios criterios en una función de recompensa
 - ▶ Gestión de usina eólica con backup de gas natural

$$r(x) = E[\alpha x + \beta \max(d - x, 0)]$$

donde el estado x es la potencia siendo proporcionada por gás y d es una variable aleatoria indicando la demanda no atendida por energia eólica.

- ▶ En situaciones de aprendizaje por refuerzo, más consideraciones son necesarias al diseñar la función de recompensa
 - ▶ la función puede ayudar o dificultar el aprendizaje (por ejemplo, funciones esparsas son difíciles de entrenar)
 - ▶ se puede deducir la función de recompensa a partir de un agente humano con buen desempeño (aprendizaje por refuerzo inverso)
 - ▶ Pero también es posible que humanos implícitamente utilicen funciones de recompensa subóptimas (ejemplo: AlphaGo)