

Toma de Decisiones Secuenciales y Aprendizaje por Refuerzo

Daniela Pucci de Farias

Universidad Torcuato Di Tella

Modulo 2: MDPs

Resumiendo: El Proceso de Recompensa (MRP)

En la última clase, exploramos el marco de MRPs para modelar la evolución de sistemas bajo incertidumbre. MRPs se caracterizan por la tupla (S, P, R) :

- **Estado (S):** Representación compacta del presente.
- **Transición (P):** Probabilidad pasiva de cambio ($s \rightarrow s'$).
- **Recompensa (R):** Valor asociado a cada estado visitado.

Función Valor

Uno de los conceptos centrales en MRP es el de la función valor $V_t(s)$, que captura el valor esperado presente y futuro de estar en un cierto estado, en un cierto momento en el tiempo.

En el contexto de MRPs, la función valor nos permite evaluar, por ejemplo, reglas fijas que usamos para tomar decisiones, como las estrategias de control de stock que vimos.

Procesos Markovianos de Decisión (MDP)

El MDP introduce la capacidad de afectar el ambiente mediante acciones.



- **Acciones (A):** El conjunto de decisiones disponibles en cada estado.
- **Transiciones Dinámicas $P_a(s, s')$:**
 - El azar sigue existiendo, pero la acción a afecta transiciones.
- **Recompensa $r_a(s)$:**
 - El beneficio ya no depende solo de dónde estamos, sino de también **qué hacemos** en ese momento.

Definición Formal

Un MDP es la tupla (S, A, P, r) que modela el ciclo interactivo de decisión.

Discusión: Eres el Gerente de una Aerolínea

Escenario: Entra una solicitud de reserva.

- **Opción A:** Cobrar \$50 (venta casi segura).
- **Opción B:** Cobrar \$120 (mayor margen, pero riesgo de no vender).

¿Qué harías tú?

- ¿Qué información considerarías para decidir?
- ¿Cómo cambia tu decisión si falta 1 día vs. 30 días para el vuelo?
- ¿Existe una regla simple que funcione siempre?

Históricamente, muchas decisiones de precios se tomaban mediante reglas simples y experiencia acumulada.

- **Precios por segmentos fijos:** Turista \$70, Primera Clase \$200.
- **Heurísticas de ocupación:**
 - Si el avión está al 50 % un mes antes, subir el precio.
 - Si falta una semana y sobran asientos, hacer descuentos.
- **Costo más margen:** Calcular el costo del asiento y agregar un porcentaje fijo.

Estas reglas suelen capturar parte de la intuición del problema, pero no cuantifican explícitamente el valor futuro de un asiento disponible.

¿Cuáles son las limitaciones de las heurísticas?

Aunque suelen ser intuitivas y fáciles de implementar, las reglas fijas presentan algunas limitaciones:

- **Rigidez:** Pueden reaccionar mal ante cambios inesperados en la demanda.
- **Miopía:** No cuantifican adecuadamente el impacto de las decisiones actuales sobre oportunidades futuras.
- **Inconsistencia:** Distintos tomadores de decisión pueden llegar a conclusiones diferentes usando la misma información.

¿Qué necesitamos?

Para mejorar estas decisiones necesitamos:

- 1 Un modelo de la incertidumbre del mercado.
- 2 Una forma de cuantificar el valor de las oportunidades futuras.

Ingrediente 1: Modelar la Incertidumbre

Para tomar decisiones racionales necesitamos un modelo de la demanda. A partir de datos históricos y segmentación de clientes, la aerolínea estima cómo se distribuye la disposición a pagar de los pasajeros.

Cada día llega un cliente potencial con una disposición a pagar máxima m . La aerolínea no conoce el valor de m para cada cliente, pero sí su distribución:

- $P(m = 50) = 1/2$
- $P(m = 70) = 1/3$
- $P(m = 120) = 1/6$

¿¿Cómo interpretarías esta distribución?

Este modelo captura la incertidumbre del mercado.

Ingrediente 2: Cuantificar el Valor Futuro

Necesitamos cuantificar el impacto futuro de una decisión tomada hoy.

- ¿Cuánto vale realmente un asiento libre?
- ¿Cómo influye ese valor en el precio que deberíamos ofrecer?

Idea: Asignamos un valor a cada estado. Ese valor resume todas las recompensas futuras que esperamos obtener desde allí.

Regla de Decisión

Elegimos la acción a que maximiza:

$$\underbrace{r_a(s)}_{\text{Beneficio inmediato}} + \underbrace{\mathbb{E}[V_{t-1}(s')|s, a]}_{\text{Valor de las oportunidades futuras}}$$


$V_{t-1}(s')$ resume todo lo que esperamos ganar desde el próximo período hasta el final del horizonte si seguimos actuando de manera óptima.

Ejemplo: Precios Dinámicos - Modelo MDP - (S, A, P, r)

Un vuelo tiene capacidad para 100 pasajeros. Cada día llega un cliente potencial con disposición a pagar un precio máximo m .

Incertidumbre del Mercado: La aerolínea desconoce m , pero conoce su distribución:

- $P(m = 50) = 1/2$, $P(m = 70) = 1/3$, $P(m = 120) = 1/6$.



a	$P_a(x, x+1) = \text{Prob}(m \geq a) = p_a$	$r_a(x) = ap_a$
50	1	50
70	0.5	35
120	1/6	20

Ejemplo: Precios Dinámicos - Modelo MDP - (S, A, P, r)

Formalizando:

- **Espacio de estados** $S = \{0, 1, \dots, 100\}$
- **Espacio de acciones** $A = \{50, 70, 120\}$
- **Matriz de transición** P

$$P_a(100, 100) = 1, \forall a \in A$$

$$P_a(x, x+1) = \text{Prob}(m \geq a) \equiv p_a, \forall x < 100, a \in A$$

$$P_a(x, x) = \text{Prob}(m < a) \equiv 1 - p_a, \forall x < 100, a \in A$$

- **Recompensa** r

$$r_a(x) = ap_a, \forall x = 0, \dots, 99, a \in A$$

$$r_a(100) = 0, \forall a \in A$$

Regla de Decisión Intuitiva

Elegimos la acción a que maximiza:


$$\underbrace{r_a(s)}_{\text{Presente}} + \underbrace{\mathbb{E}[V_{t-1}(s')]}_{\text{Futuro Prometido}}$$

- Si conocemos a la función valor, esa puede ser una buena manera de decidir (de hecho, es óptima).
- ¿Cómo calcularla?

Recordamos la Recursión para MRPs...

Caso Base ($t = 0$): $V_0(s) = r(s)$

Paso de Inducción ($t > 0$): $V_t(s) = r(s) + \sum_{s'} P(s, s') V_{t-1}(s')$



Ahora vamos a hacer lo mismo, pero para MDPs.


Inducción Hacia Atrás: El Final del Horizonte

Sea $V_t(s)$ el valor máximo esperado faltando t días para el vuelo con s asientos ocupados.

Paso 1: Caso Base ($t = 0$) En el momento del despegue, no hay más oportunidades de venta.

- Si el avión despegue, el valor de los asientos libres es nulo.
- $V_0(s) = \max_a r_a(s)$ para todo $s \in \{0, \dots, 100\}$.

$$V_0(s) = \max_a r_a(s)$$




Nota: En $t = 0$, el futuro no importa. Tomamos la acción que maximice la recompensa inmediata.

Inducción Hacia Atrás: El Salto a $t = 1$

Faltando 1 día ($t = 1$), si tenemos s ocupados y ofrecemos el precio a :

- **Venta (p_a)**: Ganamos a y pasamos a $s + 1$ en $t = 0$.
- **No Venta ($1 - p_a$)**: No ganamos nada y seguimos en s en $t = 0$.



Valor de la acción a en el estado s :

$$\begin{aligned} Q_1(s, a) &= p_a[a + V_0(s + 1)] + (1 - p_a)[V_0(s)] \\ &= \underbrace{ap_a}_{r_a(s)} + \sum_{s' \in \{s, s+1\}} P_a(s, s') V_0(s') \end{aligned}$$

La Ecuación de Bellman: Optimización General

Para encontrar el valor máximo en $t = 1$, elegimos el precio que maximiza la suma de la recompensa inmediata y el valor futuro:

$$V_1(s) = \max_{a \in A} \left\{ r_a(s) + \sum_{s'} P_a(s, s') V_0(s') \right\}$$

Generalizando para cualquier día t :

Ecuación de Bellman (Horizonte Finito)

$$V_0^*(s) = \max_{a \in A} \{ r_a(s) \}$$

$$V_t^*(s) = \max_{a \in A} \left\{ r_a(s) + \sum_{s'} P_a(s, s') V_{t-1}^*(s') \right\}, \quad t = 1, \dots, T$$

V^* es la **función de valor óptima**.

Ecuación de Bellman (Horizonte Finito)

$$V_0^*(s) = \max_{a \in A} \{r_a(s)\}$$

$$V_t^*(s) = \max_{a \in A} \left\{ r_a(s) + \sum_{s'} P_a(s, s') V_{t-1}^*(s') \right\}, \quad t = 1, \dots, T$$

¿Qué acciones tomamos?

La **acción óptima** es una función del estado s y horizonte t , l:

$$u_t^*(s) \in \arg \max_{a \in A} \left\{ r_a(s) + \sum_{s'} P_a(s, s') V_{t-1}^*(s') \right\}$$

Para entender mejor en qué sentido una acción es óptima, vamos a utilizar el concepto de **políticas**.

¿Qué es una Política? El «Manual de Instrucciones»

Una **política** (u) es el cerebro del agente: una regla que dicta qué acción tomar en cada situación posible.

- **Ejemplo Aerolínea:** Un mapeo de estados y tiempo a acciones ($S \times \mathbb{N} \rightarrow A$).
- «Si quedan 10 asientos y falta 1 día $\rightarrow$ ofrece precio de 50».

Tipos de Políticas: ¿Qué información usa el agente?

- **Markoviana:** $a_t = u_t(s_t)$. Solo mira el presente (y el tiempo restante).
- **Estacionaria:** $a_t = u(s_t)$. La regla no cambia con el tiempo.
- **Basada en el Historial:** $a_t = u_t(s_0, a_0, \dots, x_t)$. Mira todo el pasado.
- **Aleatoria:** $a_t(s) = a$ con probabilidad $q_t(s, a)$.
- ...

Definición Formal de Optimalidad

Buscamos una política u^* que sea la mejor entre **todas** las estrategias imaginables ($\mathcal{U}$) que no utilicen información del futuro, la cual es desconocida al decidir (**no anticipativas**).

El Criterio: Maximizar la suma de recompensas futuras.

$$V^*(s) = \max_{u \in \mathcal{U}} \mathbb{E}_u \left[\sum_{t=0}^T r_{u_t}(x_t) \middle| x_0 = s \right]$$

- $\mathcal{U}$ incluye políticas complejas que recuerdan todo el historial.
- $V^*(s)$ es el valor máximo que podemos extraer del sistema desde s .

Teorema Fundamental

Para un MDP, **basta con considerar políticas Markovianas**. El pasado no aporta valor extra si conocemos el estado actual x_t .

Principio de Optimalidad de Bellman

“Una política es óptima si, cualquiera sea el estado inicial y la primera acción tomada, las decisiones subsiguientes constituyen también una política óptima desde el nuevo estado.”

— Richard Bellman

Intuición:

- No puedes ser óptimo hoy si tu plan para mañana es mediocre.
- El camino óptimo de A a C debe contener el camino óptimo de B a C .

Consecuencia

Podemos romper un problema gigante en sub-problemas recursivos. Esto reduce la «explosión combinatoria» de $|A|^{|S| \times T}$ opciones a una búsqueda día por día.

Ejemplo: Precios Dinámicos - Solución Numérica

Ahora implementaremos la solución al problema de precios dinámicos en Python.

La estructura de $V_t(s)$ garantiza la consistencia económica y puede derivarse por inducción hacia atrás:

- **Tiempo:** $V_t(s)$ crece con t (más tiempo disponible implica más oportunidades de venta).
- **Inventario:** $V_t(s)$ es decreciente y **cóncava** en s .
 - Cuanto más lleno el avión, menor posibilidad de ganancias futuras, pero asientos restantes se pueden vender a precios más altos.


Reorganizando Bellman para resaltar el *trade-off* económico:

$$Q_t(s, a) = \underbrace{p_a a}_{\text{Ingreso Exp.}} - \underbrace{p_a [V_{t-1}(s) - V_{t-1}(s+1)]}_{\text{Costo de Oportunidad Exp.}} + \underbrace{V_{t-1}(s)}_{\text{Valor Base}}$$

- Definimos $\Delta V_{t-1}(s) = V_{t-1}(s) - V_{t-1}(s+1)$ como el valor marginal de un asiento libre.
- **Regla de Oro:** Solo vendemos si el precio a supera la pérdida de valor futuro esperado ΔV .
- **Escasez:** Como V es cóncava y decreciente, $\Delta V_t(s) \geq 0$ y aumenta al llenarse el avión.

Insights Cualitativos - Estructura de la Política Óptima

En el ejemplo de precios dinámicos, la política óptima presenta una estructura intuitiva.



- **Umbral en Precio:** Regiones de decisión separadas por fronteras en el plano (s, t) .
- En modelos simplificados de otras aplicaciones, eso también suele suceder:
 - **Gestión de Inventarios:** Decisiones de reabastecimiento basadas en umbrales críticos.

De la Política Óptima a Reglas de Negocio

En muchos problemas reales, la política óptima es demasiado compleja para implementarse directamente.

La programación dinámica puede utilizarse para:

- descubrir la estructura de buenas decisiones;
- identificar variables relevantes;
- validar o mejorar heurísticas existentes;
- diseñar reglas simples con desempeño cercano al óptimo.

Ejemplo

En revenue management, los MDPs ayudaron a entender y perfeccionar heurísticas existentes, además de inspirar nuevas estrategias de protección de asientos y segmentación de tarifas que transformaron la industria.

- Calculamos la función valor V^* recursivamente:

Algoritmo con Horizonte T

- 1 **Base:** Para $t = T$, calculamos la recompensa final: $V_T^*(x) = \max_a r_a(x)$.
- 2 **Inducción:** Para $t = T - 1, \dots, 0$, resolvemos:

$$V_t^*(x) = \max_{a \in A} \left\{ r_a(x) + \sum_y P_a(x, y) V_{t+1}^*(y) \right\}$$

- La política óptima $u_t^*(x)$ es el argumento que maximiza dicha expresión.

Ejemplo: Pesca de Salmones


Cada año debemos decidir cuánto salmón pescar en una determinada área. Cada ejemplar genera una ganancia fija, pero una pesca excesiva impacta negativamente en la población del año siguiente.

El objetivo es maximizar la ganancia total acumulada. ¿Cómo modelamos este problema?

Consideremos una versión simplificada para visualizar el proceso:

- **Acciones:** En cada año, decidimos no pescar, pescar una proporción moderada o agresiva de la biomasa.
- **Estados:** La población se categoriza en 4 niveles: *Vacío*, *Bajo*, *Mediano* y *Alto*.


Pesca de Salmones: Modelo



¿Qué decisiones tomar? Vamos a resolver el problema con Python.


Pesca de Salmones: Resultados

- Visualización de la política óptima:
 - La acción óptima depende tanto del **estado** como del **tiempo restante**.
- ¿Cómo impacta la elección del horizonte T en nuestras decisiones?



Pesca de Salmones: Opción de No Repoblar

- Si en el estado *vacío* existe la opción de **no repoblar**, ¿cómo cambia el análisis? ¿Bajo qué condiciones es rentable repoblar?



- Para obtener la política óptima, debemos especificar el horizonte T .
 - La acción óptima varía según la distancia al horizonte final.
 - ¿Qué horizonte debemos elegir en la vida real?
 - A veces la elección es natural:
 - Subastas o campañas electorales.
 - Logística y operaciones con fecha crítica.
 - Pricing de pasajes aéreos.
- ¿Qué hacer si no hay un final claro para el proceso?
- Podemos extender el modelo hacia un **horizonte infinito**.

MDPs con Horizonte Infinito

Buscamos maximizar la ganancia esperada acumulada considerando un **factor de descuento** $\alpha \in [0, 1)$:

$$V^*(s) = \max_u \mathbb{E} \left[\sum_{t=0}^{\infty} \alpha^t r_{u_t}(x_t) \middle| x_0 = s \right]$$

- **Convergencia:** El factor de descuento α garantiza que la suma sea finita, incluso si el proceso nunca termina.
- **Función de Valor:** A diferencia del horizonte finito, aquí la función de valor óptima depende solo del estado x , no del tiempo: $V^*(x)$.
- **Política Estacionaria:** La decisión óptima también depende solo del estado x : $u^*(x)$.

Factor de Descuento (α)

¿Por qué descontar el futuro? El parámetro α captura tres conceptos clave:

- 1 **Preferencia Temporal:** Un dólar hoy vale más que un dólar mañana (costo de oportunidad/interés).
- 2 **Incertidumbre (Supervivencia):** Podemos interpretar $(1 - \alpha)$ como la probabilidad de que el proceso termine en cada paso (ej. que la empresa quiebre o el salmón se extinga).
- 3 **Horizonte Efectivo:** Aunque el horizonte es infinito, el agente solo mira hacia el futuro una distancia aproximada de $1/(1 - \alpha)$ pasos.

Comportamiento del Agente

- $\alpha \rightarrow 1$ (**Paciente**): Decisiones basadas en sostenibilidad a largo plazo.
- $\alpha \rightarrow 0$ (**Miope**): Decisiones »codiciosas« que solo buscan el beneficio inmediato.

Ecuación de Bellman

- Con descuento α , la recursión en horizonte finito es:

$$V_t^*(s) = \max_{a \in A} \left\{ r_a(s) + \alpha \sum_{s'} P_a(s, s') V_{t-1}^*(s') \right\}$$

- ¿Qué sucede cuando el tiempo restante es muy grande ($T \rightarrow \infty$)?
- La función valor tiende a estabilizarse: $V_t \approx V_{t+1} \approx V^*$.

Ecuación de Bellman con Horizonte Infinito

$$V^*(s) = \max_{a \in A} \left\{ r_a(s) + \alpha \sum_{s'} P_a(s, s') V^*(s') \right\}$$

- ¿Cómo resolver la ecuación de Bellman?

Iteración de Valor (VI)

La iteración de valor toma el algoritmo recursivo de programación dinámica para horizonte finito y lo extiende a $T = \infty$. Solo se agrega un criterio de parada, basado en la convergencia de V^*

Algoritmo VI

- 1 Inicializamos $V_0(s) = 0$ para todo s . (También funciona con otros valores iniciales.)
- 2 **Actualización:** $V_{k+1}(s) \leftarrow \max_a \{r_a(s) + \alpha \sum P V_k\}$.
- 3 **Parada:** Si el cambio máximo es insignificante ($|V_{k+1} - V_k| < \epsilon$), terminamos.

¿Y si nos enfocamos en la Política?

Hasta ahora hemos iterado sobre la función de valor:

$$V_0 \rightarrow V_1 \rightarrow V_2 \rightarrow \dots \rightarrow V^*$$

Pero el objetivo final no es conocer V^* .


Queremos encontrar la política óptima u^* .

Pregunta

¿Podemos diseñar un algoritmo que trabaje directamente sobre políticas en lugar de funciones de valor?

El Ciclo de Mejora: Actor-Crítico

Consideramos un bucle de retroalimentación fundamental en RL:



- **Resultado Fundamental:** Si u' es la política codiciosa con respecto a V^u , entonces la nueva política es garantizadamente globalmente mejor o igual:

$$V^{u'} \geq V^u$$

- **Convergencia:** Hay número finito de políticas, por ende este ciclo **debe** terminar en la política óptima u^* en un número finito de pasos.

Iteración de Política (PI)

Algoritmo de Iteración de Política

❶ **Inicialización** ($k = 0$): Elegir una política arbitraria $u_0(s)$.

❷ **Evaluación**: Calcular V^{u_k} resolviendo el sistema:

$$V^{u_k}(s) = r_{u_k}(s) + \alpha \sum_{s' \in S} P_{u_k}(s, s') V^{u_k}(s')$$

❸ **Mejora**: Encontrar una política *greedy* u_{k+1} respecto a V^{u_k} :

$$u_{k+1}(s) = \arg \max_{a \in A} \left\{ r_a(s) + \alpha \sum_{s' \in S} P_a(s, s') V^{u_k}(s') \right\}$$

❹ **Parada**: Si $V_{u_{k+1}} = V_{u_k}$, terminar. Si no, $k \leftarrow k + 1$ y volver al paso 2.

Algoritmo de Iteración de Política

❶ **Inicialización** ($k = 0$): Elegir una política arbitraria $u_0(s)$.

❷ **Evaluación**: Calcular V_{u_k} resolviendo el sistema:

$$V_{u_k} = r_{u_k} + \alpha P_{u_k} V_{u_k}$$

❸ **Mejora**: Encontrar una política *greedy* u_{k+1} respecto a V^{u_k} :

$$u_{k+1} = \arg \max_{u \in A} \{r_u + \alpha P_u V_{u_k}\}$$

❹ **Parada**: Si $V_{u_{k+1}} = V_{u_k}$, terminar. Si no, $k \leftarrow k + 1$ y volver al paso 2.

Iteración de Valor (VI) vs. Iteración de Política (PI)

- **Convergencia:** Como el número de políticas estacionarias es finito ($|A|^{|S|}$), la iteración de política siempre termina en la solución exacta.
- **Complejidad por iteración:**
 - **PI** es más costosa (requiere resolver un sistema lineal para evaluar V^u).
 - **VI** es más ligera (solo requiere una pasada de maximización).
- **Velocidad de convergencia:**
 - **PI** suele requerir muy pocas iteraciones para converger.
 - **VI** puede ser muy lenta, especialmente cuando el factor de descuento α es cercano a 1.
- **En la práctica:** Aunque el peor caso para PI es exponencial en $|S|$, en problemas reales suele ser extremadamente eficiente.
- Ambos métodos son los pilares fundamentales para el desarrollo de algoritmos de **Aprendizaje por Refuerzo (RL)**.

De Iteración de Política a Rollout

La Iteración de Política repite:

$$u \rightarrow V^u \rightarrow u' \rightarrow V^{u'} \rightarrow \dots$$

hasta alcanzar la política óptima.

Pregunta:

¿Y si realizamos *un solo paso* de mejora?

Política de Rollout

Dada una política base u :

$$u \rightarrow V^u \rightarrow u'$$

La nueva política u' satisface:

$$V^{u'} \geq V^u$$

es decir, nunca es peor que la política original.

Un Mismo Lenguaje para Problemas Distintos

Hemos aplicado toma de decisiones secuenciales a problemas muy diferentes:

- Precios dinámicos en aerolíneas.
- Gestión de recursos naturales.
- Inventarios y logística.

Aunque los contextos son distintos, todos comparten la misma estructura:

Estado + Decisión + Incertidumbre + Consecuencias Futuras

Veamos ahora una nueva aplicación: la gestión de portafolios de inversión.

Aplicación: Gestión de Portafolios

Imagina que debes gestionar un capital W_t durante T períodos, eligiendo entre dos activos:

- **Activo Sin Riesgo (Caja de Ahorro):** Rendimiento constante r_f .
- **Activo Con Riesgo (Acción):** Precio s_t que sigue un modelo *lognormal*.

Dinámica del Precio (Tiempo Discreto)

$$s_{t+1} = s_t \cdot e^{(r - \sigma^2/2) + \sigma \epsilon_t}, \quad \epsilon_t \sim N(0, 1)$$

Donde r es el retorno esperado y σ la volatilidad (riesgo).

Objetivo inicial: Maximizar el valor final esperado del portafolio $\mathbb{E}[W_T]$.

El Modelo Lognormal: Intuición

En lugar de la fórmula compleja del precio, miremos el **log-rendimiento**:

$$\xi_{t+1} = \log \left(\frac{s_{t+1}}{s_t} \right) \approx \text{Rendimiento en el periodo } t$$

- **Normalidad de Rendimientos:** $\xi_t \sim N(\mu, \sigma^2)$
- **Precios No Negativos:** $s_{t+1} = s_t \cdot e^{\xi_{t+1}} \geq 0$
- **Interés Compuesto:** La forma exponencial captura naturalmente que los rendimientos se reinvierten y multiplican, en vez de sumarse.

El Modelo Lognormal Completo

$$s_{t+1} = s_t e^{(r - \sigma^2/2) + \sigma \epsilon_t}$$

El término $-\sigma^2/2$ es un ajuste técnico para que el valor esperado del precio crezca exactamente a tasa r . $\epsilon_t \sim N(0, 1)$ $t = 0, 1, \dots$ son variables normales estándar independientes.

De Datos Anuales a Decisiones Mensuales

Los parámetros financieros suelen reportarse en términos anuales.

Si tomamos decisiones cada Δ años, debemos ajustar:

- Retorno esperado: $r_{\Delta} = r\Delta$
- Volatilidad: $\sigma_{\Delta} = \sigma\sqrt{\Delta}$

Ejemplo

Activo con: $r = 10\%$, $\sigma = 40\%$

Si rebalanceamos mensualmente ($\Delta = 1/12$):

$$r_{mes} \approx 0,83\%, \quad \sigma_{mes} \approx 11,6\%$$

$$s_{t+1} = s_t e^{0,001572 + 0,116\epsilon_t}, \quad \epsilon_t \sim N(0, 1)$$

Portafolio como un MDP (S, A, P, R)

- **Estado (W_t):** Riqueza total en el momento t .
- **Acción (β_t):** Fracción del capital invertida en el activo con riesgo ($\beta_t \in [0, 1]$).
- **Transición:**

$$W_{t+1} = W_t \left[\underbrace{\beta_t e^{(r-\sigma^2/2)+\sigma\epsilon_t}}_{\text{Retorno Acción}} + (1 - \beta_t) \underbrace{e^{r_f}}_{\text{Retorno Seguro}} \right]$$

- **Recompensa Final:** $V_0(w) = w$. No hay recompensas intermedias.

Optimización de Portafolio: Solución

- Con el modelo lognormal para precios, se puede resolver la ecuación de Bellman analíticamente. Tenemos:

$$V_t^*(w) = w \max(e^r, e^{r_f})^t.$$

- Entonces, la política óptima no depende del tiempo ni del valor del portafolio:

$$\beta_t^*(w) = \beta^* = \begin{cases} 1 & \text{si } r > r_f \\ 0 & \text{si } r < r_f \\ \text{cualquier valor} & \text{si } r = r_f \end{cases}$$

Optimización de Portafolio: Observaciones

- En ese ejemplo, la solución es simple e intuitiva: maximizar el rendimiento esperado en cada período.
 - Eso se debe a que el rendimiento del activo es independiente y distribuido igualmente a cada periodo.
- La metodología puede ser aplicada en condiciones más complejas, por ejemplo:
 - la tasa de interés, el rendimiento de la acción y su volatilidad pueden ser fluctuantes;
 - pueden haber costos para realizar transacciones.
- En este caso tanto la variable de estado como la acción son continuas.
 - ¿Qué hacer si una solución analítica no existe? Necesitamos realizar aproximaciones, por ejemplo discretizando el espacio de estados y/o el espacio de acciones.

Solución por Inducción Hacia Atrás

Al resolver la ecuación de Bellman $V_t^*(w) = \max_{\beta} \mathbb{E}[V_{t+1}^*(W_{t+1})]$, encontramos un resultado sorprendente:

- **Política Óptima:**

$$\beta^* = \begin{cases} 1 & \text{si } r > r_f \\ 0 & \text{si } r < r_f \end{cases}$$


Conclusión "Peligrosa"

El agente decide invertir **todo** o **nada** en el activo de riesgo. No diversifica. *¿Por qué sucede esto?* Porque maximizar el valor esperado ignora por completo el **riesgo** (volatilidad).

Distribución del Rendimiento Según la Volatilidad

- $R_{\text{riesgo}} = e^{r - \sigma^2/2 + \sigma\epsilon}$, donde $\epsilon \sim N(0,1)$, y $R_{\text{ahorro}} = e^{r_f}$
- Generamos la distribución de R_{riesgo} con Python...

Distribución del Rendimiento en un Periodo del Instrumento de Riesgo



Diseño de Recompensa: Aversión al Riesgo

Maximizar el valor esperado $\mathbb{E}[W_T]$ ignora la volatilidad, resultando en decisiones de "todo o nada". Para capturar el comportamiento humano real, debemos repensar la recompensa.

El Dilema de la Moneda

¿Qué preferirías recibir?

- **Opción A:** US\$500,000 garantizados (seguridad).
- **Opción B:** Una moneda al aire por US\$0 o US\$1,000,000 (riesgo).

*Aunque el valor esperado es el mismo (US\$500k), la mayoría elige la seguridad. Esto es la **Aversión al Riesgo**.*

Perder US\$500000 duele más que ganar US\$500000. ¿Cómo capturamos esa preferencia? Mediante las **funciones de utilidad**.

Para representar la postura ante el riesgo, no maximizamos el valor nominal, sino la **Utilidad** del dinero: $\max \mathbb{E}[u(W_T)]$.

- **Aversión al riesgo ($u(w)$ cóncava):** Preferimos un resultado seguro a una apuesta con el mismo valor esperado.
- **Neutralidad al riesgo ($u(w)$ lineal):** Solo nos importa el valor esperado; es el caso que vimos al inicio.
- **Preferencia por el riesgo ($u(w)$ cónvexa):** Se valora la posibilidad de grandes ganancias por encima de la estabilidad.

*En economía y finanzas, la norma es la **concavidad**: el "dolor" de perder \$1 es mayor que el "placer" de ganar \$1.*


Utilidad CRRA: Aversión Relativa Constante

La función más utilizada es la **CRRA** (*Constant Relative Risk Aversion*):

$$u(w) = \frac{w^\gamma}{\gamma}, \quad \text{con } \gamma < 1, \gamma \neq 0$$

- **¿Qué significa Relativa Constante?** Tu tolerancia al riesgo es **proporcional** a tu riqueza. La fracción de capital invertida en riesgo (β) no cambia si tu riqueza aumenta de \$1,000 a \$1M.
- **El papel de γ (Parámetro de riesgo):**
 - $\gamma \rightarrow 1$: Neutral al riesgo (se vuelve lineal).
 - $\gamma \rightarrow 0$: Converge a $u(w) = \log(w)$.

Visualizando la Función de Utilidad



Intuición de la Curvatura

Cuanto menor es γ , más »curvada« es la función. Esto penaliza fuertemente los resultados bajos, obligando al MDP a elegir una fracción de riesgo β más pequeña.

Optimización con Utilidad (CRRA)

Al introducir $u(w) = w^\gamma$, la ecuación de Bellman cambia. La nueva política óptima β^* ahora **sí considera la volatilidad**:

$$\beta_\gamma^* = \arg \max_{\beta \in [0,1]} \mathbb{E} \left[\left(\beta e^{r - \sigma^2/2 + \sigma \epsilon} + (1 - \beta) e^{r_f} \right)^\gamma \right]$$

- Ya no es "todo o nada". El agente diversifica.
- Sin embargo, con esta función (CRRA), la fracción β^* no depende de cuánta plata tenés (w), lo cual simplifica mucho la gestión.

¿Cuándo Depende la Política del Estado?

En nuestro modelo con utilidad CRRA, vimos que β^* es una constante. La fracción óptima invertida no depende de la riqueza w .

¿Cuándo la política depende del estado? Cuando éste afecta:

- **Las acciones disponibles**

- Límites de endeudamiento.
- Requerimientos mínimos de efectivo.
- Costos de transacción.

- **Las oportunidades futuras**

- Regímenes de mercado (bull/bear).
- Horizonte restante hasta el objetivo.
- Ingresos futuros esperados.

Los Límites de MDPs

Los MDPs nos permiten formular problemas de decisión secuencial y encontrar políticas óptimas. Pero los métodos exactos que hemos estudiado enfrentan dos desafíos importantes:

1 **Modelo desconocido**

Las probabilidades de transición y recompensas pueden no estar disponibles. Deben aprender a actuar óptimamente a partir de datos o experiencia.

2 **Espacios de estados enormes**

Incluso conociendo el modelo, almacenar y calcular $V(s)$ para todos los estados puede ser imposible, cuando el espacio de estados es demasiado grande.

La Idea del RL

Aprender y mejorar políticas a partir de simulación o experiencia, sin depender de modelos exactos ni de recorrer exhaustivamente todos los estados.