

Modelos y Algoritmos para Toma de Decisiones Secuenciales y Aprendizaje por Refuerzo

Una de las áreas más impactantes de la inteligencia artificial es el *aprendizaje por refuerzo* (*reinforcement learning*). En ese paradigma, un agente interactúa con un ambiente y aprende a elegir sus acciones de forma a optimizar sus objetivos. En los últimos años, el aprendizaje por refuerzo ha sido utilizado con gran éxito en numerosas aplicaciones. Ejemplos famosos incluyen AlphaGo, el jugador automático del milenar juego y notoriamente complejo juego Go, desarrollado por Google; vehículos autónomos; sistemas de procesamiento de lenguaje natural incluyendo Alexa y ChatGPT; sistemas de recomendación, como los de Netflix; y muchas otras aplicaciones en áreas como medicina, marketing, ingeniería, finanzas y gestión.

En este curso estudiaremos las técnicas y conceptos del aprendizaje por refuerzo, así como los modelos matemáticos que están por detrás de los algoritmos. Esos modelos, denominados *procesos markovianos de decisión* (MDPs), son interesantes y poderosos por sí mismos, permitiendo modelar y resolver numerosos problemas de decisión del mundo real, capturando dependencias al largo del tiempo e incertidumbre.

El objetivo del curso será proveer un entendimiento profundo de la metodología de MDPs, permitiendo a los alumnos desarrollar sus propios modelos, resolverlos a través de varias técnicas exactas y aproximadas, e interpretar resultados computacionales para aplicarlos con seguridad en situaciones que encuentren en la vida real.

Plan de Estudios

Semana 1: Introducción al aprendizaje por refuerzo. Definición y ejemplos. Procesos Markovianos. Modelado de ambientes utilizando procesos markovianos y cadenas markovianas. Propiedad de Markov. Distribución Estacionaria de Estados. Aplicaciones al estudio de regímenes de mercado y análisis de participación de empresas en el mercado.

Semana 2. Procesos de Decisión Markovianos. Modelaje de problemas utilizando MDPs. MDPs con horizonte finito. Ecuación de Bellman y resolución por recursión. La paradoja de Monty Hall. Optimización de portafolios y funciones de utilidad. Aversión al riesgo. Precificación de opciones europeas.

Semana 3. MDPs con horizonte infinito. Criterios de optimalidad. Factores de descuento y sus interpretaciones. Función valor y función de política de acción. Iteración de valor. Iteración de políticas. Optimización de consumo con portafolios. Precificación de opciones americanas. Gestión de inventarios.

Semana 4. Aprendizaje por refuerzo. Aprendizaje basado en modelos y aprendizaje libre de modelos. Aprendizaje de la función valor o búsqueda de funciones de política. La función Q^* . El algoritmo de Robbins-Monro y Q-learning. Exploración vs explotación. Aprendizaje online y offline. Aplicación a precificación de opciones.

Semana 5. Decisiones en sistemas de grande escala. Métodos para una solución aproximada. Aproximación de la función valor, aproximación de la función de política de acción. El método actor-crítico. Agregación de estado. Arquitecturas de aproximación lineales. Arquitecturas de aproximación no lineales. Las estrategias de TD-Gammon y Alpha-Go.