

Trabajo Práctico || Optimización de Decisiones Secuenciales Bajo Incertidumbre - Propuesta del Problema

Reinforcement Learning

- 1. Selección de la problemática*
 - a. Problemática*
 - b. Justificación de la selección*
- 2. Modelado del proceso de decisión markoviano (MDP)*
 - a. Espacio de acciones*
 - b. Variables de estado*
 - c. Dinámica del sistema*
 - d. Función de recompensa*

Ayelen Noelia Abraldes - 24M1886
Matias Lopez Duberti - 24Y2422
Bruno Malarini Elgoyhen - 24T3525

1. Selección de la problemática

a. Problemática

La problemática es el modelado de un sistema de diferenciación de **precios dinámicos** para plataformas de transporte privado (ejemplos: Uber y Waze).

b. Justificación de la selección

Las plataformas de transporte privado son un buen caso para estudiar precios dinámicos porque funcionan en un mercado donde tanto conductores como pasajeros fluctúan constantemente. La demanda cambia drásticamente según la hora, el clima o eventos especiales, creando patrones complejos que pueden ser aprovechados para mejorar la satisfacción de todos los usuarios involucrados. Estas plataformas recogen constantemente información en tiempo real sobre todo lo que ocurre, permitiéndonos ser consciente de qué estrategias funcionan y qué no cuando ajustamos los precios. Por lo cual, estas plataformas son un entorno perfecto para estudiar y perfeccionar mecanismos de precios adaptativos que equilibren eficientemente el mercado mientras optimizan tanto la experiencia del usuario como la rentabilidad del servicio.

2. Modelado del proceso de decisión markoviano (MDP)

a. Espacio de acciones

El espacio de acciones A:

$A = \{1.0, 1.5, 2.0, 2.5, 3.0\}$ (multiplicadores de precio posibles)

La elección de este espacio de acciones se debe a que reflejan la práctica común en aplicaciones de transporte (Uber utiliza multiplicadores similares), donde 1.0x representa el precio base sin sobrecargo y 3.0x representa un límite superior razonable para situaciones extremas.

b. Variables de estado

El Espacio de estados S está compuesto por:

$S = \{(h, d, c) \mid h \in \{0, 1, \dots, 23\}, d \in \{\text{bajo, medio, alto}\}, c \in \{\text{bajo, medio, alto}\}\}$

Donde:

h: hora del día (0-23)

d: nivel de demanda actual

c: disponibilidad de conductores actual

La elección de las horas del día se debe a que captura las horas pico (7-9 AM, 5-7 PM), horas valle y períodos nocturnos con una discretización en 24 períodos que ofrece suficiente concentración sin excesiva complejidad computacional.

La elección del nivel de demanda actual se debe a que la categorización en tres niveles (bajo, medio, alto) simplifica el modelo mientras mantiene la capacidad de capturar variaciones significativas, y permite modelar

situaciones excepcionales (eventos, clima) sin añadir variables específicas.

Finalmente, la elección de la disponibilidad de conductores representa la oferta disponible en el sistema y es necesaria para el equilibrio del mercado y la viabilidad de completar viajes. Además, la categorización en tres niveles permite modelar escenarios críticos (escasez severa) y óptimos (abundancia).

c. Dinámica del sistema

El funcionamiento del sistema sería un modelo de transición probabilística $P(s'|s,a)$ donde:

- La hora avanza determinísticamente: $h' = (h + 1) \bmod 24$
- La demanda y disponibilidad evolucionan estocásticamente según 
 - La hora actual y siguiente
 - El multiplicador de precio aplicado
 - Los niveles actuales de demanda y conductores

La elección de dicho sistema tiene en cuenta que los precios altos pueden desalentar a los usuarios (baja la demanda) y también porque refleja que en ciertos momentos del día, como en las horas pico, es más probable que haya una demanda alta. Asimismo, refleja cómo la oferta responde a los cambios del mercado y muestra que tanto la demanda como la disponibilidad en el futuro dependen del precio que se fije hoy.

d. Función de recompensa

La función de recompensa determinada r es:

$$r(s, a) = \text{tarifa_base} * a * P_completar(s, a) - \text{penalidad_insatisfaccion}(s, a) \quad \text{img alt="purple speech bubble icon" data-bbox="614 504 644 527}$$

Donde:

- tarifa_base es el precio base del viaje (por ejemplo, \$5)
- $\text{penalidad_insatisfaccion}(s, a)$ representa la pérdida potencial por insatisfacción del cliente, que puede ocurrir por dos razones principales:
 - Penaliza situaciones con falta de conductores disponibles
 - Penaliza tiempos de espera excesivos cuando la demanda es alta y la disponibilidad baja

La función de recompensa presentada refleja el objetivo dual de maximizar ingresos mientras se mantiene una base de usuarios satisfecha, capturando el trade-off fundamental entre precios más altos que generan mayor ingreso por viaje y la experiencia del cliente que impacta en la retención a largo plazo. El modelo combina la aceptación del usuario, la disponibilidad de conductores y los tiempos de espera, permitiendo balancear precios óptimos según las condiciones del mercado mientras penaliza explícitamente situaciones que generan insatisfacción, reconociendo que el valor sostenible de la plataforma depende tanto de la rentabilidad inmediata como de la calidad del servicio percibida.