

Trabajo Práctico || Optimización de Decisiones Secuenciales Bajo Incertidumbre

Reinforcement Learning

**Sistema de diferenciación de precios dinámicos para
plataformas de transporte privado**



Ayelén Noelia Abraldes - 24M1886
Matías Lopez Duberti - 24Y2422
Bruno Malarini Elgoyhen - 24T3525

Índice

- 1. Descripción del Problema**
 - a. Problemática
 - b. Justificación
- 2. Modelado del proceso de decisión markoviano (MDP)**
 - a. Espacio de acciones
 - b. Variables de estado
 - c. Dinámica del sistema
 - d. Función de recompensa
 - e. Función valor
 - f. Restricciones del modelo
- 3. Algoritmos de solución**
 - a. Análisis del algoritmo más rápido
 - b. Métodos exactos y métodos aproximados
 - c. Aplicación Q Learning
- 4. Análisis y futuras direcciones**
 - a. Análisis de las políticas óptimas obtenidas
 - b. Impacto de modelado y aspectos computacionales
 - c. Direcciones futuras

Link al Google Colab con las resoluciones en Python:

 TP RL - Abraldes - Lopez Duberti - Malarini Elgoyhen.ipynb

Link a la Presentación: [Presentación TP RL - Abraldes - Lopez Duberti - Malarini Elgoyhen](#)

1. Descripción del Problema

a. Problemática

Se ha elegido como situación a modelar un sistema de diferenciación de **precios dinámicos** para plataformas de transporte privado en ámbitos urbanos (ejemplos: Uber y Cabify).

b. Justificación

Las plataformas de transporte privado son un buen caso para estudiar precios dinámicos porque funcionan en un mercado donde tanto conductores como pasajeros fluctúan constantemente. La demanda cambia drásticamente según la hora, el clima o eventos especiales, creando patrones complejos que pueden ser aprovechados para mejorar la satisfacción de todos los usuarios involucrados. Estas plataformas recogen constantemente información en tiempo real sobre todo lo que ocurre, permitiéndonos conocer cuáles estrategias funcionan y cuáles no, cuando se ajustan los precios. Por esta razón, estas plataformas son un entorno óptimo para estudiar y perfeccionar mecanismos de precios adaptativos que equilibren eficientemente el mercado mientras optimizan tanto la experiencia del usuario como la rentabilidad del servicio.

2. Modelado del proceso de decisión markoviano (MDP)

a. Espacio de acciones

El espacio de acciones A:

$$A = \{1.0, 1.5, 2.0, 2.5, 3.0\} \text{ (multiplicadores de precio posibles)}$$

La elección de este espacio de acciones se debe a que reflejan la práctica común en aplicaciones de transporte (Uber utiliza multiplicadores similares), donde 1.0x representa el precio base sin sobrecargo y 3.0x representa un límite superior razonable para situaciones extremas de sobredemanda.

b. Variables de estado

El Espacio de estados S está compuesto por:

$$S = \{(h, d, c) \mid h \in \{0, 1, \dots, 23\}, d \in \{\text{bajo, medio, alto}\}, c \in \{\text{bajo, medio, alto}\}\}$$

Donde:

- *h*: hora del día (0-23);
- *d*: nivel de demanda actual;
- *c*: disponibilidad de conductores actual.

La elección de las horas del día se debe a que captura las horas pico (7-9 AM, 5-7 PM), horas valle y períodos nocturnos con una discretización en 24 períodos que ofrece suficiente concentración sin excesiva complejidad computacional.

La elección del nivel de demanda actual se debe a que la categorización en tres niveles (bajo, medio, alto) simplifica el modelo mientras mantiene la capacidad de capturar variaciones significativas, y permite modelar situaciones excepcionales (eventos, clima) sin añadir variables específicas.

Finalmente, la elección de la disponibilidad de conductores representa la oferta disponible en el sistema y es necesaria para el equilibrio del mercado y la viabilidad de completar viajes. Además, la

categorización en tres niveles permite modelar escenarios críticos (escasez severa), neutrales (de equilibrio) y óptimos (abundancia).

c. Dinámica del sistema

Para cualquier estado $s = (h, d, c)$ y acción a (multiplicador de precio):

$$P(s' | s, a) = P((h', d', c') | (h, d, c), a)$$

Donde:

- $h' = (h + 1) \bmod 24$ (la hora avanza cíclicamente);
- La transición de demanda y conductores depende de:
 - La hora actual y siguiente;
 - El multiplicador de precio aplicado;
 - Los niveles actuales de demanda y conductores.

Entonces, se plantean las siguientes transiciones de estados según distintos casos posibles dentro del conjunto de escenarios planteados.

Para la demanda:

- $P(d' = \text{bajo} | s, a) = f_d_bajo(h, d, c, a)$
- $P(d' = \text{medio} | s, a) = f_d_medio(h, d, c, a)$
- $P(d' = \text{alto} | s, a) = f_d_alto(h, d, c, a)$

Para los conductores :

- $P(c' = \text{bajo} | s, a) = f_c_bajo(h, d, c, a)$
- $P(c' = \text{medio} | s, a) = f_c_medio(h, d, c, a)$
- $P(c' = \text{alto} | s, a) = f_c_alto(h, d, c, a)$

Luego, las probabilidades de aceptación del precio para los usuarios varían naturalmente según el multiplicador y luego también según el contexto de la demanda: **Buen modelo probabilístico.**

<i>Prob_usuario</i>	<i>Multiplicador</i>				
<i>Demanda</i>	<i>1.0</i>	<i>1.5</i>	<i>2.0</i>	<i>2.5</i>	<i>3.0</i>
<i>Baja</i>	1.0	0.60	0.25	0.10	0.03
<i>Media</i>	1.0	0.70	0.40	0.20	0.08
<i>Alta</i>	1.0	0.80	0.55	0.35	0.15

Estos valores son estimaciones basadas en el comportamiento típico de los usuarios de servicios de transporte y siguen una distribución decreciente que refleja la realidad. Todos los usuarios (100%) aceptarían el precio base, mientras que solo un pequeño porcentaje aceptaría un precio tope (triplicado), con un descenso gradual en base a los aumentos. Por otro lado, es lógico que en contextos de mayor demanda, el usuario esté más predispuesto a aceptar pagar un monto más elevado. ✓

Dentro de estos aumentos graduales, la curva de caída es más pronunciada entre 1.5x y 2.5x, lo que refleja umbrales psicológicos comunes en la disposición a pagar. ✓

En base a esto, continuamos con el diseño de la función de probabilidad para la concreción de un viaje.

Para un estado $s = (h, d, c)$ y acción a :

?

$$P_{\text{completar}}(s, a) = \text{Prob_usuario}(m_{\text{ea}}) * f_{\text{disponibilidad}}(c)$$

Es una probabilidad conjunta que combina dos factores independientes, por un lado que el usuario acepta un determinado multiplicador de precio (Prob_usuario) y por otro lado que haya un conductor disponible.

Aquí, $f_{\text{disponibilidad}}(c)$ es un factor que representa la probabilidad de que un usuario encuentre un conductor disponible según el nivel de oferta:

$f_{\text{disponibilidad}}$	Oferta		
<i>Demanda</i>	<i>Baja</i>	<i>Media</i>	<i>Alta</i>
<i>Baja</i>	0.45	0.40	0.30
<i>Media</i>	0.75	0.70	0.60
<i>Alta</i>	0.98	0.95	0.90

Es una probabilidad conjunta que combina la demanda, que incentiva la presencia de conductores y por otro a los efectos de congestión, que reducen la probabilidad de encontrar un viaje en escenarios de alta disponibilidad de oferta.

d. Función de recompensa

El siguiente paso consiste en determinar la función de recompensa (r), que fijará el objetivo del modelo. La misma se expresa de la siguiente manera:

$$r(s, a) = \text{Tarifa_base} * a * P_{\text{completar}}(s, a) - \text{Penalidad_insatisfaccion}(s, a)$$

Donde:

- *Tarifa_base* es el precio base del viaje (arbitrariamente lo hemos establecido en 5 unidades monetarias pero tomamos el supuesto de que el modelo es independiente de este parámetro);
- $P_{\text{completar}}(s, a)$ se ha explicado en el inciso anterior;
- $\text{Penalidad_insatisfaccion}(s, a)$ representa la pérdida potencial por insatisfacción del cliente, que puede ocurrir por dos razones principales:
 - Penaliza situaciones con falta de conductores disponibles;
 - Penaliza tiempos de espera excesivos cuando la demanda es alta y la disponibilidad baja.

Entonces, la $\text{Penalidad_insatisfaccion}(s, a)$ se define específicamente de la siguiente manera para nuestro modelo:

$$\text{Penalidad_insatisfaccion}(s, a) = \text{Penalidad_conductores}(s, c) + \text{Penalidad_espera}(s, d, c, a)$$

Donde:

- *Penalidad_conductores(s, c)* penaliza la falta de conductores disponibles:

- 3.0 si $c = \text{bajo}$;
- 1.0 si $c = \text{medio}$;
- 0.0 si $c = \text{alto}$.

Esta penalización refleja el costo a largo plazo de usuarios que abandonan la plataforma por no encontrar conductores para su viaje.

- *Penalidad_espera(s, d, c, a)* penaliza los tiempos de espera excesivos y se construye de la siguiente forma en el modelo:

$$\text{penalidad_espera}(s, d, c, a) = \text{factor_base_espera} * \text{ratio_demanda_oferta} * (1 + \text{factor_precio})$$

Sus parámetros se constituyen de la siguiente forma:

- *factor_base_espera* = 2.0 (costo base por tiempos de espera);
- *ratio_demanda_oferta* representa el desequilibrio entre demanda y oferta:
 - 3.0 si $d = \text{alto}$ y $c = \text{bajo}$;
 - 2.0 si $d = \text{alto}$ y $c = \text{medio}$, o $d = \text{medio}$ y $c = \text{bajo}$;
 - 1.0 si $d = \text{medio}$ y $c = \text{medio}$, o $d = \text{bajo}$ y $c = \text{bajo}$;
 - 0.5 si $d = \text{alto}$ y $c = \text{alto}$, o $d = \text{medio}$ y $c = \text{alto}$, o $d = \text{bajo}$ y $c = \text{medio}$;
 - 0.0 si $d = \text{bajo}$ y $c = \text{alto}$.
- *factor_precio* = $\max(0, 2.0 - a)$ representa el efecto adicional del precio en la insatisfacción, donde es inversamente proporcional al valor del multiplicador (si hay menos multiplicador, en teoría hay menor demanda y más oferta, si este es el contexto, se justifican menos los tiempos de espera). **Hay que pensar si siempre es así, dado que el multiplicador es la decisión que toma el sistema.**

La función de recompensa presentada refleja el objetivo dual de maximizar ingresos mientras se mantiene una base de usuarios satisfecha, capturando el trade-off fundamental entre precios más altos que generan mayor ingreso por viaje para los conductores y la experiencia del cliente, que impacta en la retención a largo plazo. El modelo combina entonces la aceptación del usuario, la disponibilidad de conductores y los tiempos de espera, permitiendo balancear precios óptimos según las condiciones del mercado mientras penaliza explícitamente situaciones que generan insatisfacción, reconociendo que el valor sostenible de la plataforma depende tanto de la rentabilidad inmediata como de la calidad del servicio percibida.

e. Función valor

La función de valor $V(s)$ representa el beneficio total esperado al comenzar en el estado s y seguir la política óptima:

$$V(s) = \max_a [r(s, a) + \beta * \sum_{s'} P(s'|s, a) * V(s')]$$

La política óptima $\pi^*(s)$ es la acción que maximiza esta expresión para cada estado:

$$\pi^*(s) = \operatorname{argmax}_a [r(s, a) + \beta * \sum_{s'} P(s'|s, a) * V(s')]$$

f. Restricciones del modelo

Nuestro modelo acerca una simplificación sobre la base de la realidad del transporte urbano. Dividimos la demanda y disponibilidad de conductores en solo tres categorías discretas (baja, media y alta), cuando en la práctica estos factores fluctúan de manera continua. Limitamos los precios a cinco multiplicadores fijos, mientras que algunas de las plataformas que están presentes en el mercado manejan ajustes con mucha mayor precisión. Tratamos a todos los usuarios como si tuvieran la misma sensibilidad al precio, ignorando situaciones en las cuales un usuario puede tener más urgencia que otro y tampoco consideramos la geografía de la ciudad, donde ciertos barrios pueden tener mucha mayor demanda que la media mientras que en otras zonas esta se encuentra por debajo. Tampoco incluimos factores externos como lluvia intensa o eventos masivos que alteran drásticamente los patrones normales. Asumimos que las personas responden igual a los precios independientemente de la situación, y no contemplamos cómo usuarios y conductores aprenden con el tiempo a anticipar y adaptarse a los cambios de precio. Estas simplificaciones nos permiten crear un modelo manejable matemáticamente, pero sacrifican parte de la complejidad que enfrentan quienes gestionan de forma activa las plataformas. ✓

3. Algoritmos de solución

a. Análisis del algoritmo más rápido

Observamos que la Iteración de Política se muestra como el método más eficiente, completando la convergencia en apenas 0.311 segundos, tras solo 3 mejoras. Este rendimiento supera notablemente a la Iteración de Valor, que requirió 0.613 segundos y 88 iteraciones, y especialmente al Q-Learning, que consumió 2.922 segundos para procesar 5000 episodios. La eficiencia de la Iteración de Política se debe a que, a pesar de que cada iteración implica resolver un sistema de ecuaciones lineales más complejo que en la Iteración de Valor, el número drásticamente menor de iteraciones necesarias compensa ampliamente este costo computacional adicional. Esta ventaja es típica de modelos en los que el espacio de acciones es pequeño y una acción “dominante” aparece pronto.

Particularmente para Q-Learning, es lógico que la demora sea superior ya que cada episodio requiere recorrer las 24hs de cada día simulado, generando unas 120.000 actualizaciones.

Respecto a la coincidencia de políticas, entre los algoritmos de métodos exactos, ambos llegan a exactamente la misma política tras recorrer los 216 estados posibles, encontrando solamente un óptimo.

En cambio, en la comparación entre Value Iteration y Q-Learning, solo en aproximadamente la mitad de los estados, la acción elegida por la política *greedy* sobre la tabla “Q”, coincide con la acción óptima. [Por qué?](#)

b. Métodos exactos y métodos aproximados

Los métodos exactos (Iteración de Valor e Iteración de Política) mostraron un comportamiento más eficiente, convergiendo a la misma política óptima con una diferencia media de 0.0000. Estas políticas muestran una estabilidad notable, empleando principalmente multiplicadores de 2.0x para la mayoría de los estados, con patrones predecibles como el uso consistente de este multiplicador para estados con baja y media disponibilidad de conductores.

En contraste, el método aproximado Q-Learning produjo una política mucho más variable, con una diferencia media de 0.4491 respecto a los métodos exactos. Los multiplicadores fluctúan de manera variable entre 1.0x y 3.0x a lo largo del día sin mostrar patrones claros. Esta variabilidad refleja las limitaciones del

método: no garantiza convergencia a la política óptima en un número finito de episodios, depende fuertemente de la calidad y cantidad de experiencias simuladas, y requiere un tiempo de ejecución considerablemente mayor debido a la necesidad de simular múltiples episodios para construir progresivamente la función Q. ✓

Como conclusión, en estos contextos, en los que se dispone del modelo, el Policy Iteration suele ser la mejor opción en MDP medianos.

c. Aplicación Q Learning

En la primera corrida (5.000 episodios) configuramos Q-Learning con una tasa de aprendizaje inicial moderada ($\alpha_0 = 0,5 \rightarrow 0,05$) y un esquema ϵ -greedy que descendía de 1 a 0,1 con decaimiento 0,999. Esa combinación permitió absorber rápidamente las primeras recompensas, pero el descenso relativamente veloz de α y ϵ dejó muchos estados poco visitados con ajustes mínimos, lo que se reflejó en una política que coincidía con la óptima sólo en aproximadamente el 45 % de los estados, y exhibía fuertes oscilaciones de retorno episodio-a-episodio. El entrenamiento consumió casi 3 segundos –unas 5 veces más que los métodos exactos – sin acercarse a su desempeño. ✓

Para la segunda iteración (50.000 episodios) adoptamos un enfoque “explorar-lento, consolidar-tarde”: elevamos α_0 a 0,60, fijamos $\alpha_{\min} = 0,01$ y desaceleramos el decaimiento a 0,9999. A la vez, mantuvimos ϵ en 1,0 durante más tiempo y lo llevamos solo hasta 0,05. Con 10 veces más episodios y tasas vivas por más pasos, la cobertura del espacio de estados mejoró y la política resultante alcanzó 71.30 % de coincidencia con π^* , manteniendo el tiempo en torno a 12 segundos debido a estos ajustes. Aunque todavía lejos de la perfección que logran la iteración de Valor y de Política, el salto de 26 puntos porcentuales demuestra que una exploración prolongada y tasas de aprendizaje más persistentes son esenciales para estabilizar Q-Learning en este dominio. ✓

4. Análisis y futuras direcciones

a. Análisis de las políticas óptimas obtenidas

Las políticas óptimas derivadas mediante Iteración de Valor e Iteración de Política convergen a un mismo patrón estratégico, como lo refleja su coincidencia del 100% en todas las combinaciones estado-acción. Esto valida la solidez de ambas técnicas en este entorno discreto. En contraste, Q-Learning alcanza una coincidencia del 71.30%, mostrando una aproximación razonable pero todavía distante del óptimo, incluso tras 50.000 episodios de entrenamiento.

El análisis de la política óptima obtenida por Iteración de Valor muestra un patrón altamente estable y estructurado. El multiplicador 2.0x es consistentemente seleccionado cuando la demanda es media o alta, sin importar la hora del día o la oferta disponible. En situaciones con demanda baja, la política opta por reducir los precios: 1.5x con oferta media y 1.0x con oferta alta. Este comportamiento refleja una sensibilidad al desequilibrio entre demanda y oferta, donde se penaliza la falta de conductores y se premia la contención de precios si la disponibilidad es alta.

A diferencia del análisis anterior, no se observa un uso de precios más bajos en las primeras horas del día ni una transición hacia precios más altos en horarios pico. De hecho, la política es completamente estable a lo largo de las 24 horas, lo que sugiere que las variaciones horarias no tienen un impacto directo en la política óptima bajo la parametrización actual. Asimismo, los extremos del espacio de acciones (1.0x y 3.0x) son usados selectivamente: el multiplicador 1.0x se elige exclusivamente en escenarios de demanda baja y

La dependencia de la política en el horario del día debería percibirse si el modelo hubiese capturado el impacto del horario sobre la demanda, pero en el colab veo que no incorporaron ese factor (la evolución de la demanda en su modelo depende solamente de la demanda actual).

oferta alta, y los valores superiores a 2.0x nunca son elegidos por las políticas exactas, señal de una penalización efectiva para precios considerados excesivos.

En cambio, Q-Learning introduce mayor variabilidad en sus decisiones y, aunque logra captar parte de la estructura del óptimo, tiende a generar políticas más ruidosas. Esta divergencia es atribuible a las limitaciones inherentes al aprendizaje aproximado, que enfrenta dificultades para capturar penalizaciones suaves o efectos acumulativos cuando el número de episodios es limitado.

Es necesario calibrar los hiperparámetros de Q-learning para mejorar su comportamiento.

Desde el punto de vista económico, la estrategia óptima muestra una preferencia clara por el multiplicador 2.0x como valor de referencia, ya que ofrece un balance adecuado entre ingresos por viaje y penalizaciones asociadas a espera o falta de conductores. La elección descendente a 1.5x o 1.0x en presencia de oferta más holgada es coherente con una política que evita disuadir la demanda en momentos donde los recursos (conductores) no son escasos. Así, el sistema prioriza la eficiencia operativa por sobre la rentabilidad inmediata, buscando evitar los extremos de precios que comprometan la experiencia del usuario o la disponibilidad de servicio. ✓

b. Impacto de modelado y aspectos computacionales

El diseño del modelo tiene un impacto directo en las decisiones óptimas. Por ejemplo, la penalización creciente con el desequilibrio entre demanda y oferta, y la penalización adicional para precios bajos (cuando $a < 2.0x$) moldean la función de recompensa de modo que desincentiva precios extremos. Estas funciones suaves y diferenciadas explican por qué la política evita tanto precios bajos como elevados, favoreciendo decisiones intermedias que garantizan la sostenibilidad del sistema.

La representación discreta del espacio de estados (3 niveles por variable y 24 horas) permite resolver el problema con eficiencia, pero también impone límites a la granularidad y suavidad de las políticas resultantes. A pesar de ello, los métodos exactos convergen rápidamente: Iteración de Valor lo hace en 88 barridos, mientras que Iteración de Política requiere solo 3 mejoras de política, mostrando una notable eficiencia computacional. En términos de tiempo, ambos métodos se ejecutan en menos de 1 segundo, mientras que Q-Learning requiere más de 12 segundos, sin lograr alcanzar el mismo nivel de desempeño en términos de política aprendida.

Estos resultados muestran que, si bien los métodos aproximados permiten generalizar y escalar, en dominios de tamaño manejable y con funciones suaves, los métodos exactos no solo son más eficientes, sino también más precisos.

c. Direcciones futuras

Existen varias vías prometedoras para enriquecer este modelo. Una de ellas es incorporar heterogeneidad en la demanda, modelando múltiples perfiles de usuarios con diferentes elasticidades y urgencias, lo que permitiría una política de precios más personalizada. También sería valioso incluir factores contextuales exógenos, como clima, eventos especiales o condiciones del tránsito, para capturar variaciones reales que afectan la disponibilidad o disposición a pagar. ✓

A nivel metodológico, extender el modelo a un espacio de estados continuo permitiría capturar variaciones más sutiles, aunque implicaría recurrir a técnicas más avanzadas como Redes Neuronales para aproximación de funciones en algoritmos de Aprendizaje por Refuerzo Profundo (como DQN). En esa dirección, mejorar Q-Learning mediante técnicas como Double Q-Learning, Experience Replay, o políticas de

exploración adaptativas ayudaría a reducir la varianza y mejorar la convergencia, acercando los resultados a los obtenidos por métodos exactos. ✓

Finalmente, explorar Aprendizaje por Refuerzo Inverso podría permitir derivar políticas óptimas a partir de datos históricos reales, infiriendo las verdaderas funciones de recompensa implícitas en las decisiones tomadas por operadores humanos. También se podría incorporar optimización robusta para enfrentar incertidumbre en la estimación de probabilidades de transición o parámetros de recompensa, garantizando así políticas más resilientes frente a cambios en las condiciones del mercado.

En suma, el presente modelo ofrece una base sólida para el estudio de precios dinámicos en transporte, y con las extensiones sugeridas podría evolucionar hacia una herramienta de análisis estratégica y operativamente valiosa.