

Trabajo Práctico: Optimización de Decisiones Secuenciales Bajo Incertidumbre

Toma de Decisiones Secuenciales y Aprendizaje por Refuerzo

Junio 2026

Objetivo

El objetivo de este trabajo práctico es modelar, resolver y analizar un problema real de toma de decisiones secuenciales bajo incertidumbre. A través de este proyecto, los estudiantes demostrarán su capacidad para:

- Formular y formalizar un modelo matemático adecuado basado en MDPs.
- Implementar tanto algoritmos de resolución exacta como métodos basados en simulación o aprendizaje.
- Evaluar críticamente las políticas óptimas resultantes, interpretando su estructura, viabilidad e impacto en el contexto del problema original.

Componentes del Proyecto

1. Modelado del Problema y Abstracción

- Seleccioná un problema de la realidad que requiera decisiones secuenciales y pueda estructurarse como un proceso markoviano de decisión (MDP).
- Definí y detallá analíticamente los componentes del modelo:
 - **Espacio de Estados (S)**
 - **Espacio de Acciones (A)**
 - **Dinámica de Transición (P)**
 - **Función de Recompensa (R)**
- **Justificación del Modelo:** Explicá por qué esta representación captura fielmente la dinámica temporal y la incertidumbre del problema. Discutí el trade-off del diseño: cómo tu elección metodológica permite modelar los aspectos más críticos del sistema real sin sufrir las consecuencias de una excesiva complejidad computacional. ¿Qué simplificaciones asumiste y qué elementos decidiste omitir para mantener el modelo manejable?

2. Implementación Numérica en Python

A partir de la formalización matemática anterior, programá las siguientes tres funciones utilizando estructuras vectorizadas en Python:

- $f(x, a, V) = r_a(x) + \alpha \sum_y P_a(x, y) V(y)$
Calcula y retorna el valor de continuación esperado al estar en el estado x y ejecutar la acción a , dada una función de valor V .
- $a^*(x, V) = \arg \max_a f(x, a, V)$
Determina la acción codiciosa (*greedy*) para el estado x , dada una función de valor V .
- $g(x, a) = (r, y)$ donde $r = r_a(x)$ y $y \sim P_a(x, \cdot)$
Genera una muestra estocástica de transición desde el estado x tras tomar la acción a , devolviendo la recompensa inmediata obtenida y el próximo estado.

3. Algoritmos de Solución

Usando las funciones programadas en la sección anterior, implementá tres algoritmos para resolver el problema de decisión formalizado:

- Iteración de Valor.
- Iteración de Política.
- Q-Learning (basado en el muestreo estocástico de transiciones).

4. Desempeño Algorítmico y Dinámica Computacional

- ¿Qué algoritmo demostró una mayor eficiencia computacional en términos de tiempo de convergencia? ¿Qué discrepancias u omisiones observás al contrastar las políticas y funciones de valor obtenidas mediante métodos exactos frente al método basado en simulación (Q-Learning)?
- Discutí detalladamente los aspectos críticos de tu implementación de Q-Learning, tales como la calibración de la tasa de aprendizaje y del *trade-off* entre exploración y explotación, y la estabilidad numérica del algoritmo.

5. Interpretación, Aplicabilidad y Crítica del Modelado

El informe final debe incluir una discusión profunda que traduzca los resultados numéricos en decisiones de gestión, estructurada bajo los siguientes ejes:

- **Interpretación y Sentido Económico de la Política Óptima:** Analizá la política resultante. ¿Tiene sentido desde la perspectiva económica y operativa del problema real? Identificá si la política tiene una estructura discernible. ¿Hay una interpretación intuitiva de la política óptima?
- **Impacto de la Abstracción y el Diseño del Modelo:** Evaluá cómo afectaron tus decisiones de modelado al resultado final. Podés profundizar en el impacto del tamaño del espacio de estados (maldición de la dimensionalidad) o en cómo la simplificación de la función de recompensa pudo haber inducido comportamientos imprevistos o sesgados respecto a la realidad.

- **Aplicabilidad, Limitaciones y Extensiones Futuras:** Proponé direcciones futuras para mitigar las limitaciones de tu modelo actual y mejorar su transferencia práctica. Describí qué desafíos teóricos y prácticos surgirían si decidieras incorporar espacios de estados continuos (aproximación lineal/Deep RL) o mitigar sesgos de maximización.

Entregables

- **8 de junio:** Formación de grupos (3 integrantes).
- **29 de junio:** Propuesta del problema a ser resuelto y modelo inicial de MDP (PDF, máx. 2 páginas).
- **27 de julio:**
 - Un informe PDF (máx. 8 páginas) con:
 - Descripción del problema.
 - Formalización final del MDP.
 - Resultados de las políticas obtenidas.
 - Análisis y futuras direcciones.
 - Código Python en un Jupyter Notebook. organizado y documentado.
 - Presentación oral (15 minutos).

Criterios de Evaluación

El proyecto se evaluará de manera integral bajo los siguientes criterios:

- **Calidad del Modelado:** Rigor en la definición de estados, acciones y recompensas, y solidez en la justificación de los supuestos y simplificaciones asumidas.
- **Corrección de la Implementación:** Exactitud numérica de los tres algoritmos en Python y eficiencia en la convergencia.
- **Profundidad del Análisis:** Capacidad crítica para interpretar la estructura de la política resultante, discutir sus limitaciones y evaluar su aplicabilidad práctica.
- **Claridad y Rigor Académico:** Estructura profesional del informe, uso correcto de la notación matemática y claridad en la visualización de resultados.
- **Originalidad:** Creatividad en el modelado del problema y/o la implementación computacional.

Sugerencias de proyectos

Los grupos pueden elegir una opción entre las ideas abajo o otro problema que sea de su interés, desde que se trate de una situación de toma de decisiones secuenciales.

Extensiones de Ejemplos Vistos en Clase

1. **Precios Dinámicos con Segmentación de Demanda:** Optimización de tarifas en tiempo real frente a un flujo heterogéneo de clientes donde la probabilidad de llegada de cada perfil varía a lo largo del horizonte de decisión.
2. **Optimización de Portafolio:** Extensiones donde el agente debe decidir simultáneamente el nivel de consumo y la asignación de capital entre activos con y sin riesgo, y/o donde se incorporen fricciones reales del mercado, como costos de transacción asimétricos o dinámicas de volatilidad estocástica y cambios de régimen en los activos, o múltiples activos de riesgo.
3. **Valuación de Opciones:** Determinación del precio y de la política de ejercicio óptimo para contratos con opcionalidad compleja (opciones bermuda, de barrera o asiáticas), o bajo modelos de activos subyacentes que abandonen los supuestos tradicionales de Black-Scholes (como incorporar saltos en el precio o volatilidad estocástica).
4. **Gestión de Inventario:** Estrategias de reposición bajo situaciones más complejas, por ejemplo donde la demanda exhiba patrones como estacionalidad, tendencias o autocorrelación, o la reposición esté sujeta a lead times, posiblemente con incertidumbre.

Otras Ideas de Aplicación

1. **Arbitraje Energético y Gestión de Baterías en la Red:** Optimización de los ciclos de carga y descarga de un sistema de almacenamiento comercial conectado a una red eléctrica.
2. **Mantenimiento Predictivo y Reemplazo de Activos:** Gestión del ciclo de vida de un equipo industrial sujeto a un proceso continuo y estocástico de deterioro.
3. **Control de Riego y Decisiones Agrícolas bajo Riesgo Climático:** Planificación secuencial del uso de recursos hídricos en el agro, donde las decisiones de riego deben adaptarse continuamente al estado de maduración del cultivo, las condiciones del suelo y un pronóstico meteorológico incierto.
4. **Estrategias de Retención y Gestión de Campañas de Marketing:** Optimización de la frecuencia de contacto y envío de incentivos a una base de clientes en un entorno contractual o de suscripción.